BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC FPT
FPT School of Business & Technology (FSB)

LUẬN VĂN THẠC SĨ

PHÁT TRIỂN TRỢ LÝ AI BẰNG GIỌNG NÓI HỖ TRỢ TÀI XẾ XE CÔNG NGHỆ

Chương trình đào tạo: Thạc sĩ — Kỹ thuật phần mềm
(Master of Software Engineering)

Học viên thực hiện: Trương Bá Chính

Giảng viên hướng dẫn:

TS. Lê Minh Đức

Hà Nội — 2026

Lời cam đoan

Tôi xin cam đoan đây là công trình nghiên cứu của riêng tôi, được thực hiện dưới sự hướng dẫn của TS. Lê Minh Đức. Các kết quả nêu trong luận văn là trung thực và chưa được công bố trong bất kỳ công trình nào khác để nhận bằng cấp.

Tôi xin chịu trách nhiệm trước Nhà trường về tính trung thực của luận văn này.

Hà Nội — 2026

Học viên

Trương Bá Chính

Tóm tắt

Tài xế xe công nghệ thường phải thao tác trên điện thoại trong lúc lái để xem chuyến, cập nhật trạng thái và liên lạc với khách hàng, làm tăng nguy cơ mất an toàn giao thông. Luận văn thiết kế, triển khai và đánh giá một trợ lý AI bằng giọng nói giúp tài xế thực hiện các nghiệp vụ này mà không cần dùng tay.

Trợ lý hỗ trợ tiếng Việt là ngôn ngữ chính và tiếng Anh là ngôn ngữ thứ hai, với ba nhóm nghiệp vụ: tra cứu và quản lý chuyến đi, liên lạc với khách hàng, hỗ trợ trong lúc vận hành (nhắc giờ đón, trả lời câu hỏi thường gặp). Trợ lý hoạt động trong ứng dụng tài xế (WebRTC) và qua cuộc gọi điện thoại (SIP).

Về phương pháp, luận văn đặc tả năm yêu cầu phi chức năng theo mô hình chất lượng ISO/IEC 25010 (khả năng sử dụng, hiệu năng, khả năng mở rộng, khả năng phục hồi, bảo mật), từ đó lập luận lựa chọn kiến trúc microservices triển khai trên AWS. Tác nhân hội thoại giọng nói xử lý mỗi lượt theo chuỗi nhận dạng giọng nói – mô hình ngôn ngữ lớn kèm gọi công cụ – tổng hợp giọng nói (STT – LLM – TTS), có nhà cung cấp dự phòng cho từng khâu và câu đệm khi phản hồi chậm quá 2 giây. Các nghiệp vụ được thực hiện qua các dịch vụ riêng, mỗi dịch vụ sở hữu dữ liệu của mình.

Hệ thống được đánh giá theo từng yêu cầu: độ trễ phản hồi (ngưỡng định hướng P95 $\leq$ 2 giây), tỷ lệ lỗi từ khi nhận dạng giọng nói, độ chính xác gọi công cụ, tỷ lệ hoàn thành nghiệp vụ, khả năng mở rộng và khả năng phục hồi. Chương 6 trình bày số liệu kèm cỡ mẫu và giới hạn của từng phép đo; trong đó phân tích nhật ký hội thoại xác định thời gian mô hình ngôn ngữ sinh token đầu là thành phần lớn nhất của độ trễ phản hồi.

Từ khóa: trợ lý AI bằng giọng nói, tài xế xe công nghệ, kiến trúc microservices, AWS, ISO/IEC 25010, gọi công cụ, STT, LLM, TTS, P95.

Lời cảm ơn

Trước hết, tôi xin bày tỏ lòng biết ơn sâu sắc tới TS. Lê Minh Đức, giảng viên hướng dẫn đã tận tình chỉ bảo, định hướng chuyên môn và góp ý trong suốt quá trình thực hiện luận văn.

Tôi xin chân thành cảm ơn Ban Giám hiệu, quý thầy cô và toàn thể cán bộ của FPT School of Business & Technology (FSB) đã tạo điều kiện học tập và nghiên cứu thuận lợi.

Tôi cũng xin gửi lời cảm ơn đến đồng nghiệp, bạn bè đã sẵn sàng chia sẻ kinh nghiệm, hỗ trợ chuyên môn và động viên trong quá trình triển khai hệ thống nguyên mẫu.

Đặc biệt, tôi xin bày tỏ lòng biết ơn sâu sắc đến gia đình — chỗ dựa vững chắc, luôn động viên và tạo điều kiện để tôi hoàn thành luận văn này.

Dù đã dành nhiều thời gian và nỗ lực, luận văn khó tránh khỏi thiếu sót. Tôi rất mong nhận được ý kiến đóng góp của quý thầy cô và bạn đọc để hoàn thiện hơn.

Xin trân trọng cảm ơn!

Danh sách hình ảnh

Hình 4.1. Kiến trúc hệ thống trên nền tảng AWS theo mô hình microservices

Hình 4.2. Sequence S1: đăng nhập tài xế và phát hành JWT

Hình 4.3. Sequence S2: khởi tạo phiên trợ lý trong ứng dụng

Hình 4.4. Sequence S3: xử lý một lượt hội thoại có gọi công cụ, câu đệm và dự phòng nhà cung cấp

Hình 4.5. Sequence S4: mời tài xế nhận chuyến qua cuộc gọi điện thoại

Hình 4.6. Sequence S5: gọi khách hàng theo ba chế độ và gửi tin nhắn SMS

Hình 4.7. Sequence S6: lưu bản ghi hội thoại và tra cứu tóm tắt cuộc gọi

Hình 4.8. Sequence S7: lập báo cáo vận hành ngày từ bản ghi hội thoại và chỉ số phiên

Hình 4.9. Chuỗi xử lý một lượt hội thoại: STT, LLM kèm gọi công cụ, TTS, câu đệm và dự phòng nhà cung cấp

Hình 5.1. Màn hình chào của ứng dụng tài xế

Hình 5.2. Màn hình đăng nhập tài xế bằng số điện thoại và mật khẩu

Hình 5.3. Màn hình bản đồ sau khi đăng nhập và bật trạng thái hoạt động

Hình 5.4. Phiên trợ lý giọng nói với biểu tượng trợ lý ở trạng thái đang xử lý

Hình 5.5. Hội thoại mẫu: tra cứu lịch trình và thông tin chuyến bằng giọng nói

Hình 5.6. Trang báo cáo vận hành ngày: các chỉ số tổng hợp (dữ liệu ngày 06/09/2026)

Hình 5.7. Trang báo cáo vận hành ngày: ví dụ câu trả lời bị chấm sai và xu hướng 7 ngày (dữ liệu ngày 06/09/2026)

Hình 6.1. P50 và P95 độ trễ phản hồi theo nhánh xử lý, đợt đo 05–06/09/2026 (n = 341 lượt)

Hình 6.2. Tỷ lệ lỗi từ ở điều kiện yên tĩnh và điều kiện nhiễu mô phỏng khoang xe

Hình C.1. Màn hình đăng ký trở thành tài xế trên ứng dụng Czen Driver.

Hình C.2. Biểu tượng trợ lý giọng nói ở trạng thái đang kết nối.

Hình C.3. Cài đặt trợ lý: chọn ngôn ngữ và chế độ gọi khách mặc định (tác nhân gọi thay hoặc tài xế nói trực tiếp).

Hình C.4. Cài đặt trợ lý: kích hoạt rảnh tay bằng từ khóa đánh thức và các tùy chọn nhắc khách.

Hình C.5. Màn hình dẫn đường trên bản đồ của ứng dụng tài xế (chức năng bản đồ, không thuộc trợ lý giọng nói): hướng rẽ, khoảng cách và thời gian còn lại.

Hình C.6. Gợi ý lộ trình tối ưu cho nhiều điểm đón/trả trong danh sách chuyến đang chạy.

Hình C.7. Tài xế tự tạo chuyến cho khách vãng lai, kèm các yêu cầu đặc biệt (hàng cồng kềnh, đi cùng trẻ em).

Hình C.8. Màn hình hồ sơ tài xế và các chỉ số vận hành (đánh giá, số chuyến, tỷ lệ nhận/hoàn thành).

Hình C.9. Màn hình thu nhập theo kỳ và chi tiết cước từng chuyến đã hoàn thành.

Hình C.10. Trang quản trị: bảng điều phối chuyến, lọc trạng thái và gán tài xế.

Hình C.11. Trang quản trị: tạo chuyến thử nghiệm và thông báo cho tài xế được gán.

Hình C.12. Trang quản trị: danh sách tài xế, trạng thái trực tuyến và khóa tài khoản.

Hình C.13. Trang quản trị: danh sách khách hàng và trạng thái tài khoản.

Hình C.14. Trang quản trị: nhật ký cuộc gọi kèm tóm tắt nội dung hội thoại.

Hình C.15. Trang giám sát hệ thống: tình trạng hoạt động của các dịch vụ backend (6/6 đang chạy).

Hình C.16. Trang giám sát hệ thống: cấu hình chuỗi STT – LLM – TTS của tác nhân hội thoại theo gói ngôn ngữ.

Hình C.17. Trang giám sát hệ thống: nhật ký thời gian thực của các dịch vụ, dùng để đọc độ trễ tổng hợp giọng nói (TTFB).

Hình C.18. Trang giám sát hệ thống: bản ghi và tóm tắt cuộc gọi, lấy qua Dịch vụ Giám sát vận hành.

Danh sách bảng

Bảng 1.1. Ánh xạ mục tiêu nghiên cứu, câu hỏi nghiên cứu và chương trả lời

Bảng 2.1. Các tính chất cơ bản của kiến trúc microservices

Bảng 2.2. Các chỉ số đánh giá và câu hỏi nghiên cứu tương ứng

Bảng 3.1. Thành phần hệ thống, trách nhiệm và ranh giới

Bảng 3.2. Ba chế độ gọi khách hàng

Bảng 3.3. Yêu cầu chức năng nhóm chuyến đi (FR-T)

Bảng 3.4. Yêu cầu chức năng nhóm liên lạc khách hàng (FR-C)

Bảng 3.5. Yêu cầu chức năng nhóm chờ đón, sự cố, thu nhập, hỗ trợ và ngôn ngữ

Bảng 3.6. Yêu cầu chức năng nhóm kích hoạt (FR-A)

Bảng 3.7. Yêu cầu chức năng nhóm giám sát vận hành (FR-O)

Bảng 3.8. Trường hợp sử dụng cốt lõi

Bảng 3.9. Yêu cầu phi chức năng theo ISO/IEC 25010 và kịch bản thuộc tính chất lượng

Bảng 3.10. Ràng buộc kiến trúc

Bảng 3.11. Đối chiếu yêu cầu phi chức năng với tính chất của kiến trúc microservices

Bảng 3.12. Tiêu chí chấp nhận theo yêu cầu

Bảng 4.1. Động lực kiến trúc

Bảng 4.2. Đánh giá các phương án kiến trúc theo yêu cầu phi chức năng

Bảng 4.3. Các phương án luồng xử lý lượt hội thoại

Bảng 4.4. Các luồng chính trên Hình 4.1

Bảng 4.5. Phân chia dịch vụ

Bảng 4.6. Các bước của sequence S1

Bảng 4.7. Các bước của sequence S2

Bảng 4.8. Các bước của sequence S3 (ví dụ tài xế yêu cầu cập nhật trạng thái đã đón khách)

Bảng 4.9. Các bước của sequence S4

Bảng 4.10. Các bước của sequence S5

Bảng 4.11. Các bước của sequence S6

Bảng 4.12. Các bước của sequence S7

Bảng 4.13. Nội dung trạng thái phiên hội thoại

Bảng 4.14. Loại phiên và tập công cụ

Bảng 4.15. Cơ chế thiết kế cho khả năng phục hồi, bảo mật và khả năng quan sát

Bảng 4.16. Đối chiếu yêu cầu phi chức năng với thiết kế

Bảng 5.1. Công nghệ sử dụng theo lớp kiến trúc

Bảng 5.2. Tổ chức mã nguồn

Bảng 5.3. Một lượt thực tế: tài xế nhờ nhắn tin cho khách khi dịch vụ gửi SMS gặp lỗi

Bảng 5.4. Nhóm API của Dịch vụ Chuyến đi và Điều phối phục vụ trợ lý

Bảng 5.5. Cấu trúc một bản ghi trong bảng call-records (giá trị ví dụ lấy từ phiên ngày 06/09/2026, số điện thoại đã che)

Bảng 5.6. Tài nguyên AWS theo stack

Bảng 5.7. Thành phần tối thiểu để chạy nguyên mẫu đầu cuối

Bảng 5.8. Đối chiếu quyết định thiết kế và hiện thực

Bảng 6.1. Ma trận đánh giá theo yêu cầu

Bảng 6.2. Môi trường đo hội thoại

Bảng 6.3. Ánh xạ thành phần AWS sang môi trường mô phỏng

Bảng 6.4. Độ trễ phản hồi theo nhánh xử lý (giây, nhật ký 05–06/09/2026, gpt-5.6-luna)

Bảng 6.5. Phân tích điểm nghẽn độ trễ trong một lượt (mili-giây)

Bảng 6.6. Độ trễ phản hồi trên thiết kế hiện hành (luồng xử lý đơn và câu đệm)

Bảng 6.7. Tỷ lệ lỗi từ theo điều kiện âm thanh (một người đọc, một lượt mỗi điều kiện)

Bảng 6.8. Độ chính xác gọi công cụ và tỷ lệ hoàn thành nghiệp vụ (đánh giá thủ công, một người đánh giá, nhật ký 2026-09-05 đến 2026-09-06)

Bảng 6.9. Phân loại lỗi quan sát (n ≈ 39 lượt)

Bảng 6.10. Danh mục kiểm tra hành vi khi lái

Bảng 6.11. Kết quả thử tải trên môi trường mô phỏng

Bảng 6.12. Kết quả tiêm lỗi trên môi trường mô phỏng

Bảng 6.13. Danh mục kiểm tra bảo mật

Bảng 6.14. Kết quả trường hợp kiểm thử phía khách hàng và giám sát vận hành

Bảng 6.15. Tổng hợp kết quả theo yêu cầu

Bảng A.1. Danh mục công cụ gói tiếng Việt (45 công cụ)

Bảng D.1. Cấu hình chính của tác nhân hội thoại

Bảng E.1. Ma trận đối chiếu yêu cầu

Bảng F.1. Đối chiếu các bước sequence với mã nguồn

Bảng G.1. Ánh xạ tên thành phần

Danh mục từ viết tắt

Luận văn chỉ viết tắt các thuật ngữ dùng nhiều lần. Lần xuất hiện đầu trong thân bài vẫn viết đầy đủ kèm chữ viết tắt trong ngoặc đơn. Bảng dưới xếp theo thứ tự ABC.

Từ viết tắt	Tiếng Anh	Tiếng Việt
ADR	Architecture Decision Record	Bản ghi quyết định kiến trúc
AI	Artificial Intelligence	Trí tuệ nhân tạo
API	Application Programming Interface	Giao diện lập trình ứng dụng
AWS	Amazon Web Services	Nền tảng điện toán đám mây của Amazon
CLI	Command-Line Interface	Giao diện dòng lệnh
CON	Constraint	Ràng buộc kiến trúc (mã ở Chương 3)
ECR	Elastic Container Registry	Kho image container của AWS
ECS	Elastic Container Service	Dịch vụ điều phối container của AWS
FaaS	Function as a Service	Hàm như dịch vụ
FAQ	Frequently Asked Questions	Câu hỏi thường gặp
FR	Functional Requirement	Yêu cầu chức năng
HTTP	Hypertext Transfer Protocol	Giao thức truyền siêu văn bản
HTTPS	Hypertext Transfer Protocol Secure	Giao thức HTTP có mã hóa
IAM	Identity and Access Management	Quản lý định danh và quyền truy cập
IIHS	Insurance Institute for Highway Safety	Viện Bảo hiểm An toàn Đường cao tốc (Hoa Kỳ)
JWT	JSON Web Token	Mã thông báo web JSON (xác thực)
LLM	Large Language Model	Mô hình ngôn ngữ lớn
MSA	Microservices Architecture	Kiến trúc microservices
NFR	Non-Functional Requirement	Yêu cầu phi chức năng
NHTSA	National Highway Traffic Safety Administration	Cục An toàn Giao thông Đường cao tốc (Hoa Kỳ)
P50	50th percentile (median)	Trung vị: một nửa số lần đo nhanh hơn hoặc bằng mức này
P90	90th percentile	Mức thời gian mà 90% số lần đo nhanh hơn hoặc bằng
P95	95th percentile	Mức thời gian mà 95% số lần đo nhanh hơn hoặc bằng; chỉ 5% lần chậm nhất vượt mức này

Từ viết tắt	Tiếng Anh	Tiếng Việt
PSTN	Public Switched Telephone Network	Mạng điện thoại công cộng
RAG	Retrieval-Augmented Generation	Sinh câu trả lời có truy xuất tri thức
REST	Representational State Transfer	Kiểu thiết kế API qua HTTP
RQ	Research Question	Câu hỏi nghiên cứu
SAM	Serverless Application Model	Mô hình ứng dụng serverless của AWS (hạ tầng dạng mã)
SDK	Software Development Kit	Bộ công cụ phát triển phần mềm
SIP	Session Initiation Protocol	Giao thức khởi tạo phiên thoại
SMS	Short Message Service	Dịch vụ tin nhắn ngắn
STT	Speech-to-Text	Nhận dạng giọng nói thành chữ
TTFB	Time to First Byte	Thời gian đến khi nhận byte (âm thanh) đầu tiên
TTL	Time to Live	Thời hạn tồn tại của bản ghi hoặc token
TTS	Text-to-Speech	Tổng hợp giọng nói từ chữ
UC	Use Case	Trường hợp sử dụng
URL	Uniform Resource Locator	Địa chỉ tài nguyên trên mạng
UUID	Universally Unique Identifier	Mã định danh duy nhất
VAD	Voice Activity Detection	Phát hiện hoạt động giọng nói
VPC	Virtual Private Cloud	Mạng riêng ảo trên AWS
WebRTC	Web Real-Time Communication	Truyền thông thời gian thực trên web/ứng dụng
WER	Word Error Rate	Tỷ lệ lỗi từ khi nhận dạng giọng nói (so với câu đúng)
WSS	WebSocket Secure	WebSocket có mã hóa

Mục lục

Lời cam đoan 2

Tóm tắt 3

Lời cảm ơn 4

Danh sách hình ảnh 5

Danh sách bảng 7

Danh mục từ viết tắt 10

Mục lục 12

Chương 1. Giới thiệu 18

1.1. Bối cảnh và động lực nghiên cứu 18

1.2. Phát biểu bài toán 19

1.3. Mục tiêu nghiên cứu 20

1.4. Câu hỏi nghiên cứu 21

1.5. Phạm vi và giới hạn nghiên cứu 22

1.5.1. Đối tượng, không gian và thời gian nghiên cứu 22

1.5.2. Phạm vi nghiên cứu 22

1.5.3. Giới hạn 23

1.6. Phương pháp nghiên cứu 23

1.7. Những đóng góp của luận văn 24

1.8. Cấu trúc luận văn 24

Kết luận chương 25

Chương 2. Cơ sở lý thuyết và nghiên cứu liên quan 26

2.1. Kiến trúc chuỗi xử lý của trợ lý giọng nói 26

2.2. Mô hình ngôn ngữ lớn có khả năng gọi công cụ 27

2.3. Truyền thông thời gian thực: WebRTC và SIP 27
2.4. Yêu cầu phi chức năng và mô hình chất lượng phần mềm 28
2.5. Kiến trúc microservices 29
2.6. Điện toán đám mây: serverless và container 30
2.7. An toàn khi lái và cơ sở lựa chọn ngưỡng độ trễ 31
2.8. Nghiên cứu liên quan về AI trong dịch vụ gọi xe 31
2.9. Chỉ số đánh giá 32
2.10. Khoảng trống nghiên cứu và định hướng luận văn 32
Kết luận chương 33
Chương 3. Phân tích yêu cầu 34
3.1. Phương pháp xác định yêu cầu 34
3.2. Đối tượng sử dụng và kênh tương tác 35
3.2.1. Đối tượng sử dụng 35
3.2.2. Thành phần hệ thống 35
3.3. Kịch bản vận hành của phiên trợ lý 36
3.3.1. Tài xế chủ động mở trợ lý trong ứng dụng 36
3.3.2. Hệ thống chủ động gọi điện mời tài xế nhận chuyến 37
3.3.3. Ba chế độ gọi khách hàng 37
3.4. Yêu cầu chức năng 38
3.4.1. Nhóm nghiệp vụ chuyến đi 38
3.4.2. Nhóm nghiệp vụ liên lạc khách hàng 39
3.4.3. Nhóm nghiệp vụ chờ đón, sự cố, thu nhập, hỗ trợ và ngôn ngữ 39
3.4.4. Nhóm kích hoạt và kết thúc chế độ nói trực tiếp 40
3.4.5. Nhóm giám sát vận hành 41
3.5. Trường hợp sử dụng chính 41

3.6. Yêu cầu phi chức năng 42
3.6.1. Đặc tả yêu cầu phi chức năng 42
3.6.2. Ràng buộc kiến trúc 43
3.7. Từ yêu cầu phi chức năng đến tính chất của kiến trúc microservices 44
3.8. Phạm vi yêu cầu 45
3.9. Tiêu chí chấp nhận 45
Kết luận chương 46
Chương 4. Thiết kế hệ thống 47
4.1. Động lực kiến trúc 47
4.2. Quyết định kiến trúc 48
4.2.1. Lựa chọn kiểu kiến trúc (ADR-01) 48
4.2.2. Lựa chọn luồng xử lý lượt hội thoại (ADR-02) 49
4.3. Kiến trúc tổng thể trên AWS 50
4.4. Phân chia hệ thống thành các dịch vụ 56
4.5. Sequence diagram cho các luồng chính 56
4.5.1. S1 — Đăng nhập (Dịch vụ Định danh) 57
4.5.2. S2 — Khởi tạo phiên trợ lý trong ứng dụng (Dịch vụ Chuyến đi và Điều phối) 59
4.5.3. S3 — Xử lý một lượt hội thoại (Tác nhân hội thoại giọng nói) 61
4.5.4. S4 — Mời nhận chuyến qua cuộc gọi điện thoại (Dịch vụ Chuyến đi và Điều phối) 63
4.5.5. S5 — Gọi khách hàng và gửi tin nhắn (Dịch vụ Chuyến đi và Điều phối, Dịch vụ Kênh liên lạc) 65
4.5.6. S6 — Ghi nhật ký và tóm tắt cuộc gọi (Dịch vụ Nhật ký cuộc gọi) 67
4.5.7. S7 — Lập báo cáo vận hành ngày (Dịch vụ Giám sát vận hành) 68

4.6. Thiết kế xử lý một lượt hội thoại 69
4.6.1. Chuỗi xử lý và câu đệm 69
4.6.2. Trạng thái phiên hội thoại 70
4.6.3. Phân loại phiên và tập công cụ 71
4.7. Thiết kế cho khả năng phục hồi, bảo mật và khả năng quan sát 71
4.8. Thiết kế trải nghiệm trên ứng dụng tài xế 72
4.9. Đối chiếu yêu cầu với thiết kế 73
Kết luận chương 73
Chương 5. Triển khai 74
5.1. Công nghệ sử dụng 74
5.2. Tổ chức mã nguồn 74
5.3. Hiện thực tác nhân hội thoại giọng nói 75
5.3.1. Khởi tạo phiên và phân loại phòng 75
5.3.2. Xử lý lượt hội thoại và câu đệm 76
5.3.3. Gọi API nghiệp vụ 76
5.3.4. Lớp trừu tượng và dự phòng nhà cung cấp AI 77
5.3.5. Xử lý im lặng và kết thúc phiên 77
5.3.6. Chỉ số chất lượng của phiên 78
5.4. Hiện thực các dịch vụ backend 78
5.4.1. Dịch vụ Chuyến đi và Điều phối 78
5.4.2. Dịch vụ Định danh 79
5.4.3. Dịch vụ Kênh liên lạc, Dịch vụ Nhật ký cuộc gọi và Dịch vụ Giám sát vận hành 79
5.5. Hiện thực ứng dụng tài xế 81
5.6. Triển khai trên AWS 88

5.6.1. Hạ tầng dạng mã 88
5.6.2. Môi trường phát triển và thử nghiệm 90
5.7. Đối chiếu thiết kế và hiện thực 90
Kết luận chương 91
Chương 6. Thực nghiệm và đánh giá 92
6.1. Mục tiêu và ma trận đánh giá 92
6.2. Môi trường thực nghiệm 93
6.2.1. Môi trường đo hội thoại 93
6.2.2. Môi trường mô phỏng thử tải và tiêm lỗi 94
6.3. Định nghĩa chỉ số 95
6.4. Kết quả hiệu năng — NFR-02 (RQ2) 95
6.5. Kết quả nhận dạng giọng nói (RQ3) 97
6.6. Kết quả tính đúng chức năng (RQ4) 98
6.7. Kết quả khả năng sử dụng — NFR-01 100
6.8. Kết quả khả năng mở rộng — NFR-03 (RQ1) 100
6.9. Kết quả khả năng phục hồi — NFR-04 (RQ1) 101
6.10. Kết quả bảo mật — NFR-05 102
6.11. Kết quả luồng khách hàng và giám sát vận hành qua trường hợp kiểm thử 102
6.12. Tổng hợp và thảo luận theo câu hỏi nghiên cứu 103
6.13. Hạn chế và yếu tố ảnh hưởng đến độ tin cậy của kết luận 104
Kết luận chương 105
Kết luận và hướng phát triển 106
Tài liệu tham khảo 108
Phụ lục 110

Phụ lục A. Danh mục công cụ của trợ lý giọng nói 110

Phụ lục B. Kịch bản thoại mẫu 112

Kịch bản B.1 — Tra cứu lịch trình và thông tin chuyến (phiên trong ứng dụng, 2026-09-06) 112

Kịch bản B.2 — Nhận chuyến qua cuộc gọi mời nhận chuyến (phiên SIP, tập công cụ hẹp) 113

Phụ lục C. Ảnh màn hình ứng dụng và trang quản trị 113

Phụ lục D. Cấu hình môi trường triển khai 127

Phụ lục E. Ma trận đối chiếu yêu cầu 128

Phụ lục F. Đối chiếu sequence diagram với mã nguồn 131

Phụ lục G. Bảng ánh xạ tên thành phần 133

Chương 1. Giới thiệu

Chương này xác lập bối cảnh, bài toán và định hướng của luận văn: lý do cần một trợ lý giọng nói cho tài xế, những yêu cầu mà hệ thống phải đáp ứng và các tiêu chí dùng để đánh giá. Các mục tiêu và câu hỏi nghiên cứu nêu ở đây là căn cứ tổ chức nội dung các chương sau.

1.1. Bối cảnh và động lực nghiên cứu

Trong những năm gần đây, dịch vụ gọi xe công nghệ ngày càng phổ biến nhờ đáp ứng linh hoạt nhu cầu đi lại. Song song với sự mở rộng đó, tài xế phải thực hiện nhiều nghiệp vụ trong lúc điều khiển phương tiện: xem và xác nhận chuyến, cập nhật trạng thái đón và trả khách, liên lạc với khách hàng, tra cứu thông tin lộ trình. Các thao tác này thường diễn ra trên điện thoại thông minh, buộc tài xế rời mắt khỏi mặt đường và rời một tay khỏi vô-lăng trong khi vẫn phải tập trung vào giao thông.

Nhiều bằng chứng thực nghiệm đã chỉ ra mối liên hệ giữa việc sử dụng điện thoại khi lái xe và nguy cơ mất an toàn. Phân tích trên dữ liệu lái xe tự nhiên quy mô lớn cho thấy các yếu tố liên quan đến người lái (sai sót, suy giảm khả năng, mệt mỏi, xao nhãng) hiện diện trong gần 90% số vụ va chạm được quan sát, và xao nhãng do thao tác thiết bị cầm tay làm tăng đáng kể nguy cơ va chạm (Dingus et al., 2016). Tổng hợp của Insurance Institute for Highway Safety (IIHS) cũng nêu nguy cơ va chạm cao gấp khoảng hai đến sáu lần khi người lái thao tác trên điện thoại so với khi không bị xao nhãng (Insurance Institute for Highway Safety, n.d.). Những số liệu này cho thấy nhu cầu về một phương thức tương tác không dùng tay (hands-free) bằng giọng nói, giúp tài xế giảm thời gian nhìn và chạm màn hình khi lái.

Về điều kiện kỹ thuật, các mô hình trí tuệ nhân tạo (Artificial Intelligence – AI) cho hội thoại hiện đã được cung cấp dưới dạng dịch vụ thương mại: nhận dạng giọng nói (Speech-to-Text – STT), mô hình ngôn ngữ lớn (Large Language Model – LLM) và tổng hợp giọng nói (Text-to-Speech – TTS) có thể ghép thành một chuỗi xử lý thời gian thực. Cơ chế gọi công cụ (function calling) cho phép mô hình ngôn ngữ không chỉ trả lời bằng ngôn ngữ tự nhiên mà còn thực thi nghiệp vụ thông qua giao diện lập trình ứng dụng (Application Programming Interface – API) (Schick et al., 2023). Hạ

tầng truyền thông thời gian thực — WebRTC cho ứng dụng và SIP cho mạng điện thoại — cũng đã sẵn có dưới dạng dịch vụ (LiveKit Inc., n.d.).

Tuy nhiên, một hệ thống ghép từ các thành phần trên để vận hành thực tế phải đáp ứng các yêu cầu chất lượng khắt khe hơn một ứng dụng hỏi đáp thông thường. Trợ lý phải phản hồi đủ nhanh để không gây gián đoạn khi lái, phục vụ đồng thời nhiều phiên hội thoại, tiếp tục hoạt động khi một dịch vụ phụ trợ hoặc một nhà cung cấp AI bên ngoài gặp sự cố, và bảo vệ dữ liệu cá nhân của tài xế và khách hàng. Đây là các yêu cầu phi chức năng (Non-Functional Requirement – NFR) quyết định lựa chọn kiến trúc của hệ thống, và là động lực để luận văn xem xét kiến trúc microservices (Microservices Architecture – MSA) trên nền tảng điện toán đám mây.

Từ nhu cầu thực tiễn và điều kiện kỹ thuật trên, luận văn đặt vấn đề xây dựng và đánh giá một trợ lý giọng nói chuyên cho nghiệp vụ tài xế, trình bày ở mục 1.2.

1.2. Phát biểu bài toán

Bài toán đặt ra là thiết kế, triển khai và đánh giá một hệ thống trợ lý AI bằng giọng nói hỗ trợ tài xế khi đang vận hành chuyến đi. Hệ thống cần nghe yêu cầu của tài xế, hiểu ý định, thực hiện nghiệp vụ tương ứng trên hệ thống quản lý chuyến đi thông qua cơ chế gọi công cụ, rồi trả lời bằng giọng nói trong thời gian thực. Ngôn ngữ chính là tiếng Việt, vì đối tượng phục vụ là tài xế tại Việt Nam. Tiếng Anh được hỗ trợ như ngôn ngữ thứ hai cho cùng tập nghiệp vụ, phục vụ tài xế hoặc khách hàng không dùng tiếng Việt và để kiểm chứng rằng kiến trúc cho phép bổ sung ngôn ngữ mà không phải sửa luồng xử lý.

Cụ thể, trợ lý cần hỗ trợ ba nhóm nghiệp vụ:

- **Tra cứu và quản lý chuyến đi:** xem lịch trình, cập nhật trạng thái, hủy chuyến khi đủ điều kiện.
- **Liên lạc với khách hàng:** gọi điện và gửi tin nhắn cho khách thông qua dịch vụ phía máy chủ (backend).
- **Hỗ trợ trong lúc vận hành:** nhắc trước giờ đón, trả lời câu hỏi thường gặp về cách dùng ứng dụng.

Hệ thống phải hoạt động trên cả kênh trong ứng dụng (WebRTC) và kênh điện thoại (SIP) khi hệ thống gọi cho tài xế hoặc gọi cho khách hàng.

Bài toán không dừng ở việc duy trì hội thoại mà đòi hỏi hệ thống thực hiện đúng nghiệp vụ, kiểm soát độ trễ mà tài xế cảm nhận, hoạt động trong điều kiện nhiễu của khoang xe, đồng thời đáp ứng các yêu cầu về khả năng mở rộng và khả năng chịu lỗi của một hệ thống phân tán. Các yêu cầu này được cụ thể hóa thành mục tiêu và câu hỏi nghiên cứu ở các mục tiếp theo.

1.3. Mục tiêu nghiên cứu

Mục tiêu tổng quát của luận văn là xây dựng một giải pháp trợ lý AI bằng giọng nói giúp giảm thao tác thủ công trên thiết bị di động của tài xế xe công nghệ, đồng thời chứng minh tính khả thi kỹ thuật của giải pháp thông qua triển khai nguyên mẫu và đánh giá theo các chỉ số đo được.

Các mục tiêu cụ thể gồm:

1. Phân tích yêu cầu chức năng (Functional Requirement – FR) và yêu cầu phi chức năng cho trợ lý giọng nói dành cho tài xế; phân loại yêu cầu phi chức năng theo mô hình chất lượng chuẩn và đặc tả dưới dạng đo được.
2. Đề xuất kiến trúc hệ thống theo mô hình microservices, lập luận lựa chọn kiến trúc từ các yêu cầu phi chức năng; tách tác nhân hội thoại khỏi các dịch vụ nghiệp vụ, cho phép thay thế và dự phòng nhà cung cấp STT, LLM, TTS, và phân loại phiên hội thoại để giới hạn tập nghiệp vụ được phép thực hiện.
3. Triển khai hệ thống nguyên mẫu trên nền tảng truyền thông thời gian thực (WebRTC và SIP), ứng dụng di động của tài xế và các dịch vụ backend, với cấu hình hạ tầng dạng mã cho Amazon Web Services (AWS).
4. Đánh giá hệ thống theo từng yêu cầu đã đặc tả: độ trễ phản hồi, độ chính xác nhận dạng giọng nói, độ chính xác gọi công cụ và tỷ lệ hoàn thành nghiệp vụ, khả năng mở rộng và khả năng chịu lỗi.

Đối với mục tiêu 4, luận văn đặt trước các ngưỡng định hướng sau; đây là mốc kỳ vọng khi đánh giá, chưa phải kết quả đo (phương pháp đo trình bày ở Chương 6):

- **Độ trễ phản hồi:** khoảng thời gian từ khi tài xế kết thúc phát ngôn đến khi hệ thống bắt đầu phát âm thanh trả lời. Thay vì dùng giá trị trung bình, vốn che mất những lần phản hồi chậm, luận văn dùng chỉ số P95: sắp xếp mọi lần đo từ nhanh đến chậm, P95 là thời gian mà 95% số lần phản hồi nhanh hơn hoặc bằng. Ví dụ, P95 = 2 giây nghĩa là cứ 100 lượt hỏi thì tối đa 5 lượt phải chờ lâu hơn 2 giây. Ngưỡng định hướng là P95 ≤ 2 giây trên các luồng nghiệp vụ cốt lõi. Cơ sở lựa chọn ngưỡng trình bày ở Chương 2.
- **Tỷ lệ lỗi từ** (Word Error Rate – WER): tỷ lệ từ bị thay thế, bị xóa hoặc bị chèn so với câu tham chiếu. Luận văn không đặt ngưỡng tuyệt đối mà so sánh tương đối giữa điều kiện yên tĩnh và điều kiện nhiễu mô phỏng khoang xe.
- **Độ chính xác gọi công cụ và tỷ lệ hoàn thành nghiệp vụ:** báo cáo theo nhóm kịch bản.
- **Khả năng mở rộng và khả năng chịu lỗi:** đánh giá bằng thử nghiệm tải và tiêm lỗi trên môi trường mô phỏng; ngưỡng cụ thể được nêu cùng yêu cầu phi chức năng ở Chương 3.

1.4. Câu hỏi nghiên cứu

Luận văn định hướng trả lời các câu hỏi nghiên cứu (Research Question – RQ) sau:

- **RQ1.** Kiến trúc microservices, được lựa chọn từ các yêu cầu phi chức năng, có đáp ứng được yêu cầu về khả năng mở rộng và khả năng chịu lỗi của một trợ lý giọng nói thời gian thực thực thi nghiệp vụ qua gọi công cụ hay không?
- **RQ2.** Với các luồng nghiệp vụ cốt lõi (tra cứu chuyến, nhận hoặc từ chối chuyến, liên lạc khách hàng), độ trễ phản hồi đạt mức nào, và P95 có duy trì được ở mức không quá 2 giây hay không?
- **RQ3.** Tỷ lệ lỗi từ của khâu nhận dạng giọng nói thay đổi như thế nào giữa môi trường yên tĩnh và môi trường có nhiễu nền mô phỏng khoang xe?
- **RQ4.** Trên bộ kịch bản nghiệp vụ đã thiết kế, tỷ lệ chọn đúng công cụ và hoàn thành đúng nghiệp vụ đạt mức nào, và những lỗi phổ biến nào ảnh hưởng đến trải nghiệm không dùng tay của tài xế?

Mối liên hệ giữa mục tiêu cụ thể, câu hỏi nghiên cứu và chương trả lời được tóm tắt trong Bảng 1.1.

Bảng 1.1. Ánh xạ mục tiêu nghiên cứu, câu hỏi nghiên cứu và chương trả lời

STT	Mục tiêu cụ thể	Câu hỏi nghiên cứu	Tiêu chí / chỉ số định hướng	Chương
1	Phân tích yêu cầu	Cơ sở cho RQ1–RQ4	FR có điều kiện chấp nhận; NFR phân loại theo ISO/IEC 25010, đặc tả đo được	Chương 3
2	Đề xuất kiến trúc	RQ1	Lập luận chọn microservices từ NFR; kiến trúc trên AWS; sequence cho từng dịch vụ	Chương 4
3	Triển khai nguyên mẫu	RQ1	Dịch vụ backend, tác nhân hội thoại, ứng dụng tài xế, hạ tầng dạng mã	Chương 5
4	Đánh giá theo yêu cầu	RQ1–RQ4	Khả năng mở rộng, khả năng chịu lỗi (RQ1); P95 ≤ 2 giây (RQ2); WER (RQ3); độ đúng gọi công cụ, hoàn thành nghiệp vụ (RQ4)	Chương 6

1.5. Phạm vi và giới hạn nghiên cứu

1.5.1. Đối tượng, không gian và thời gian nghiên cứu

- **Đối tượng nghiên cứu:** trợ lý AI bằng giọng nói dành cho tài xế xe công nghệ và kiến trúc hệ thống phục vụ trợ lý; đối tượng sử dụng chính là tài xế, ngôn ngữ ưu tiên là tiếng Việt.
- **Không gian nghiên cứu:** hệ thống nguyên mẫu trên môi trường phát triển và thử nghiệm (LiveKit Cloud, các dịch vụ backend, ứng dụng di động, cấu hình triển khai AWS), không phải mạng lưới vận hành thương mại quy mô lớn.
- **Thời gian nghiên cứu:** giai đoạn thiết kế, triển khai và đánh giá trong quá trình thực hiện luận văn (2025–2026); số liệu thực nghiệm phản ánh cấu hình hệ thống tại thời điểm đo, được ghi rõ ở Chương 6.

1.5.2. Phạm vi nghiên cứu

Luận văn tập trung vào trợ lý giọng nói và kiến trúc tích hợp trợ lý với nền tảng vận hành chuyến đi, không nhằm xây dựng một hệ thống quản lý vận tải hoàn chỉnh (điều phối tối ưu toàn mạng, định giá cước, thanh toán, bảo hiểm). Ứng dụng di động, dịch vụ định danh và dịch vụ quản lý chuyến đi được xem là nền tảng tích hợp cần

thiết để trợ lý thực thi nghiệp vụ thật, và được trình bày ở mức đủ để làm rõ cách các thành phần phối hợp.

Về chức năng, luận văn bao gồm: tương tác bằng giọng nói tiếng Việt và tiếng Anh; quản lý chuyến đi bằng giọng nói; liên lạc và xác nhận với khách hàng; nhắc lịch và trả lời câu hỏi thường gặp có truy xuất tri thức; kích hoạt trợ lý bằng từ khóa đánh thức (wake-word) trên ứng dụng tài xế. Hệ thống hoạt động trên kênh WebRTC trong ứng dụng và kênh SIP khi cần kết nối mạng điện thoại công cộng (Public Switched Telephone Network – PSTN). Các dịch vụ cấu thành hệ thống được đặt tên theo chức năng (Dịch vụ Định danh, Dịch vụ Chuyến đi và Điều phối, Dịch vụ Kênh liên lạc, Dịch vụ Nhật ký cuộc gọi, Dịch vụ Giám sát vận hành và Tác nhân hội thoại giọng nói); bảng đối chiếu tên chức năng với tên kỹ thuật trong mã nguồn đặt ở Phụ lục G.

1.5.3. Giới hạn

- **Mô hình AI:** luận văn không huấn luyện lại các mô hình STT, LLM, TTS mà dùng mô hình có sẵn của nhà cung cấp, thông qua một lớp trung gian để có thể thay nhà cung cấp khi cần.
- **Chức năng:** không bao gồm nhắn tin nhóm giữa các tài xế, dẫn đường từng ngã rẽ (đã có ứng dụng bản đồ chuyên dụng), xử lý tranh chấp thanh toán và khiếu nại pháp lý.
- **Môi trường thử nghiệm:** khả năng mở rộng và khả năng chịu lỗi được thử trên môi trường mô phỏng cục bộ, không trên hạ tầng AWS thật; số tài xế thật tham gia thử nghiệm còn ít.

Ảnh hưởng của các giới hạn này đến độ tin cậy của kết luận được thảo luận ở Chương 6.

1.6. Phương pháp nghiên cứu

Luận văn theo tiếp cận nghiên cứu khoa học thiết kế (design science research) với chu trình thiết kế – xây dựng – đánh giá. Bốn mục tiêu ở mục 1.3 tương ứng bốn giai đoạn: phân tích yêu cầu (Chương 3), thiết kế kiến trúc (Chương 4), triển khai nguyên mẫu (Chương 5) và đánh giá thực nghiệm (Chương 6). Mỗi yêu cầu được gán

mã định danh và được đối chiếu qua quyết định thiết kế, thành phần hiện thực và kịch bản đánh giá (ma trận đối chiếu yêu cầu ở Phụ lục E). Việc đánh giá kết hợp bốn cách:

- Đo độ trễ và phân tích nhật ký của các phiên hội thoại thật.
- Đo tỷ lệ lỗi từ trên bộ câu tham chiếu.
- Chấm độ đúng gọi công cụ trên bộ kịch bản có kiểm soát.
- Thử tải và cố ý gây lỗi (fault injection) trên môi trường mô phỏng để kiểm chứng khả năng mở rộng và khả năng chịu lỗi.

1.7. Những đóng góp của luận văn

Luận văn hướng tới ba đóng góp chính:

1. **Xác định khoảng trống nghiên cứu:** thiếu một trợ lý giọng nói vừa hội thoại thời gian thực, vừa thực thi nghiệp vụ vận tải qua gọi công cụ, vừa được đánh giá theo tiêu chí của tài xế (Chương 2).
2. **Đề xuất và hiện thực một kiến trúc microservices có lập luận từ yêu cầu phi chức năng:** tác nhân hội thoại tách khỏi các dịch vụ nghiệp vụ, chuỗi xử lý STT – LLM kèm gọi công cụ – TTS có câu đệm và cơ chế dự phòng nhà cung cấp, phân loại phiên hội thoại theo ngữ cảnh, triển khai trên AWS (Chương 3–5).
3. **Xây dựng bộ kịch bản và khung đánh giá theo từng yêu cầu** (độ trễ, tỷ lệ lỗi từ, gọi công cụ, hoàn thành nghiệp vụ, khả năng mở rộng, khả năng chịu lỗi) cùng ma trận đối chiếu từ yêu cầu đến kết quả (Chương 6).

1.8. Cấu trúc luận văn

Ngoài chương này, luận văn gồm:

- **Chương 2:** cơ sở lý thuyết về trợ lý giọng nói, mô hình chất lượng phần mềm, kiến trúc microservices, điện toán đám mây và khoảng trống nghiên cứu.
- **Chương 3:** phân tích yêu cầu chức năng và phi chức năng.
- **Chương 4:** quyết định kiến trúc và thiết kế hệ thống.
- **Chương 5:** triển khai nguyên mẫu.
- **Chương 6:** thực nghiệm và đánh giá.

– **Kết luận:** đóng góp, hạn chế và hướng phát triển.

Các nội dung bổ trợ (danh mục công cụ, kịch bản hội thoại mẫu, ảnh màn hình, cấu hình môi trường, ma trận đối chiếu yêu cầu, bảng kiểm sequence và bảng ánh xạ tên thành phần) đặt ở Phụ lục.

Kết luận chương

Chương 1 đã xác lập bối cảnh, bài toán, bốn mục tiêu và bốn câu hỏi nghiên cứu cùng các ngưỡng đánh giá định hướng. Trọng tâm nghiên cứu là trợ lý AI bằng giọng nói cho tài xế xe công nghệ và kiến trúc hệ thống đáp ứng các yêu cầu phi chức năng của trợ lý. Chương 2 trình bày cơ sở lý thuyết làm nền cho việc phân tích yêu cầu và lựa chọn kiến trúc.

Chương 2. Cơ sở lý thuyết và nghiên cứu liên quan

Chương này trình bày các khái niệm làm nền cho phân tích yêu cầu và lựa chọn kiến trúc ở các chương sau, gồm hai nhóm. Nhóm thứ nhất liên quan đến trợ lý giọng nói: chuỗi xử lý STT – LLM – TTS, cơ chế gọi công cụ và truyền thông thời gian thực. Nhóm thứ hai thuộc kỹ nghệ phần mềm: mô hình chất lượng sản phẩm, kiến trúc microservices và các mô hình điện toán đám mây. Cuối chương đối chiếu với các nghiên cứu liên quan và xác định khoảng trống mà luận văn hướng tới.

2.1. Kiến trúc chuỗi xử lý của trợ lý giọng nói

Trợ lý giọng nói trong luận văn xử lý một lượt hội thoại qua ba khâu nối tiếp:

1. **Nhận dạng giọng nói** (Speech-to-Text – STT): chuyển tín hiệu âm thanh thu từ micro thành văn bản.
2. **Hiểu và ra quyết định** bằng mô hình ngôn ngữ lớn (Large Language Model – LLM): từ văn bản, mô hình sinh câu trả lời hoặc chọn một hành động nghiệp vụ.
3. **Tổng hợp giọng nói** (Text-to-Speech – TTS): chuyển câu trả lời thành âm thanh phát ra loa.

Cách tổ chức này được gọi là chuỗi xử lý theo tầng (cascaded pipeline). Ưu điểm của chuỗi theo tầng là từng khâu có thể được thay thế độc lập (đổi nhà cung cấp STT, LLM hoặc TTS) mà không phải xây dựng lại toàn bộ hệ thống. Nhược điểm là độ trễ của các khâu cộng dồn: thời gian chờ nhận dạng xong phát ngôn, thời gian mô hình ngôn ngữ sinh token đầu tiên (time to first token) và thời gian tổng hợp đoạn âm thanh đầu tiên. Khi tổng độ trễ lớn, người dùng cảm nhận trợ lý phản hồi chậm.

Các bộ đánh giá trợ lý giọng nói dựa trên LLM nhấn mạnh việc kiểm thử trong điều kiện gần thực tế (nhiễu nền, cách nói khác nhau), không chỉ trên dữ liệu sạch (Chen et al., 2024). Với tài xế, có thêm hai ràng buộc: nhiễu của khoang xe (động cơ, gió, mặt đường), và yêu cầu mọi câu trả lời phải khớp với dữ liệu nghiệp vụ thật, không được sinh thông tin không có nguồn (hallucination) để câu trả lời nghe trôi chảy.

2.2. Mô hình ngôn ngữ lớn có khả năng gọi công cụ

Trợ lý hội thoại thông thường chỉ sinh câu trả lời. Trợ lý cho tài xế còn phải thực hiện thao tác thay người dùng: nhận chuyến, cập nhật trạng thái đón và trả khách, gọi cho khách hàng, trả lời câu hỏi về cách sử dụng ứng dụng. Cơ chế gọi công cụ (function calling) cho phép mô hình chọn một công cụ đã được định nghĩa sẵn kèm lược đồ tham số, điền tham số, sau đó hệ thống thực thi công cụ đó thông qua giao diện lập trình ứng dụng (Application Programming Interface – API) của dịch vụ phía máy chủ (Schick et al., 2023).

Khi áp dụng cho nghiệp vụ tài xế, khó khăn không nằm ở việc định nghĩa danh sách công cụ mà ở ba điểm:

- **Công cụ gần nghĩa:** ví dụ "hủy chuyến đang chạy" và "từ chối chuyến mới" dễ bị mô hình chọn nhầm.
- **Thao tác khó hoàn tác:** hủy chuyến hay gọi một số điện thoại ngoài chuyến cần tài xế xác nhận trước khi thực hiện.
- **Câu trả lời bằng giọng nói:** phải ngắn, vì tài xế không thể đọc lại như trên màn hình.

Vì vậy, chất lượng của trợ lý phụ thuộc vào cách mô tả công cụ, cơ chế xác nhận hai bước và việc đo độ chính xác chọn công cụ trên kịch bản nghiệp vụ thực tế.

2.3. Truyền thông thời gian thực: WebRTC và SIP

Để tài xế hội thoại với trợ lý ngay trên điện thoại, âm thanh cần được truyền với độ trễ thấp. WebRTC là bộ giao thức chuẩn cho thoại và video thời gian thực trên trình duyệt và ứng dụng (Alvestrand, 2021). Trong luận văn, kênh chính của ứng dụng tài xế sử dụng WebRTC: tài xế mở trợ lý (bằng nút bấm hoặc từ khóa đánh thức) và tham gia một phòng hội thoại (room) cùng tác nhân hội thoại (conversational agent).

Khi cần kết nối mạng điện thoại công cộng (Public Switched Telephone Network – PSTN), chẳng hạn khi hệ thống gọi điện mời tài xế nhận chuyến hoặc gọi cho khách hàng, hệ thống sử dụng giao thức khởi tạo phiên (Session Initiation Protocol – SIP) qua cầu nối với nhà cung cấp dịch vụ thoại. Điểm quan trọng về thiết

kế là cùng một logic nghiệp vụ (nhận hoặc từ chối chuyến, gọi khách) được tái sử dụng trên cả hai kênh thay vì xây dựng hai trợ lý tách biệt. Các nền tảng như LiveKit Agents cung cấp khung để xây dựng tác nhân tham gia phòng hội thoại thời gian thực và tích hợp STT, LLM, TTS (LiveKit Inc., n.d.); luận văn kế thừa tầng truyền thông này.

2.4. Yêu cầu phi chức năng và mô hình chất lượng phần mềm

Yêu cầu chức năng (Functional Requirement – FR) mô tả hệ thống phải làm gì; yêu cầu phi chức năng (Non-Functional Requirement – NFR) mô tả hệ thống phải làm điều đó tốt đến mức nào. Để phân loại NFR một cách thống nhất, luận văn sử dụng mô hình chất lượng sản phẩm của tiêu chuẩn ISO/IEC 25010:2023. Mô hình này gồm chín đặc tính chất lượng: tính phù hợp chức năng (functional suitability), hiệu năng (performance efficiency), tính tương thích (compatibility), khả năng tương tác (interaction capability), độ tin cậy (reliability), bảo mật (security), khả năng bảo trì (maintainability), tính linh hoạt (flexibility) và tính an toàn (safety) (ISO/IEC, 2023). So với phiên bản 2011, bản 2023 đổi "usability" thành "interaction capability", đổi "portability" thành "flexibility" và bổ sung khả năng mở rộng (scalability) làm đặc tính con của tính linh hoạt, đồng thời bổ sung đặc tính an toàn.

Luận văn dùng thuật ngữ khả năng phục hồi (resilience) theo nghĩa tổng hợp ba đặc tính con của độ tin cậy trong ISO/IEC 25010: tính sẵn sàng (availability), khả năng chịu lỗi (fault tolerance) và khả năng khôi phục (recoverability). Thuật ngữ khả năng sử dụng (usability) được dùng tương đương với "interaction capability".

Một đặc tính chất lượng chỉ có ý nghĩa kiểm chứng khi được đặc tả dưới dạng đo được. Bass, Clements và Kazman đề xuất mô tả mỗi yêu cầu chất lượng bằng một kịch bản thuộc tính chất lượng (quality attribute scenario) gồm sáu phần: nguồn kích thích, kích thích, môi trường, thành phần chịu tác động, phản ứng và thước đo phản ứng (Bass et al., 2021). Ví dụ, "khi tài xế kết thúc phát ngôn (kích thích) trong phiên hội thoại bình thường (môi trường), hệ thống bắt đầu phát âm thanh trả lời (phản ứng) với P95 không quá 2 giây (thước đo)". Chương 3 áp dụng cách đặc tả này cho từng NFR, và các NFR đó là động lực kiến trúc (architectural drivers) cho quyết định thiết kế ở Chương 4.

2.5. Kiến trúc microservices

Kiến trúc microservices (Microservices Architecture – MSA) tổ chức một ứng dụng thành tập hợp các dịch vụ nhỏ, mỗi dịch vụ chạy trong tiến trình riêng, giao tiếp qua cơ chế nhẹ như HTTP, được xây dựng quanh một năng lực nghiệp vụ và có thể triển khai độc lập (Lewis & Fowler, 2014). Ở góc độ học thuật, microservice được định nghĩa là một tiến trình gắn kết, độc lập, tương tác với các thành phần khác thông qua thông điệp (Dragoni et al., 2017).

Bảng 2.1 tóm tắt các tính chất cơ bản của kiến trúc microservices được dùng làm căn cứ đối chiếu với NFR ở Chương 3.

Bảng 2.1. Các tính chất cơ bản của kiến trúc microservices

Tính chất	Nội dung	Thuộc tính chất lượng được hỗ trợ
Tổ chức theo năng lực nghiệp vụ (organized around business capabilities)	Mỗi dịch vụ sở hữu trọn vẹn một năng lực nghiệp vụ và ranh giới rõ	Khả năng bảo trì
Triển khai độc lập (independent deployability)	Thay đổi một dịch vụ không yêu cầu triển khai lại dịch vụ khác	Khả năng bảo trì, tính sẵn sàng
Quản lý dữ liệu phi tập trung (decentralized data management)	Mỗi dịch vụ sở hữu cơ sở dữ liệu riêng; dịch vụ khác truy cập qua API	Khả năng bảo trì, khả năng chịu lỗi
Thiết kế cho lỗi (design for failure)	Giả định dịch vụ phụ thuộc có thể lỗi; dùng thời gian chờ, suy giảm có kiểm soát, dự phòng	Khả năng phục hồi
Mở rộng độc lập (independent scalability)	Mỗi dịch vụ được mở rộng theo nhu cầu tải của riêng nó	Khả năng mở rộng, hiệu năng
Dị biệt công nghệ (technology heterogeneity)	Mỗi dịch vụ chọn ngôn ngữ và nền tảng phù hợp với tác vụ	Hiệu năng
Tự động hóa hạ tầng (infrastructure automation)	Triển khai và cấu hình hạ tầng dạng mã, tự động	Khả năng bảo trì

Nguồn: tổng hợp từ Lewis và Fowler (2014), Newman (2021), Richardson (2018).

Newman nhấn mạnh rằng ranh giới dịch vụ nên được vẽ theo miền nghiệp vụ và mỗi dịch vụ ẩn giấu dữ liệu của mình để thay đổi được độc lập (Newman, 2021). Richardson hệ thống hóa các mẫu thiết kế tương ứng như mỗi dịch vụ một cơ sở dữ

liệu (database per service) và cổng API (API gateway), đồng thời mô tả ba trục mở rộng của "scale cube": trục X nhân bản dịch vụ, trục Y tách theo chức năng và trục Z phân mảnh dữ liệu (Richardson, 2018).

Microservices cũng có chi phí đáng kể. Tổng quan tài liệu thực tiễn công nghiệp cho thấy các khó khăn chính gồm độ phức tạp vận hành của hệ thống phân tán, khó kiểm thử và giám sát xuyên dịch vụ, và khó bảo đảm nhất quán dữ liệu (Soldani et al., 2018). Do đó, lựa chọn microservices cần được lập luận từ yêu cầu cụ thể của hệ thống chứ không phải mặc định; Chương 4 trình bày lập luận này dưới dạng bản ghi quyết định kiến trúc (Architecture Decision Record – ADR).

2.6. Điện toán đám mây: serverless và container

Điện toán không máy chủ (serverless computing) chuyển gần như toàn bộ công việc quản trị hệ thống cho nhà cung cấp đám mây: nhà phát triển chỉ cung cấp hàm, nền tảng tự động cấp phát, mở rộng theo số yêu cầu và tính phí theo mức sử dụng (Jonas et al., 2019). Mô hình hàm như dịch vụ (Function as a Service – FaaS), điển hình là AWS Lambda, phù hợp với các API giao dịch ngắn, phi trạng thái. Tuy nhiên, FaaS có giới hạn về thời gian thực thi, khởi động nguội (cold start) và không phù hợp với tác vụ cần duy trì kết nối dài như một tác nhân hội thoại giữ kết nối âm thanh liên tục (Jonas et al., 2019).

Với tác vụ chạy dài hạn, container được quản lý (ví dụ Amazon ECS trên AWS Fargate) là lựa chọn thay thế: nhà phát triển đóng gói ứng dụng thành image, nền tảng đảm nhận hạ tầng máy chủ, số bản sao tác vụ được điều chỉnh để mở rộng theo chiều ngang. Ở tầng dữ liệu, luận văn dùng Amazon DynamoDB, một cơ sở dữ liệu NoSQL do AWS quản lý, ở chế độ tính phí theo số yêu cầu; hàm Lambda truy cập DynamoDB qua API HTTP nên không phải duy trì kết nối cơ sở dữ liệu giữa các lần gọi.

Khung AWS Well-Architected Framework hệ thống hóa các nguyên tắc thiết kế trên AWS thành sáu trụ cột: vận hành xuất sắc, bảo mật, độ tin cậy, hiệu quả hiệu năng, tối ưu chi phí và tính bền vững (Amazon Web Services, 2024). Hai trụ cột độ tin cậy và hiệu quả hiệu năng tương ứng trực tiếp với các yêu cầu khả năng phục hồi, khả năng mở rộng và hiệu năng của luận văn.

2.7. An toàn khi lái và cơ sở lựa chọn ngưỡng độ trễ

Thao tác điện thoại khi lái gắn với nguy cơ xao nhãng. Như đã dẫn ở mục 1.1, các yếu tố liên quan đến người lái hiện diện trong phần lớn vụ va chạm, và xao nhãng do thiết bị cầm tay làm tăng nguy cơ va chạm (Dingus et al., 2016). Hướng dẫn về xao nhãng do thiết bị điện tử trên xe của Cục An toàn Giao thông Đường cao tốc Hoa Kỳ (NHTSA) đặt tiêu chí chấp nhận cho các tác vụ thao tác nhìn–tay: thời lượng trung bình mỗi lần rời mắt khỏi mặt đường không vượt quá 2,0 giây và không quá 15% số lần rời mắt dài hơn 2,0 giây (National Highway Traffic Safety Administration, 2013). Tiêu chí này cho thấy mỗi thao tác cần nhìn màn hình phải rất ngắn; tương tác bằng giọng nói giúp loại bỏ phần lớn các lần rời mắt đó.

Luận văn không xây dựng trên các nền tảng hiển thị trên xe như Android Auto hay Apple CarPlay, vì trợ lý cần gắn trực tiếp với dữ liệu và nghiệp vụ riêng của hệ thống chuyến đi (nhận chuyến, gọi đúng khách của chuyến, báo khách không có mặt). Phạm vi được giới hạn ở trợ lý nghiệp vụ chạy trong ứng dụng tài xế và qua cuộc gọi điện thoại.

Về độ trễ, nghiên cứu liên ngôn ngữ trên mười ngôn ngữ cho thấy khoảng lặng chuyển lượt trong hội thoại tự nhiên có giá trị phổ biến nhất trong khoảng 0 đến 200 mili-giây (Stivers et al., 2009). Một chuỗi xử lý STT – LLM – TTS qua mạng khó đạt mức này. Luận văn chọn ngưỡng P95 $\leq$ 2 giây như một ràng buộc kỹ thuật thực dụng cho bối cảnh vừa lái vừa nói, kết hợp với câu đệm (filler utterance) ngắn khi phản hồi chậm để người dùng biết hệ thống vẫn đang xử lý. Ngưỡng này là lựa chọn thiết kế của luận văn, không phải giá trị được rút ra trực tiếp từ các tài liệu trên.

2.8. Nghiên cứu liên quan về AI trong dịch vụ gọi xe

Một hướng nghiên cứu AI cho dịch vụ gọi xe tập trung vào phía nền tảng: phân phối đơn, điều phối xe và tái định vị tài xế, trong đó mô hình ngôn ngữ đóng vai trò tác nhân ra quyết định (Lyu et al., 2025). Hướng này quan trọng cho vận hành mạng lưới nhưng không giải quyết nhu cầu của tài xế đang lái cần tra lịch, gọi khách và cập nhật trạng thái mà không nhìn màn hình.

Ở phía trải nghiệm người dùng, có công trình sử dụng chatbot giọng nói để tăng cảm giác an toàn cho hành khách trong chuyến đi (Alvarado Contreras et al., 2024). Đối tượng và bài toán của công trình này khác với tập nghiệp vụ của tài xế.

2.9. Chỉ số đánh giá

Một trợ lý có thể nhận dạng chính xác nhưng vẫn không hoàn thành nghiệp vụ nếu chọn sai công cụ, phản hồi chậm, hoặc ngừng hoạt động khi một thành phần gặp sự cố. Các khung đánh giá trợ lý giọng nói dựa trên LLM khuyến nghị dùng nhiều chỉ số bổ sung nhau thay vì một điểm số tổng (Chen et al., 2024). Bảng 2.2 liệt kê các chỉ số được luận văn sử dụng; định nghĩa vận hành và phương pháp đo trình bày ở Chương 6.

Bảng 2.2. Các chỉ số đánh giá và câu hỏi nghiên cứu tương ứng

STT	Chỉ số	Ý nghĩa	Câu hỏi nghiên cứu
1	Độ trễ phản hồi (P50, P95)	Thời gian từ khi tài xế kết thúc phát ngôn đến khi hệ thống bắt đầu phát âm thanh trả lời	RQ2
2	Tỷ lệ lỗi từ (WER)	WER = (S + D + I) / N, với S, D, I là số từ bị thay thế, bị xóa, bị chèn; N là số từ của câu tham chiếu	RQ3
3	Độ chính xác gọi công cụ	Tỷ lệ lượt chọn đúng công cụ và đúng tham số	RQ4
4	Tỷ lệ hoàn thành nghiệp vụ	Tỷ lệ kịch bản đạt trạng thái nghiệp vụ mong đợi	RQ4
5	Chỉ số khả năng mở rộng	Biến thiên P95 và tỷ lệ lỗi khi tăng số phiên đồng thời và số bản sao tác nhân	RQ1
6	Chỉ số khả năng phục hồi	Tỷ lệ phiên duy trì khi tiêm lỗi; thời gian khôi phục	RQ1

2.10. Khoảng trống nghiên cứu và định hướng luận văn

Từ các nội dung trên, luận văn xác định ba khoảng trống gắn trực tiếp với đề tài:

1. Thiếu một giải pháp tích hợp đồng thời hội thoại thời gian thực, mô hình ngôn ngữ có gọi công cụ, nghiệp vụ của tài xế gọi xe và mục tiêu giảm thao tác khi lái.

2. Các nghiên cứu AI trong dịch vụ gọi xe nghiêng về tối ưu phía nền tảng hoặc trải nghiệm hành khách, chưa tập trung vào trợ lý thực thi nghiệp vụ cho tài xế.
3. Các công trình về trợ lý giọng nói ít trình bày lập luận kiến trúc từ yêu cầu phi chức năng và ít đánh giá các thuộc tính chất lượng của hệ thống phân tán (khả năng mở rộng, khả năng phục hồi) bên cạnh các chỉ số hội thoại.

Luận văn hướng tới lấp các khoảng trống này bằng cách phân tích yêu cầu theo mô hình chất lượng chuẩn, lập luận lựa chọn kiến trúc microservices trên AWS, triển khai nguyên mẫu và đánh giá theo từng yêu cầu.

Kết luận chương

Chương 2 đã trình bày chuỗi xử lý STT – LLM – TTS, cơ chế gọi công cụ, truyền thông thời gian thực, mô hình chất lượng ISO/IEC 25010 cùng cách đặc tả kịch bản thuộc tính chất lượng, các tính chất của kiến trúc microservices, các mô hình điện toán đám mây, cơ sở chọn ngưỡng độ trễ và bộ chỉ số đánh giá. Chương 3 vận dụng các khái niệm này để phân tích yêu cầu của hệ thống.

Chương 3. Phân tích yêu cầu

Chương này xác định hệ thống phải làm gì (yêu cầu chức năng) và phải làm tốt đến mức nào (yêu cầu phi chức năng). Yêu cầu chức năng được gắn với thành phần phụ trách và điều kiện chấp nhận quan sát được; yêu cầu phi chức năng được phân loại theo mô hình chất lượng ISO/IEC 25010 và đặc tả dưới dạng kịch bản thuộc tính chất lượng (mục 2.4). Cuối chương, các yêu cầu phi chức năng được đối chiếu với tính chất của kiến trúc microservices, làm căn cứ cho quyết định kiến trúc ở Chương 4.

3.1. Phương pháp xác định yêu cầu

Yêu cầu được xác định từ ba nguồn:

- **Nghiệp vụ hằng ngày của tài xế:** các thao tác tài xế thường làm trên ứng dụng khi đang hoặc chuẩn bị lái xe.
- **Tài liệu nội bộ của dự án:** tài liệu yêu cầu và bộ kịch bản hội thoại mẫu.
- **Ràng buộc an toàn khi lái:** các tiêu chí đã phân tích ở mục 2.7.

Các nghiệp vụ thường xuyên của tài xế gồm:

- Xem các chuyến trong ngày và tình trạng chuyến đang thực hiện.
- Nhận hoặc từ chối chuyến mới, đặc biệt khi hệ thống gọi điện mời nhận chuyến.
- Cập nhật tiến độ chuyến: đã đến điểm đón, đã đón khách, hoàn thành.
- Gọi hoặc nhắn tin cho khách khi đến điểm đón, khi khách đến muộn hoặc khi cần xác nhận địa chỉ.
- Hỏi cách sử dụng ứng dụng mà không phải dừng xe đọc hướng dẫn.
- Theo dõi thu nhập trong ngày hoặc trong một khoảng thời gian.
- Mở trợ lý bằng từ khóa đánh thức khi không thể dùng tay, và kết thúc phiên khi xong việc.

Mỗi nghiệp vụ được chuyển thành một hoặc nhiều yêu cầu chức năng có mã định danh. Mã định danh được dùng xuyên suốt các chương sau và trong ma trận đối chiếu yêu cầu (Phụ lục E).

3.2. Đối tượng sử dụng và kênh tương tác

3.2.1. Đối tượng sử dụng

Tài xế là người dùng chính và là đối tượng đánh giá trọng tâm. Tài xế tương tác với trợ lý qua hai kênh: kênh trong ứng dụng (WebRTC) khi chủ động mở trợ lý, và kênh điện thoại (SIP) khi hệ thống gọi điện mời nhận chuyến. Hai kênh khác nhau về trải nghiệm nhưng dùng chung logic nghiệp vụ.

Hành vi của tài xế khi đang lái là cơ sở để xác định yêu cầu:

- Mắt nhìn đường, tay giữ vô-lăng, nên không thể đọc hay chạm màn hình.
- Không muốn nghe danh sách dài hoặc địa chỉ đọc từng ký tự.
- Câu hỏi thường ngắn và gắn với việc đang làm: "còn mấy chuyến", "đến nơi rồi", "gọi khách", "thu nhập hôm nay".
- Thao tác có rủi ro (hủy chuyến, báo khách không có mặt) cần được xác nhận trước khi ghi nhận.

Khách hàng có luồng hội thoại riêng: đặt chuyến, theo dõi chuyến, hỏi thời gian tài xế đến, hoặc nghe cuộc gọi do tác nhân thực hiện thay tài xế. Luận văn không khảo sát trải nghiệm của khách hàng thật; luồng khách hàng được đánh giá qua bộ trường hợp kiểm thử (test case) với tiêu chí đạt hoặc không đạt theo điều kiện nghiệp vụ.

Người điều phối và quản trị viên tạo chuyến thử nghiệm và theo dõi cuộc gọi trên trang quản trị điều hành; người vận hành kỹ thuật giám sát tình trạng hệ thống và xem báo cáo vận hành hằng ngày trên trang giám sát hệ thống. Các đối tượng này không nằm trên luồng xử lý chính của hội thoại nhưng cần thiết để nguyên mẫu vận hành đầy đủ.

3.2.2. Thành phần hệ thống

Hệ thống gồm các thành phần sau; tên tiếng Việt được dùng trong toàn bộ luận văn, tên kỹ thuật tương ứng trong mã nguồn nêu trong ngoặc và tổng hợp ở Phụ lục G. Bảng 3.1 mô tả trách nhiệm và ranh giới của từng thành phần.

Bảng 3.1. Thành phần hệ thống, trách nhiệm và ranh giới

Thành phần	Trách nhiệm	Ranh giới (không thực hiện)
Ứng dụng tài xế (driver-app)	Đăng nhập, xin token thoại, tham gia phòng hội thoại, thu và phát âm thanh, nhận dạng từ khóa đánh thức, hiển thị giao diện	Không tự tạo dữ liệu chuyến; không phát hành JWT
Dịch vụ Định danh (identity-service)	Quản lý tài khoản, đăng nhập, phát hành JWT, lưu cài đặt tài xế	Không ghi dữ liệu chuyến
Dịch vụ Chuyến đi và Điều phối (external-api-service)	Nguồn dữ liệu chuẩn về chuyến đi; cung cấp ngữ cảnh tài xế; cấp token thoại; gửi lời mời nhận chuyến; khởi tạo cuộc gọi thoại qua nền tảng truyền thông thời gian thực (SIP)	Không phát hành JWT đăng nhập; không gửi SMS trực tiếp
Tác nhân hội thoại giọng nói (llm-orchestrator)	Xử lý hội thoại STT – LLM kèm gọi công cụ – TTS; gọi API nghiệp vụ qua HTTP	Không truy cập cơ sở dữ liệu; không lưu dữ liệu nghiệp vụ
Nền tảng truyền thông thời gian thực (LiveKit Cloud)	Truyền âm thanh qua WebRTC; quay số ra mạng điện thoại qua SIP trunk; phân công tác nhân vào phòng	Không chứa logic nghiệp vụ
Dịch vụ Kênh liên lạc (external-channel-service)	Gửi tin nhắn SMS; nhận và lưu sự kiện do nhà cung cấp dịch vụ thoại (Twilio) gửi về (trạng thái cuộc gọi, tin nhắn đến, kết quả gửi SMS)	Không phải nguồn dữ liệu chuyến; không tham gia cuộc gọi thoại qua SIP
Dịch vụ Nhật ký cuộc gọi (call-records-service)	Lưu bản ghi hội thoại, tóm tắt và chỉ số chất lượng của phiên do tác nhân gửi khi kết thúc phiên; cung cấp bản ghi để tra cứu theo người gọi hoặc theo ngày	Không điều khiển nghiệp vụ chuyến
Dịch vụ Giám sát vận hành (ops-service)	Tổng hợp tình trạng các dịch vụ, nhật ký và cấu hình tác nhân; lập và lưu báo cáo vận hành hằng ngày	Không nằm trên luồng xử lý chính của hội thoại; chỉ đọc dữ liệu của dịch vụ khác qua API

3.3. Kịch bản vận hành của phiên trợ lý

3.3.1. Tài xế chủ động mở trợ lý trong ứng dụng

Khi tài xế bấm nút trợ lý hoặc nói từ khóa đánh thức, ứng dụng dùng JWT đã được Dịch vụ Định danh phát hành để xin token thoại từ Dịch vụ Chuyến đi và Điều phối, sau đó tham gia phòng hội thoại trên nền tảng truyền thông thời gian thực; tác nhân hội thoại được phân công vào phòng và kết nối âm thanh. Nếu phòng của phiên trước vẫn còn tác nhân, hệ thống tái sử dụng phòng đó. Tác nhân phát lời chào ngắn

ngay khi vào phòng, đồng thời tải trước ngữ cảnh tài xế (danh sách chuyến, chuyến hiện tại, thu nhập trong ngày, chế độ gọi khách mặc định), sau đó hỏi tài xế cần hỗ trợ gì. Chuỗi bước chi tiết trình bày ở sequence S2 (mục 4.5).

Ngữ cảnh được giữ trong trạng thái phiên để các câu hỏi như "hôm nay còn mấy chuyến?" được trả lời từ dữ liệu đã tải hoặc làm mới qua API, giảm số lần gọi mạng lặp lại. Khi ngữ cảnh trống hoặc API lỗi, tác nhân phải thông báo chưa có dữ liệu thay vì tạo ra thông tin không có nguồn.

Mỗi phát ngôn của tài xế được xử lý theo một luồng duy nhất: STT, LLM kèm gọi công cụ, rồi TTS. Khi phản hồi chưa sẵn sàng sau khoảng hai giây, hệ thống phát một câu đệm ngắn (ví dụ "Đợi mình một chút") không chứa dữ liệu nghiệp vụ.

3.3.2. Hệ thống chủ động gọi điện mời tài xế nhận chuyến

Khi có chuyến mới cần tài xế xác nhận, Dịch vụ Chuyến đi và Điều phối khởi tạo cuộc gọi SIP tới tài xế thông qua nền tảng truyền thông thời gian thực, tạo phòng hội thoại gắn thông tin chuyến. Trong phiên này, tác nhân chỉ được phép thực hiện hai thao tác: nhận chuyến hoặc từ chối chuyến. Lời chào nêu điểm đón và hỏi tài xế có nhận chuyến không. Việc giới hạn tập công cụ phù hợp với thực tế: khi điện thoại đổ chuông, tài xế không nên được đưa vào toàn bộ chức năng như khi chủ động mở trợ lý. Nếu tài xế đang có phiên trợ lý trong ứng dụng, hệ thống gửi thông báo vào phòng hiện có thay vì tạo cuộc gọi mới.

3.3.3. Ba chế độ gọi khách hàng

Khi tài xế yêu cầu gọi khách, hệ thống hỗ trợ ba chế độ tương ứng ba hoàn cảnh sử dụng (Bảng 3.2).

Bảng 3.2. Ba chế độ gọi khách hàng

Chế độ	Hành vi	Hoàn cảnh phù hợp
Tác nhân gọi thay	Tác nhân trao đổi với khách; tài xế nghe và có thể can thiệp	Tài xế muốn tác nhân hỏi thay nhưng vẫn theo dõi
Nói trực tiếp (bridge)	Kết nối để tài xế nói trực tiếp với khách; tác nhân không phát âm chồng lấn	Cần trao đổi nhanh, mang tính cá nhân
Gọi nền	Tác nhân gọi trong phòng riêng; tài xế tiếp tục sử dụng trợ lý cho việc khác	Tài xế đang bận, chỉ cần kết quả sau cuộc gọi

Chế độ mặc định lấy từ cài đặt của tài xế (lưu ở Dịch vụ Định danh và đưa vào ngữ cảnh phiên), trừ khi tài xế nêu rõ chế độ khác trong câu nói. Gọi số điện thoại không thuộc chuyến hiện tại bắt buộc có bước xác nhận trước khi quay số.

3.4. Yêu cầu chức năng

Yêu cầu chức năng được nhóm theo nghiệp vụ. Mỗi yêu cầu nêu hành vi hệ thống phải thực hiện, thành phần phụ trách chính và điều kiện chấp nhận. Điều kiện chấp nhận chung cho mọi yêu cầu: tác nhân không được tạo ra dữ liệu chuyến, thu nhập, vị trí hoặc kết quả cuộc gọi không có nguồn từ API nghiệp vụ. Tập công cụ tiếng Việt hiện thực các yêu cầu này gồm 45 công cụ: 39 công cụ cho phiên tài xế trong ứng dụng, 2 công cụ cho phiên mời nhận chuyến (dùng chung với phiên trong ứng dụng) và 7 công cụ cho phiên khách hàng (1 công cụ hỏi đáp dùng chung); danh mục ở Phụ lục A. Gói tiếng Anh có cùng 39 công cụ cho tài xế; phía khách hàng, gói tiếng Anh hiện có 4 công cụ.

3.4.1. Nhóm nghiệp vụ chuyến đi

Nhóm này gồm các yêu cầu trong vòng đời một chuyến, từ xem lịch, nhận chuyến, cập nhật tiến độ đến hủy chuyến (Bảng 3.3).

Bảng 3.3. Yêu cầu chức năng nhóm chuyến đi (FR-T)

Mã	Yêu cầu	Thành phần phụ trách	Điều kiện chấp nhận
FR-T01	Liệt kê các chuyến sắp tới trong ngày	Tác nhân hội thoại; Dịch vụ Chuyến đi và Điều phối	Số chuyến và thông tin khớp dữ liệu API
FR-T02	Cung cấp thông tin chuyến hiện tại (điểm đón, điểm trả, trạng thái)	Tác nhân hội thoại; Dịch vụ Chuyến đi và Điều phối	Thiếu dữ liệu thì thông báo thiếu
FR-T03	Cập nhật trạng thái chuyến (đã đến, đã đón, hoàn thành)	Dịch vụ Chuyến đi và Điều phối	Chỉ xác nhận bằng lời sau khi API trả về thành công
FR-T04	Nhận hoặc từ chối chuyến mới, cả trong ứng dụng và trong cuộc gọi mời nhận chuyến	Dịch vụ Chuyến đi và Điều phối; nền tảng truyền thông thời gian thực (SIP)	Chọn đúng thao tác nhận/từ chối, không nhầm với hủy chuyến
FR-T05	Hủy chuyến theo hai bước: đề nghị rồi xác nhận	Tác nhân hội thoại; Dịch vụ Chuyến đi và Điều phối	Chỉ hủy sau khi tài xế xác nhận
FR-T06	Tài xế tạo chuyến cho khách vãng lai	Dịch vụ Chuyến đi và Điều phối	Chuyến được tạo với trạng thái đã xác nhận

Mã	Yêu cầu	Thành phần phụ trách	Điều kiện chấp nhận
FR-T07	Gợi ý điểm dừng tiếp theo, lộ trình tối ưu và tình trạng giao thông	Dịch vụ Chuyến đi và Điều phối (dịch vụ bản đồ)	Thông tin lấy từ API bản đồ; không đọc hướng dẫn rẽ từng bước

3.4.2. Nhóm nghiệp vụ liên lạc khách hàng

Nhóm này gồm các yêu cầu gọi điện, nhắn tin và theo dõi kết quả liên lạc với khách hàng (Bảng 3.4).

Bảng 3.4. Yêu cầu chức năng nhóm liên lạc khách hàng (FR-C)

Mã	Yêu cầu	Thành phần phụ trách	Điều kiện chấp nhận
FR-C01	Gọi khách của chuyến theo một trong ba chế độ (Bảng 3.2)	Tác nhân hội thoại; Dịch vụ Chuyến đi và Điều phối; nền tảng truyền thông thời gian thực (SIP)	Gọi đúng khách; áp dụng chế độ mặc định trừ khi tài xế nêu khác
FR-C02	Gọi số điện thoại khác hoặc liên hệ trong danh bạ	Tác nhân hội thoại; Dịch vụ Chuyến đi và Điều phối; nền tảng truyền thông thời gian thực (SIP)	Có bước xác nhận trước khi quay số
FR-C03	Gửi tin nhắn SMS cho khách hoặc số khác	Dịch vụ Chuyến đi và Điều phối; Dịch vụ Kênh liên lạc	Thông báo ngắn kết quả thành công hoặc thất bại
FR-C04	Cung cấp vị trí khách và xác nhận chuyến với khách	Dịch vụ Chuyến đi và Điều phối	Không đưa ra vị trí không có trong dữ liệu
FR-C05	Thông báo trạng thái và tóm tắt cuộc gọi gần nhất	Dịch vụ Chuyến đi và Điều phối; Dịch vụ Nhật ký cuộc gọi	Chưa có dữ liệu thì thông báo chưa có

3.4.3. Nhóm nghiệp vụ chờ đón, sự cố, thu nhập, hỗ trợ và ngôn ngữ

Nhóm này gồm các yêu cầu còn lại của luồng tài xế (Bảng 3.5).

Bảng 3.5. Yêu cầu chức năng nhóm chờ đón, sự cố, thu nhập, hỗ trợ và ngôn ngữ

Mã	Yêu cầu	Thành phần phụ trách	Điều kiện chấp nhận
FR-W01	Tạo nhắc việc và đọc lại thời điểm nhắc	Tác nhân hội thoại	Thời điểm đọc lại khớp yêu cầu
FR-W02	Gia hạn thời gian chờ khách	Dịch vụ Chuyến đi và Điều phối	Gia hạn được ghi nhận qua API

Mã	Yêu cầu	Thành phần phụ trách	Điều kiện chấp nhận
FR-I01	Báo khách không có mặt sau khi xác nhận	Dịch vụ Chuyến đi và Điều phối	Chỉ ghi nhận sau khi tài xế xác nhận
FR-I02	Báo sự cố trong chuyến	Dịch vụ Chuyến đi và Điều phối	Hỏi loại sự cố; không xử lý tranh chấp thanh toán hoặc pháp lý
FR-E01	Tra cứu thu nhập trong ngày và theo kỳ, lịch sử chuyến và chỉ số tài xế	Dịch vụ Chuyến đi và Điều phối	Số liệu lấy từ API; thiếu thì thông báo chưa có
FR-E02	Bật hoặc tắt trạng thái sẵn sàng nhận chuyến	Dịch vụ Chuyến đi và Điều phối	Trạng thái mới được xác nhận qua API
FR-F01	Trả lời câu hỏi về cách sử dụng ứng dụng	Tác nhân hội thoại (truy xuất tri thức)	Trả lời theo tài liệu hướng dẫn; câu hỏi ngoài phạm vi được từ chối và hướng dẫn kênh phù hợp
FR-L01	Hỗ trợ tiếng Việt và tiếng Anh cho luồng tài xế	Tác nhân hội thoại	Cùng tập công cụ tài xế ở hai ngôn ngữ
FR-L02	Kết thúc phiên theo yêu cầu hoặc sau khi tài xế im lặng kéo dài	Tác nhân hội thoại; Dịch vụ Chuyến đi và Điều phối	Nhắc tối đa hai lần (khoảng 15 giây mỗi lần) rồi kết thúc lịch sự
FR-L03	Giới hạn tập công cụ theo loại phiên (trong ứng dụng, mời nhận chuyến, khách hàng)	Tác nhân hội thoại	Phiên mời nhận chuyến chỉ có nhận/từ chối

3.4.4. Nhóm kích hoạt và kết thúc chế độ nói trực tiếp

Hai yêu cầu trong nhóm này không đi qua lượt gọi công cụ như các nhóm trên (Bảng 3.6). Từ khóa đánh thức được nhận dạng ngay trên điện thoại thay vì tách thành một dịch vụ riêng trên máy chủ, vì ba lý do:

– Phải phản hồi tức thì khi tài xế nói từ khóa.

– Không nên gửi âm thanh liên tục lên máy chủ khi trợ lý chưa được kích hoạt.

– Sau khi kích hoạt, chỉ cần dùng lại luồng mở phiên đã có.

Bảng 3.6. Yêu cầu chức năng nhóm kích hoạt (FR-A)

Mã	Yêu cầu	Thành phần phụ trách	Điều kiện chấp nhận
FR-A01	Mở trợ lý bằng từ khóa đánh thức	Ứng dụng tài xế (nhận dạng trên thiết bị)	Mở phiên theo cùng luồng như khi bấm nút; nếu không nhận được từ khóa, tài xế vẫn mở được bằng nút

Mã	Yêu cầu	Thành phần phụ trách	Điều kiện chấp nhận
FR-A02	Kết thúc chế độ nói trực tiếp bằng cụm từ quy định	Tác nhân hội thoại	Tác nhân trở lại hội thoại với tài xế sau khi nghe cụm từ kết thúc

3.4.5. Nhóm giám sát vận hành

Người vận hành cần đánh giá hệ thống theo từng ngày mà không phải đọc từng bản ghi hội thoại. Yêu cầu này làm Dịch vụ Giám sát vận hành sở hữu một loại dữ liệu của riêng nó là báo cáo đã tổng hợp (Bảng 3.7).

Bảng 3.7. Yêu cầu chức năng nhóm giám sát vận hành (FR-O)

Mã	Yêu cầu	Thành phần phụ trách	Điều kiện chấp nhận
FR-O01	Lập báo cáo vận hành cho từng ngày (giờ Việt Nam): số phiên và số tài xế được phục vụ; tỷ lệ công cụ thành công, tỷ lệ API lỗi và tỷ lệ trả lời đúng trên mẫu có chấm; lỗi theo loại; độ trễ phản hồi trung bình, P50, P95	Dịch vụ Giám sát vận hành; Dịch vụ Nhật ký cuộc gọi (dữ liệu nguồn); tác nhân hội thoại (chỉ số phiên)	Báo cáo tự lập sau nửa đêm cho ngày trước, lập lại được theo yêu cầu, ghi rõ cỡ mẫu và phương pháp chấm
FR-O02	Xem báo cáo theo ngày và xu hướng 7 ngày trên trang giám sát hệ thống	Dịch vụ Giám sát vận hành; trang giám sát hệ thống	Chỉ tài khoản quản trị hệ thống truy cập được

3.5. Trường hợp sử dụng chính

Bảng 3.8 tóm tắt mười một trường hợp sử dụng (use case) cốt lõi cùng luồng thành công và luồng ngoại lệ; lời thoại mẫu đặt ở Phụ lục B.

Bảng 3.8. Trường hợp sử dụng cốt lõi

Mã	Trường hợp sử dụng	Yêu cầu liên quan	Kết quả thành công	Ngoại lệ phải xử lý
UC01	Xem lịch chuyến trong ứng dụng	FR-T01, FR-T02	Danh sách đúng theo dữ liệu	Ngữ cảnh trống: thông báo chưa có chuyến hoặc làm mới
UC02	Nhận hoặc từ chối chuyến qua cuộc gọi mời nhận chuyến	FR-T04, FR-L03	Quyết định được cập nhật	Không nghe rõ: hỏi lại; API lỗi: thông báo không cập nhật được

Mã	Trường hợp sử dụng	Yêu cầu liên quan	Kết quả thành công	Ngoại lệ phải xử lý
UC03	Cập nhật tiến độ chuyến	FR-T03	Trạng thái mới được xác nhận	Không đủ điều kiện nghiệp vụ: giải thích ngắn
UC04	Gọi khách hàng	FR-C01, FR-C02	Cuộc gọi khởi tạo đúng chế độ	Đang có cuộc gọi: không mở thêm; lỗi quay số: thông báo rõ
UC05	Hủy chuyến hai bước	FR-T05	Chỉ hủy sau khi tài xế đồng ý	Tài xế không đồng ý: giữ nguyên chuyến
UC06	Báo khách không có mặt hoặc báo sự cố	FR-I01, FR-I02	Ghi nhận sau xác nhận	Không đưa ra quy định bồi thường
UC07	Hỏi cách sử dụng ứng dụng	FR-F01	Trả lời theo tài liệu hướng dẫn	Ngoài phạm vi: hướng dẫn kênh phù hợp
UC08	Tra cứu thu nhập, bật/tắt nhận chuyến	FR-E01, FR-E02	Số liệu hoặc trạng thái đúng	API không trả dữ liệu: thông báo chưa có
UC09	Im lặng kéo dài hoặc lỗi API giữa phiên	FR-L02, NFR-04	Nhắc tài xế hoặc thông báo lỗi ngắn; phiên không bị kết thúc bất thường	Không tạo thông tin thay thế cho dữ liệu lỗi
UC10	Mở trợ lý bằng từ khóa đánh thức	FR-A01	Vào phiên trong ứng dụng	Không nhận từ khóa: vẫn mở bằng nút
UC11	Người vận hành xem báo cáo ngày	FR-O01, FR-O02	Báo cáo hiển thị đủ các nhóm chỉ số	Chưa có báo cáo: cho phép lập lại từ bản ghi

3.6. Yêu cầu phi chức năng

3.6.1. Đặc tả yêu cầu phi chức năng

Luận văn tập trung vào năm yêu cầu phi chức năng: khả năng sử dụng, hiệu năng, khả năng mở rộng, khả năng phục hồi và bảo mật. Mỗi yêu cầu được phân loại theo đặc tính của ISO/IEC 25010 (ISO/IEC, 2023) và đặc tả dưới dạng kịch bản thuộc tính chất lượng (Bass et al., 2021) như trình bày trong Bảng 3.9.

Bảng 3.9. Yêu cầu phi chức năng theo ISO/IEC 25010 và kịch bản thuộc tính chất lượng

Mã	Phân loại (ISO/IEC 25010)	Kích thích và môi trường	Phản ứng mong đợi	Thước đo
NFR-01	Usability (Interaction capability)	Tài xế thực hiện nghiệp vụ cốt lõi bằng giọng nói khi đang lái	Mỗi lượt phản hồi chứa một ý chính; thao tác có rủi ro được xác nhận trước khi thực thi	100% thao tác rủi ro có bước xác nhận; tỷ lệ đạt danh mục kiểm tra hành vi khi lái (Chương 6)
NFR-02	Performance efficiency (time behaviour)	Tài xế kết thúc phát ngôn trong phiên hội thoại bình thường	Hệ thống bắt đầu phát âm thanh trả lời; phát câu đệm nếu phản hồi chưa sẵn sàng sau khoảng 2 giây	P95 độ trễ phản hồi ≤ 2 giây trên luồng cốt lõi
NFR-03	Scalability (thuộc Flexibility)	Số phiên hội thoại đồng thời tăng từ 1 lên 20	Hệ thống mở rộng theo chiều ngang bằng cách tăng số bản sao tác nhân, không thay đổi mã hay các dịch vụ khác	P95 ở 20 phiên (với số bản sao tương ứng) tăng không quá 20% so với 1 phiên; tỷ lệ phiên lỗi < 1%
NFR-04	Reliability: availability, fault tolerance, recoverability (khả năng phục hồi)	Một dịch vụ phụ trợ, API nghiệp vụ hoặc nhà cung cấp AI chính gặp lỗi trong phiên; hoặc một bản sao tác nhân bị dừng	Phiên hội thoại tiếp tục; tác nhân thông báo rõ thao tác không thực hiện được; nhà cung cấp AI dự phòng được sử dụng; bản sao tác nhân được thay thế	100% phiên không bị kết thúc bất thường trong các kịch bản tiêm lỗi; thời gian khôi phục bản sao tác nhân được đo và báo cáo
NFR-05	Security (confidentiality, authenticity)	Người dùng hoặc dịch vụ truy cập API; hệ thống ghi nhật ký	Chỉ Dịch vụ Định danh phát hành JWT, các dịch vụ khác xác minh; tham số bí mật không nằm trong mã nguồn; nhật ký không chứa số điện thoại đầy đủ hoặc token	100% mục đạt trong danh mục kiểm tra bảo mật (Chương 6)

3.6.2. Ràng buộc kiến trúc

Bên cạnh các yêu cầu phi chức năng, hệ thống có bốn ràng buộc kiến trúc (Bảng 3.10). Đây là quy tắc thiết kế bắt buộc được rút ra từ yêu cầu, dùng để kiểm tra tính tuân thủ của hiện thực.

Bảng 3.10. Ràng buộc kiến trúc

Mã	Ràng buộc	Yêu cầu nguồn
CON-01	Tác nhân hội thoại chỉ truy cập dữ liệu nghiệp vụ qua API HTTP, không kết nối trực tiếp cơ sở dữ liệu	Điều kiện chấp nhận chung của FR; NFR-03; NFR-04
CON-02	Mỗi dịch vụ sở hữu dữ liệu của mình; dịch vụ khác truy cập qua API	NFR-03; NFR-04
CON-03	JWT đăng nhập chỉ do Dịch vụ Định danh phát hành	NFR-05
CON-04	Mọi phiên hội thoại được gắn mã phòng trên nhật ký để theo dõi và tìm nguyên nhân lỗi	NFR-04

3.7. Từ yêu cầu phi chức năng đến tính chất của kiến trúc microservices

Bảng 3.11 đối chiếu từng yêu cầu phi chức năng với tính chất của kiến trúc microservices có khả năng đáp ứng yêu cầu đó (mục 2.5), cùng cơ chế dự kiến trong hệ thống. Bảng này là đầu vào cho quyết định kiến trúc ở mục 4.2.

Bảng 3.11. Đối chiếu yêu cầu phi chức năng với tính chất của kiến trúc microservices

Yêu cầu	Tính chất microservices	Cơ chế dự kiến trong hệ thống
NFR-02 Performance	Dị biệt công nghệ; tách xử lý thời gian thực khỏi xử lý giao dịch	Tác nhân hội thoại viết bằng Python, chạy dài hạn trên container, duy trì kết nối âm thanh; API giao dịch viết bằng Node.js chạy trên FaaS; tải trước ngữ cảnh phiên
NFR-03 Scalability	Mở rộng độc lập từng dịch vụ (trục X và trục Y của scale cube)	Tăng số bản sao tác nhân độc lập với API; API nghiệp vụ tự động mở rộng theo số yêu cầu; cơ sở dữ liệu tính phí theo yêu cầu
NFR-04 Resilience	Thiết kế cho lỗi; cô lập lỗi; dịch vụ phi trạng thái; mỗi dịch vụ một cơ sở dữ liệu	Thời gian chờ và suy giảm có kiểm soát khi gọi API; dự phòng nhà cung cấp STT, LLM, TTS; nền tảng container tự thay thế bản sao lỗi; chỉ số phiên và báo cáo ngày để phát hiện suy giảm
NFR-05 Security	Xác thực tập trung, xác minh phân tán; đặc quyền tối thiểu	Dịch vụ Định danh phát hành JWT, các dịch vụ khác xác minh bằng khóa bí mật dùng chung; vai trò IAM riêng cho từng dịch vụ
NFR-01 Usability	Ngữ cảnh giới hạn (bounded context) theo kênh	Phiên trong ứng dụng, phiên mời nhận chuyến và phiên khách hàng có tập công cụ riêng

Từ Bảng 3.11 có thể thấy bốn trên năm yêu cầu phi chức năng (hiệu năng, khả năng mở rộng, khả năng phục hồi, bảo mật) đòi hỏi tách tác nhân hội thoại khỏi các

dịch vụ nghiệp vụ, tách các chức năng phụ trợ (tin nhắn, nhật ký cuộc gọi) khỏi nguồn dữ liệu chuyến để lỗi của chúng không lan sang luồng chính, và tập trung định danh vào một dịch vụ. Đây là các tính chất đặc trưng của kiến trúc microservices; Chương 4 lập luận lựa chọn này so với các phương án thay thế.

3.8. Phạm vi yêu cầu

Trong phạm vi: các nhóm FR-T, FR-C, FR-W, FR-I, FR-E, FR-F, FR-L, FR-A, FR-O và năm yêu cầu phi chức năng NFR-01 đến NFR-05.

Ngoài phạm vi: các chức năng dưới đây không được xây dựng trong luận văn.

- **Nhắn tin nhóm giữa các tài xế:** không thuộc nghiệp vụ của một chuyến đi.
- **Dẫn đường từng ngã rẽ:** tài xế đã dùng ứng dụng bản đồ chuyên dụng; trợ lý chỉ gợi ý điểm dừng và tình trạng giao thông (FR-T07).
- **Thanh toán, hoàn tiền, bảo hiểm và tranh chấp:** cần quy trình pháp lý và con người xử lý, không phù hợp để tự động hóa bằng giọng nói.
- **Thay đổi hồ sơ, biển số xe, khôi phục mật khẩu:** là thao tác nhạy cảm về bảo mật, tài xế thực hiện trên màn hình khi xe đã dừng.
- **Thao tác trên ứng dụng của hãng gọi xe khác:** trợ lý chỉ làm việc với hệ thống chuyến đi của luận văn.
- **Huấn luyện lại mô hình nhận dạng hoặc tổng hợp giọng nói:** luận văn dùng mô hình có sẵn của nhà cung cấp (mục 1.5.3).

3.9. Tiêu chí chấp nhận

Tiêu chí chấp nhận là điều kiện đo được để kết luận một yêu cầu đã được đáp ứng. Bảng 3.12 nêu, cho từng nhóm yêu cầu, chỉ số cần đo, ngưỡng đạt và trường hợp sử dụng hoặc kịch bản dùng để đo. Chương 6 đánh giá hệ thống theo đúng các tiêu chí này.

Bảng 3.12. Tiêu chí chấp nhận theo yêu cầu

Yêu cầu	Chỉ số	Ngưỡng	Trường hợp sử dụng / kịch bản
FR-T, FR-C, FR-W, FR-I, FR-E	Độ chính xác chọn công cụ; tỷ lệ hoàn thành nghiệp vụ	Báo cáo theo nhóm kịch bản	UC01–UC06, UC08

Yêu cầu	Chỉ số	Ngưỡng	Trường hợp sử dụng / kịch bản
FR-F01	Tỷ lệ trả lời đúng theo tài liệu hướng dẫn	Không đưa ra chính sách không có trong tài liệu	UC07
FR-L02, FR-A01	Hành vi khi im lặng; mở phiên bằng từ khóa	Đạt / không đạt	UC09, UC10
Luồng khách hàng	Tỷ lệ trường hợp kiểm thử đạt	Đạt / không đạt	Bộ trường hợp kiểm thử khách hàng
NFR-01	Danh mục kiểm tra hành vi khi lái	100% thao tác rủi ro có xác nhận	UC01–UC06
NFR-02	P50, P95 độ trễ phản hồi	P95 ≤ 2 giây	UC01, UC03, UC04, UC07
NFR-03	P95 và tỷ lệ phiên lỗi theo số phiên đồng thời	Tăng P95 ≤ 20%; lỗi < 1%	Kịch bản SC-01 đến SC-03
NFR-04	Tỷ lệ phiên duy trì khi tiêm lỗi; thời gian khôi phục	100% phiên duy trì	Kịch bản RS-01 đến RS-05
NFR-05	Danh mục kiểm tra bảo mật	100% mục đạt	Kiểm tra mã nguồn và cấu hình
FR-O01, FR-O02	Báo cáo được lập đúng từ bản ghi mẫu; hiển thị trên trang giám sát	Đạt / không đạt	UC11
Nhận dạng giọng nói	Tỷ lệ lỗi từ yên tĩnh so với nhiễu	So sánh tương đối	Bộ câu tham chiếu cố định

Kết luận chương

Chương 3 đã xác định các yêu cầu chức năng theo nhóm nghiệp vụ, gắn với thành phần phụ trách và điều kiện chấp nhận; đặc tả năm yêu cầu phi chức năng theo ISO/IEC 25010 dưới dạng kịch bản đo được; nêu bốn ràng buộc kiến trúc; và đối chiếu các yêu cầu phi chức năng với tính chất của kiến trúc microservices. Chương 4 dùng các yêu cầu này làm động lực kiến trúc để lựa chọn và thiết kế hệ thống.

Chương 4. Thiết kế hệ thống

Chương này trình bày quyết định kiến trúc và thiết kế hệ thống dựa trên các yêu cầu ở Chương 3. Chương bắt đầu từ các động lực kiến trúc, lập luận lựa chọn kiến trúc microservices so với các phương án thay thế, sau đó mô tả kiến trúc tổng thể trên AWS, phân chia hệ thống thành các dịch vụ, luồng hoạt động chính của từng dịch vụ dưới dạng sequence diagram, thiết kế xử lý một lượt hội thoại và các cơ chế bảo đảm yêu cầu phi chức năng. Chi tiết hiện thực trình bày ở Chương 5.

4.1. Động lực kiến trúc

Động lực kiến trúc là tập yêu cầu và ràng buộc có ảnh hưởng quyết định đến cấu trúc hệ thống (Bass et al., 2021). Bảng 4.1 tổng hợp các động lực kiến trúc của hệ thống, rút ra từ Chương 3.

Bảng 4.1. Động lực kiến trúc

Loại	Mã	Nội dung	Ảnh hưởng đến kiến trúc
Yêu cầu chức năng	FR-T, FR-C	Nghiệp vụ chuyến đi và liên lạc khách hàng thực hiện qua gọi công cụ, trên hai kênh WebRTC và SIP	Tách logic nghiệp vụ khỏi tác nhân để dùng chung cho mọi kênh
Yêu cầu phi chức năng	NFR-02	P95 độ trễ phản hồi ≤ 2 giây	Tác nhân chạy dài hạn, duy trì kết nối âm thanh; tải trước ngữ cảnh
Yêu cầu phi chức năng	NFR-03	Mở rộng theo số phiên đồng thời	Tác nhân và API mở rộng độc lập
Yêu cầu phi chức năng	NFR-04	Phiên không bị kết thúc khi thành phần phụ trợ hoặc nhà cung cấp AI lỗi	Cô lập lỗi giữa các dịch vụ; dự phòng nhà cung cấp
Yêu cầu phi chức năng	NFR-05	Định danh tập trung, bảo vệ bí mật và dữ liệu cá nhân	Một dịch vụ định danh riêng; quyền truy cập riêng từng dịch vụ
Yêu cầu phi chức năng	NFR-01	Tập công cụ phù hợp từng loại phiên	Phân loại phiên trong tác nhân
Ràng buộc	CON-01 đến CON-04	Tác nhân chỉ gọi API; mỗi dịch vụ sở hữu dữ liệu; JWT chỉ do Dịch vụ Định danh phát hành; nhật ký gắn mã phòng	Ranh giới dịch vụ bắt buộc
Ràng buộc môi trường	—	STT, LLM, TTS và truyền thông thời gian thực là dịch vụ bên ngoài (LiveKit Cloud, Twilio, OpenAI, Google); nhóm phát triển nhỏ; chi phí vận hành thấp	Ưu tiên dịch vụ đám mây được quản lý, tính phí theo mức sử dụng

4.2. Quyết định kiến trúc

4.2.1. Lựa chọn kiểu kiến trúc (ADR-01)

Bối cảnh. Hệ thống gồm hai loại tải có đặc điểm khác nhau. Tác nhân hội thoại là tác vụ chạy dài hạn, giữ kết nối âm thanh liên tục trong suốt phiên, sử dụng các thư viện AI và âm thanh trong hệ sinh thái Python. Các API nghiệp vụ (chuyến đi, định danh, tin nhắn, nhật ký cuộc gọi) là giao dịch ngắn, phi trạng thái, được gọi bởi nhiều bên (ứng dụng tài xế, ứng dụng khách hàng, trang quản trị và tác nhân).

Các phương án. Bốn phương án được xem xét:

- **(A) Nguyên khối:** một tiến trình gồm cả API nghiệp vụ và tác nhân.
- **(B) Nguyên khối phân mô-đun:** một đơn vị triển khai, bên trong chia mô-đun.
- **(C) Microservices:** tác nhân và từng năng lực nghiệp vụ là dịch vụ triển khai độc lập.
- **(D) Thuần serverless:** mọi thành phần, kể cả tác nhân, chạy trên FaaS.

Bảng 4.2 đánh giá bốn phương án theo các yêu cầu phi chức năng.

Bảng 4.2. Đánh giá các phương án kiến trúc theo yêu cầu phi chức năng

Yêu cầu	(A) Nguyên khối	(B) Nguyên khối phân mô-đun	(C) Microservices	(D) Thuần serverless
NFR-02 Performance	Đáp ứng một phần: tác nhân và API tranh chấp tài nguyên trong cùng tiến trình	Đáp ứng một phần: như (A)	Đáp ứng: tác nhân chạy riêng trên container, API chạy riêng	Không đáp ứng: FaaS giới hạn thời gian thực thi, khởi động nguội, không giữ được kết nối âm thanh dài
NFR-03 Scalability	Không đáp ứng: phải nhân bản toàn bộ ứng dụng	Không đáp ứng: như (A)	Đáp ứng: tăng số bản sao tác nhân độc lập; API tự mở rộng	Đáp ứng một phần: API tự mở rộng, tác nhân không chạy được
NFR-04 Resilience	Không đáp ứng: lỗi một mô-đun làm dừng cả tiến trình	Đáp ứng một phần: cô lập ở mức mã, không cô lập ở mức tiến trình	Đáp ứng: lỗi dịch vụ phụ trợ không lan sang luồng chính	Đáp ứng một phần

Yêu cầu	(A) Nguyên khối	(B) Nguyên khối phân mô-đun	(C) Microservices	(D) Thuần serverless
NFR-05 Security	Đáp ứng một phần: một tập quyền chung cho toàn bộ ứng dụng	Đáp ứng một phần	Đáp ứng: định danh tập trung, quyền riêng từng dịch vụ	Đáp ứng
Độ phức tạp vận hành	Thấp	Thấp	Cao	Trung bình

Quyết định. Chọn phương án (C) microservices, trong đó các API nghiệp vụ triển khai trên FaaS (AWS Lambda) sau cổng API (Amazon API Gateway), tác nhân hội thoại triển khai trên container được quản lý (Amazon ECS trên AWS Fargate), mỗi dịch vụ sở hữu bảng dữ liệu riêng trên Amazon DynamoDB.

Hệ quả và biện pháp giảm thiểu. Microservices làm tăng độ phức tạp vận hành, thêm độ trễ mạng giữa các dịch vụ và gây khó khăn cho tính nhất quán dữ liệu (Soldani et al., 2018). Luận văn giảm thiểu các chi phí này bằng:

- **Độ phức tạp vận hành:** hạ tầng dạng mã cho từng dịch vụ (AWS SAM, AWS CloudFormation) và kịch bản triển khai tự động.
- **Độ trễ mạng:** tải trước ngữ cảnh phiên và dùng lại kết nối HTTP để giảm số lần gọi mạng trên luồng hội thoại.
- **Nhất quán dữ liệu:** chỉ một dịch vụ là nguồn dữ liệu chuẩn cho chuyến đi; tác nhân không lưu dữ liệu nghiệp vụ.
- **Khó giám sát xuyên dịch vụ:** mọi dòng nhật ký gắn mã phòng hội thoại để theo dõi một yêu cầu qua các dịch vụ.

4.2.2. Lựa chọn luồng xử lý lượt hội thoại (ADR-02)

Bối cảnh. Thời gian mô hình ngôn ngữ sinh token đầu tiên chiếm phần lớn độ trễ của một lượt (số liệu ở Chương 6). Nguyên mẫu từng thử nghiệm một nhánh xử lý rút gọn dựa trên nhận dạng ý định: với các câu quen thuộc, hệ thống gọi thẳng công cụ mà không qua mô hình ngôn ngữ.

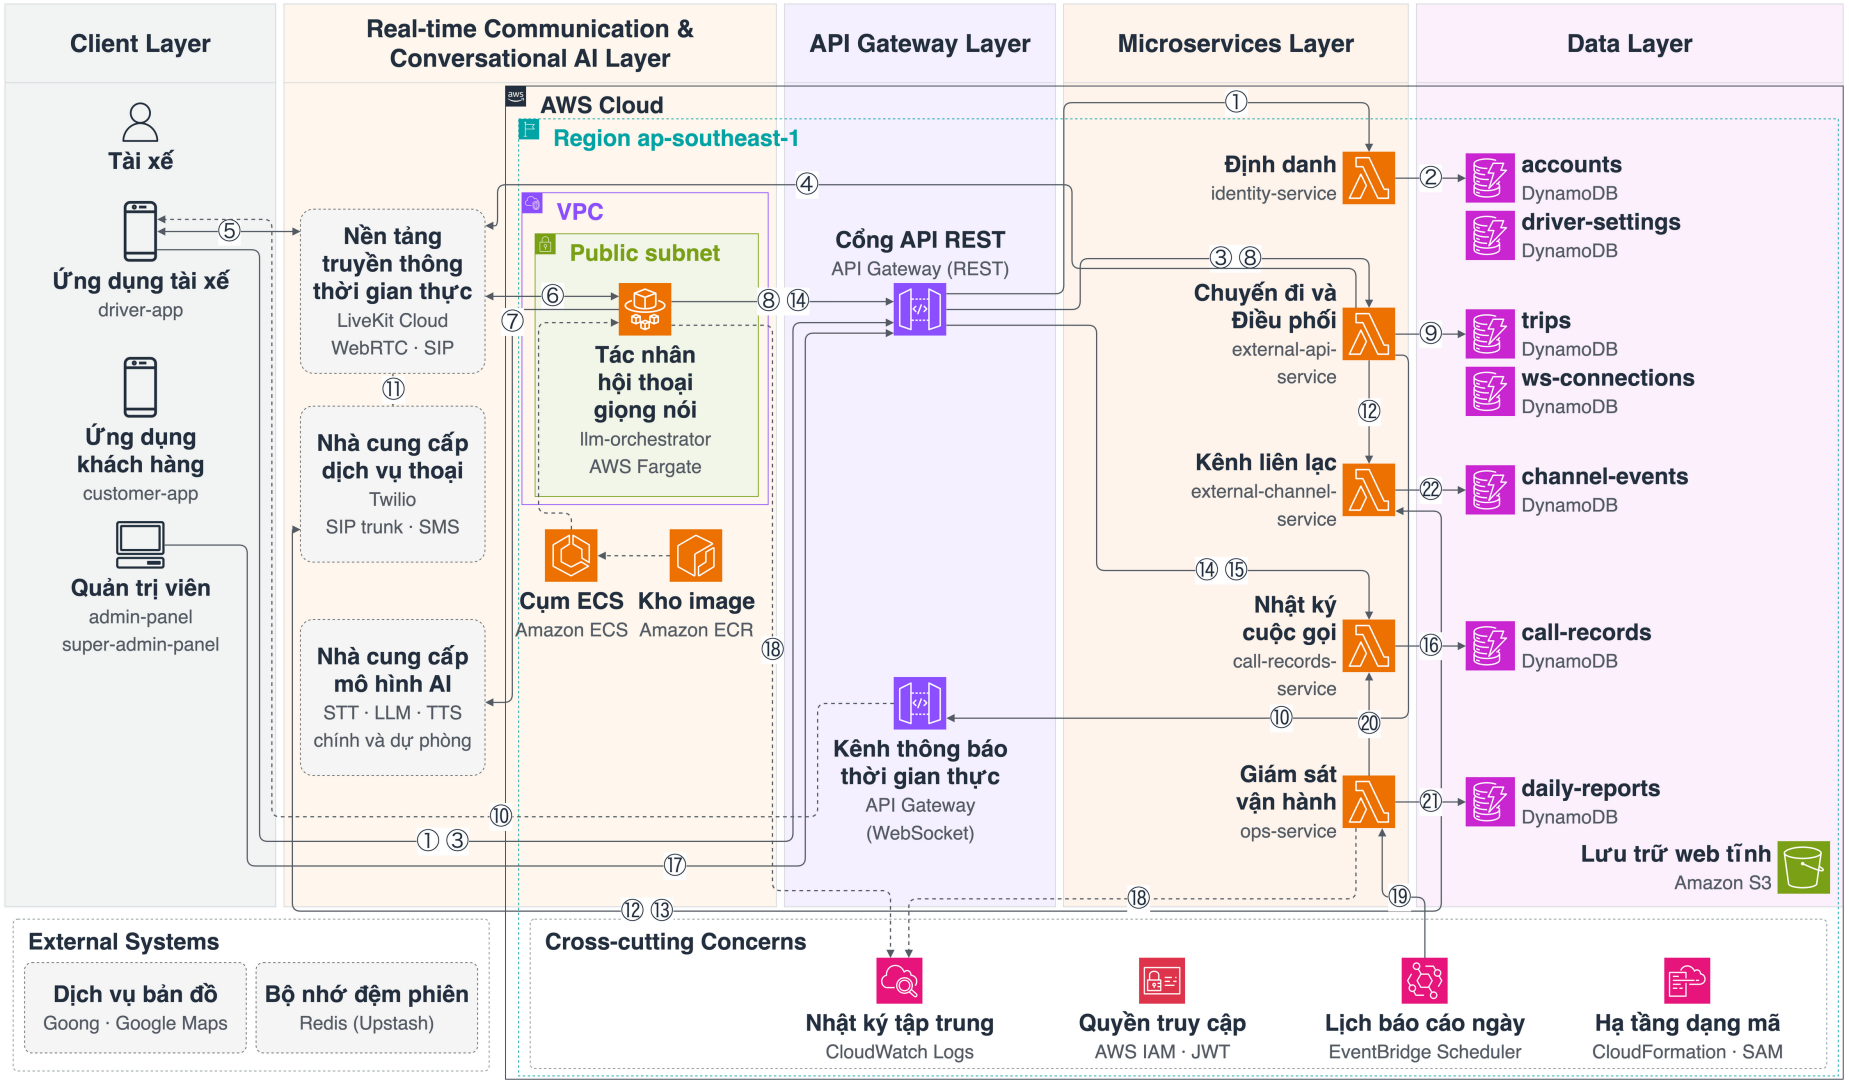
Các phương án và quyết định được tóm tắt trong Bảng 4.3.

Bảng 4.3. Các phương án luồng xử lý lượt hội thoại

Phương án	Ưu điểm	Nhược điểm	Kết luận
Mọi câu qua LLM, không có câu đệm	Một luồng xử lý duy nhất	Người dùng cảm nhận khoảng lặng khi thời gian sinh token đầu cao	Không chọn
Nhánh rút gọn theo ý định kết hợp LLM	Độ trễ thấp với câu quen thuộc (số liệu đợt đo 05–06/09/2026 ở Chương 6)	Dễ chọn sai công cụ với phát ngôn không rõ ý định; khó bảo trì tập mẫu	Không chọn; đã tắt trong mã nguồn
Mọi câu qua LLM kèm gọi công cụ; câu đệm sau khoảng 2 giây; tải trước ngữ cảnh	Một luồng thống nhất; không tạo phản hồi nghiệp vụ trước khi có kết quả thật; câu đệm báo hiệu hệ thống đang xử lý	Độ trễ thực của lượt vẫn phụ thuộc thời gian sinh token đầu	Chọn

4.3. Kiến trúc tổng thể trên AWS

Hình 4.1 trình bày kiến trúc tổng thể của hệ thống theo quy ước sơ đồ kiến trúc AWS (in trên trang ngang). Năm lớp được xếp thành năm cột, đọc từ trái sang phải theo đường đi của một yêu cầu; các thành phần dùng chung cho mọi lớp nằm ở dải Cross-cutting Concerns phía dưới. Mỗi thành phần ghi tên chức năng (chữ đậm) và tên kỹ thuật (chữ nhỏ). Các luồng chính được đánh số ① đến ㉒, khớp Bảng 4.4 và các bước của sequence diagram ở mục 4.5; mũi tên nét đứt là luồng phụ trợ; hộp xám nét đứt là hệ thống bên ngoài AWS.



Hình 4.1. Kiến trúc hệ thống trên nền tảng AWS theo mô hình microservices

Mỗi lớp dưới đây nêu vai trò, thành phần và dịch vụ AWS được dùng, kèm giải thích ngắn cho dịch vụ đó.

- **Lớp máy khách (Client Layer)** — nơi người dùng thao tác. Gồm ứng dụng tài xế, ứng dụng khách hàng, trang quản trị điều hành và trang giám sát hệ thống. Các trang web là tệp tĩnh (HTML, JavaScript) lưu trên Amazon S3, dịch vụ lưu trữ tệp của AWS, và được tải thẳng về trình duyệt.
- **Lớp truyền thông thời gian thực và hội thoại AI (Real-time Communication & Conversational AI Layer)** — nơi diễn ra cuộc nói chuyện. LiveKit Cloud truyền âm thanh giữa điện thoại tài xế và trợ lý (WebRTC), và quay số ra mạng điện thoại khi cần (SIP). Tác nhân hội thoại giọng nói nghe âm thanh, gọi các mô hình AI (STT, LLM, TTS; mỗi khâu có nhà cung cấp chính và dự phòng) và trả lời. Tác nhân chạy liên tục nên được đóng gói thành container và chạy trên Amazon ECS với AWS Fargate: ECS quản lý số bản sao đang chạy, còn Fargate cung cấp máy chủ, nhờ vậy nhóm phát triển không phải tự quản lý máy chủ.
- **Lớp cổng API (API Gateway Layer)** — cửa vào duy nhất của các dịch vụ nghiệp vụ. Amazon API Gateway nhận yêu cầu HTTPS từ ứng dụng hoặc từ tác nhân rồi chuyển tới đúng dịch vụ. Một cổng dạng WebSocket giữ kết nối mở với ứng dụng tài xế để máy chủ chủ động đẩy thông báo (ví dụ có chuyến mới).
- **Lớp microservices (Microservices Layer)** — nơi xử lý nghiệp vụ. Gồm năm dịch vụ: Định danh, Chuyến đi và Điều phối, Kênh liên lạc, Nhật ký cuộc gọi, Giám sát vận hành. Mỗi dịch vụ là một hàm AWS Lambda: đoạn mã chỉ chạy khi có yêu cầu, AWS tự tăng số bản chạy song song khi tải tăng và chỉ tính phí theo thời gian chạy thực tế.
- **Lớp dữ liệu (Data Layer)** — nơi lưu dữ liệu. Mỗi dịch vụ có bảng riêng trên Amazon DynamoDB, cơ sở dữ liệu NoSQL do AWS quản lý; dịch vụ khác muốn đọc phải gọi API của dịch vụ sở hữu, không đọc thẳng bảng. Danh sách bảng của từng dịch vụ ở Bảng 4.5. Riêng bộ nhớ đệm Redis (dịch vụ bên ngoài) lưu trạng thái phiên ngắn hạn của Dịch vụ Chuyến đi và Điều phối.

– **Các mối quan tâm xuyên suốt (Cross-cutting Concerns)** — các chức năng dùng chung cho mọi lớp: ghi nhật ký tập trung (Amazon CloudWatch Logs); phân quyền truy cập tài nguyên AWS cho từng dịch vụ (AWS IAM) và xác thực người dùng bằng JWT; hẹn giờ chạy báo cáo ngày (Amazon EventBridge Scheduler); mô tả hạ tầng bằng mã để triển khai tự động (AWS CloudFormation, AWS SAM).

Các hệ thống bên ngoài không chạy trên AWS: LiveKit Cloud, Twilio (kết nối mạng điện thoại công cộng và gửi SMS) và các nhà cung cấp mô hình AI nằm trong cột Real-time Communication & Conversational AI; dịch vụ bản đồ và bộ nhớ đệm Redis (cả hai được Dịch vụ Chuyến đi và Điều phối sử dụng) nằm trong khung External Systems. Trong cùng cột đó, Amazon ECS chạy tác vụ Fargate của tác nhân, còn Amazon ECR lưu image container mà ECS kéo về khi khởi chạy tác vụ (hai mũi tên nét đứt không đánh số). Amazon S3 lưu các trang web tĩnh (trang quản trị, trang giám sát) nên được đặt ở cột Data Layer.

Ví dụ một yêu cầu đi qua các lớp. Tài xế đang có một chuyến chờ xác nhận và nói "nhận chuyến này":

1. Âm thanh đi từ ứng dụng tài xế qua LiveKit Cloud tới tác nhân (luồng ⑤, ⑥).
2. Tác nhân chuyển âm thanh thành chữ; mô hình ngôn ngữ chọn công cụ nhận chuyến (⑦).
3. Tác nhân gọi API qua API Gateway tới Dịch vụ Chuyến đi và Điều phối (⑧); hàm Lambda của dịch vụ ghi trạng thái confirmed vào bảng trips trên DynamoDB (⑨).
4. Dịch vụ tra bảng ws-connections rồi đẩy thông báo trip_confirmed qua API Gateway WebSocket tới ứng dụng tài xế (⑩) và ứng dụng khách hàng, để cả hai màn hình cập nhật ngay.
5. Sau khi API trả về thành công, tác nhân mới đọc câu xác nhận cho tài xế. Mỗi bước đều ghi nhật ký lên CloudWatch Logs (⑱).

Bảng ws-connections cần thiết vì API Gateway WebSocket cấp cho mỗi ứng dụng đang kết nối một mã kết nối (connectionId), trong khi hàm Lambda không nhớ gì giữa các lần gọi. Khi ứng dụng kết nối, hàm Lambda lưu cặp mã kết nối và định

danh người dùng (ví dụ driver#<số điện thoại>); khi cần đẩy thông báo, Dịch vụ Chuyến đi và Điều phối tra bảng này để biết gửi tới kết nối nào; khi ứng dụng ngắt kết nối, bản ghi bị xóa. Bảng này không chứa nội dung hội thoại; lời thoại giữa tài xế và trợ lý được lưu ở bảng call-records của Dịch vụ Nhật ký cuộc gọi.

Toàn bộ tài nguyên AWS nằm trong vùng ap-southeast-1 (Singapore). Lambda, API Gateway và DynamoDB là dịch vụ cấp vùng, không cần đặt trong mạng riêng ảo (VPC). Tác nhân hội thoại chạy trong subnet công khai của một VPC; nhóm bảo mật (security group) chỉ cho phép kết nối chiều ra, vì tác nhân chủ động kết nối tới LiveKit Cloud, các API nghiệp vụ và nhà cung cấp AI, không nhận kết nối từ ngoài vào. API Gateway không tự kiểm tra đăng nhập (không dùng authorizer); JWT được xác minh trong mã của từng dịch vụ bằng khóa bí mật dùng chung với Dịch vụ Định danh.

Bảng 4.4 mô tả các luồng được đánh số trên Hình 4.1.

Bảng 4.4. Các luồng chính trên Hình 4.1

Số	Từ → Đến	Giao thức	Mục đích	Sequence
①	Ứng dụng tài xế → API Gateway → Dịch vụ Định danh	HTTPS	Đăng nhập, làm mới token	S1
②	Dịch vụ Định danh → DynamoDB (accounts, driver-settings)	AWS SDK	Đọc tài khoản, lưu băm refresh token	S1
③	Ứng dụng tài xế → API Gateway → Dịch vụ Chuyến đi và Điều phối	HTTPS	Xin token thoại, tra cứu chuyến	S2
④	Dịch vụ Chuyến đi và Điều phối → LiveKit Cloud	HTTPS	Tạo phòng hội thoại, phân công tác nhân, quay số SIP	S2, S4, S5
⑤	Ứng dụng tài xế ↔ LiveKit Cloud	WebRTC	Truyền âm thanh hai chiều	S2, S3
⑥	LiveKit Cloud ↔ Tác nhân hội thoại	WebRTC / WebSocket	Giao việc cho tác nhân; truyền âm thanh	S2, S3
⑦	Tác nhân hội thoại → Nhà cung cấp AI (chính, dự phòng)	HTTPS / gRPC	Nhận dạng giọng nói, sinh phản hồi, tổng hợp giọng nói	S3
⑧	Tác nhân hội thoại → API Gateway → Dịch vụ Chuyến đi và Điều phối	HTTPS	Đăng ký phiên, tải ngữ cảnh, gọi công cụ nghiệp vụ	S2, S3, S4, S5

Số	Từ → Đến	Giao thức	Mục đích	Sequence
⑨	Dịch vụ Chuyến đi và Điều phối → DynamoDB (trips, ws-connections)	AWS SDK	Đọc, ghi chuyến và kết nối WebSocket	S3, S4
⑩	Dịch vụ Chuyến đi và Điều phối → API Gateway WebSocket → Ứng dụng tài xế (và ứng dụng khách hàng)	WSS	Thông báo đẩy khi chuyến thay đổi	S4
⑪	LiveKit Cloud → Twilio (SIP trunk) → điện thoại	SIP / PSTN	Gọi điện mời tài xế nhận chuyến; gọi khách hàng	S4, S5
⑫	Dịch vụ Chuyến đi và Điều phối → API Gateway → Dịch vụ Kênh liên lạc → Twilio	HTTPS	Gửi SMS	S5
⑬	Twilio → API Gateway → Dịch vụ Kênh liên lạc	HTTPS (webhook)	Trạng thái cuộc gọi, tin nhắn đến	S5
⑭	Tác nhân hội thoại → API Gateway → Dịch vụ Nhật ký cuộc gọi	HTTPS	Ghi bản ghi và tóm tắt hội thoại khi kết thúc phiên	S6
⑮	Dịch vụ Chuyến đi và Điều phối → API Gateway → Dịch vụ Nhật ký cuộc gọi	HTTPS	Đọc tóm tắt cuộc gọi gần nhất	S6
⑯	Dịch vụ Nhật ký cuộc gọi → DynamoDB (call-records)	AWS SDK	Lưu bản ghi cuộc gọi	S6
⑰	Trang quản trị, trang giám sát → API Gateway → các dịch vụ	HTTPS	Quản trị chuyến; giám sát tình trạng, nhật ký	—
⑱	Mọi dịch vụ và tác nhân → CloudWatch Logs	AWS SDK	Ghi nhật ký gắn mã phòng	—
⑲	EventBridge Scheduler → Dịch vụ Giám sát vận hành	AWS (Lambda invoke)	Kích hoạt lập báo cáo ngày lúc 00:15 giờ Việt Nam	S7
⑳	Dịch vụ Giám sát vận hành → API Gateway → Dịch vụ Nhật ký cuộc gọi	HTTPS	Đọc bản ghi hội thoại của một ngày	S7
㉑	Dịch vụ Giám sát vận hành → DynamoDB (daily-reports)	AWS SDK	Lưu báo cáo ngày	S7
㉒	Dịch vụ Kênh liên lạc → DynamoDB (channel-events)	AWS SDK	Lưu sự kiện Twilio và kết quả gửi SMS	S5

4.4. Phân chia hệ thống thành các dịch vụ

Bảng 4.5 mô tả năng lực nghiệp vụ, nhóm API, bảng dữ liệu sở hữu, nền tảng chạy và yêu cầu được đáp ứng của từng dịch vụ (cột Dịch vụ ghi tên rút gọn, bỏ chữ "Dịch vụ"). Dữ liệu nguồn của báo cáo ngày vẫn thuộc Dịch vụ Nhật ký cuộc gọi; Dịch vụ Giám sát vận hành chỉ lưu báo cáo đã tổng hợp. Ranh giới dịch vụ được xác định theo năng lực nghiệp vụ (Newman, 2021): mỗi dịch vụ sở hữu một năng lực và dữ liệu tương ứng, dịch vụ khác chỉ truy cập qua API.

Bảng 4.5. Phân chia dịch vụ

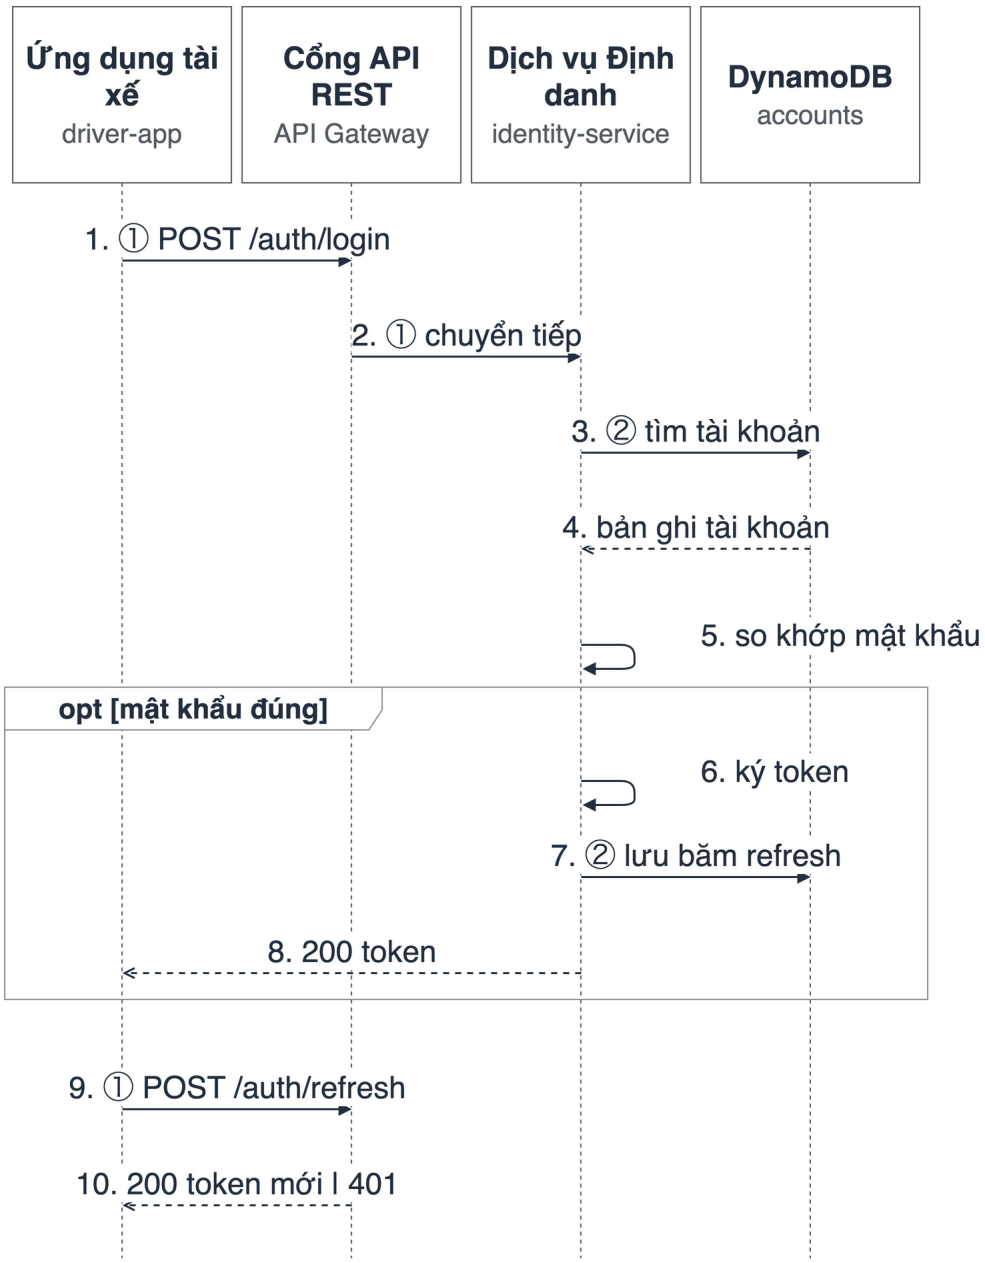
Dịch vụ	Năng lực nghiệp vụ	Nhóm API	Dữ liệu sở hữu	Nền tảng	Yêu cầu
Định danh	Tài khoản, đăng nhập, cài đặt tài xế	auth, accounts, settings	accounts, driver-settings	Lambda	NFR-05; CON-03
Chuyến đi và Điều phối	Chuyến đi, ngữ cảnh tài xế, phiên thoại, mời nhận chuyến, cuộc gọi, nhắc việc	trips, drivers, voice, calls, sms, reminders, customers, places	trips, ws-connections; bộ nhớ đệm Redis	Lambda; API Gateway WebSocket	FR-T, FR-C, FR-W, FR-I, FR-E; NFR-02, NFR-03
Kênh liên lạc	SMS, sự kiện của nhà cung cấp thoại	sms, calls (webhook)	channel-events	Lambda	FR-C03; NFR-04
Nhật ký cuộc gọi	Bản ghi hội thoại, tóm tắt, chỉ số phiên	records	call-records	Lambda	FR-C05, FR-O01; NFR-04
Giám sát vận hành	Tình trạng dịch vụ, nhật ký, báo cáo ngày	status, logs, records, agent, reports	daily-reports (chỉ báo cáo đã tổng hợp)	Lambda; EventBridge Scheduler	FR-O01, FR-O02; CON-04
Tác nhân hội thoại giọng nói	Hội thoại STT – LLM kèm gọi công cụ – TTS	Không có; nhận việc từ LiveKit	Không lưu bền vững (chỉ trạng thái phiên)	ECS Fargate	FR-T, FR-C, FR-F, FR-L; NFR-01 đến NFR-04; CON-01

4.5. Sequence diagram cho các luồng chính

Mục này mô tả luồng hoạt động chính của từng dịch vụ bằng sequence diagram. Mỗi bước ghi thành phần tham gia, thông điệp (phương thức và đường dẫn API) và

tham số chính; các bước đã được đối chiếu với mã nguồn, bảng đối chiếu chi tiết (tệp và dòng mã) ở Phụ lục F. Số trong ngoặc tròn tương ứng với luồng trên Hình 4.1.

4.5.1. S1 — Đăng nhập (Dịch vụ Định danh)



Hình 4.2. Sequence S1: đăng nhập tài xế và phát hành JWT

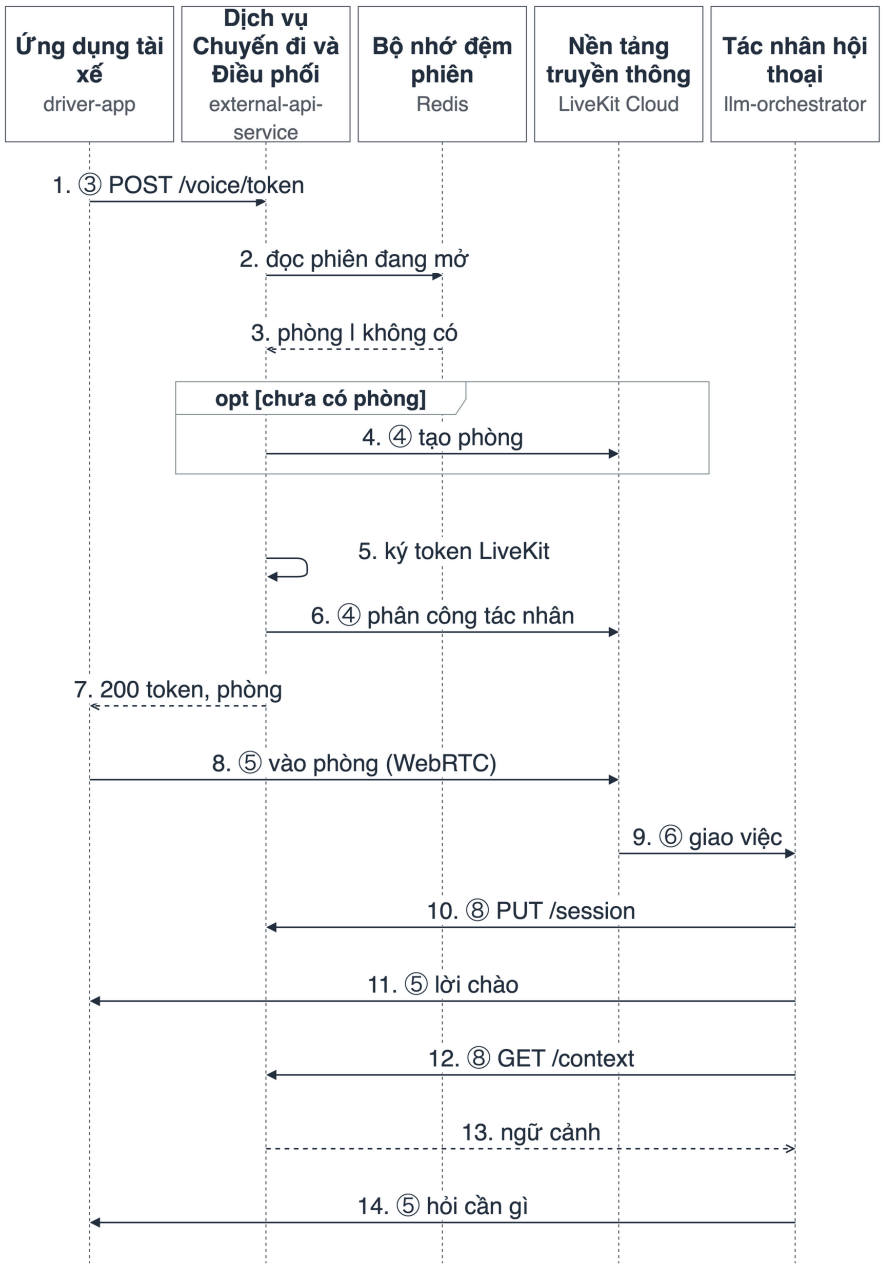
Bảng 4.6. Các bước của sequence S1

Bước	Từ → Đến	Thông điệp	Ghi chú
1 ①	Ứng dụng tài xế → Cổng API REST	POST /api/v1/auth/login, thân gồm role = driver, phone, password	Thiếu trường bắt buộc: 400

Bước	Từ → Đến	Thông điệp	Ghi chú
2 ①	Cổng API REST → Dịch vụ Định danh	Chuyển tiếp yêu cầu	—
3 ②	Dịch vụ Định danh → DynamoDB accounts	Tìm tài khoản theo số điện thoại và vai trò	—
4	DynamoDB accounts → Dịch vụ Định danh	Bản ghi tài khoản	—
5	Dịch vụ Định danh	So khớp mật khẩu với giá trị băm bcrypt	Sai thông tin: 401; tài khoản bị khóa: 403
6	Dịch vụ Định danh	Ký access token và refresh token	Access token 15 phút, refresh token 30 ngày (mặc định)
7 ②	Dịch vụ Định danh → DynamoDB accounts	Lưu giá trị băm và hạn của refresh token	Cho phép thu hồi token
8	Dịch vụ Định danh → Ứng dụng tài xế	200: access_token, refresh_token	Ứng dụng lưu token cho các lời gọi sau
9 ①	Ứng dụng tài xế → Cổng API REST	POST /api/v1/auth/refresh, thân gồm refresh_token	—
10	Cổng API REST → Ứng dụng tài xế	200: cặp token mới	Token bị thu hồi hoặc hết hạn: 401

Các dịch vụ khác xác minh access token bằng khóa bí mật dùng chung, không gọi lại Dịch vụ Định danh cho mỗi yêu cầu.

4.5.2. S2 — Khởi tạo phiên trợ lý trong ứng dụng (Dịch vụ Chuyến đi và Điều phối)



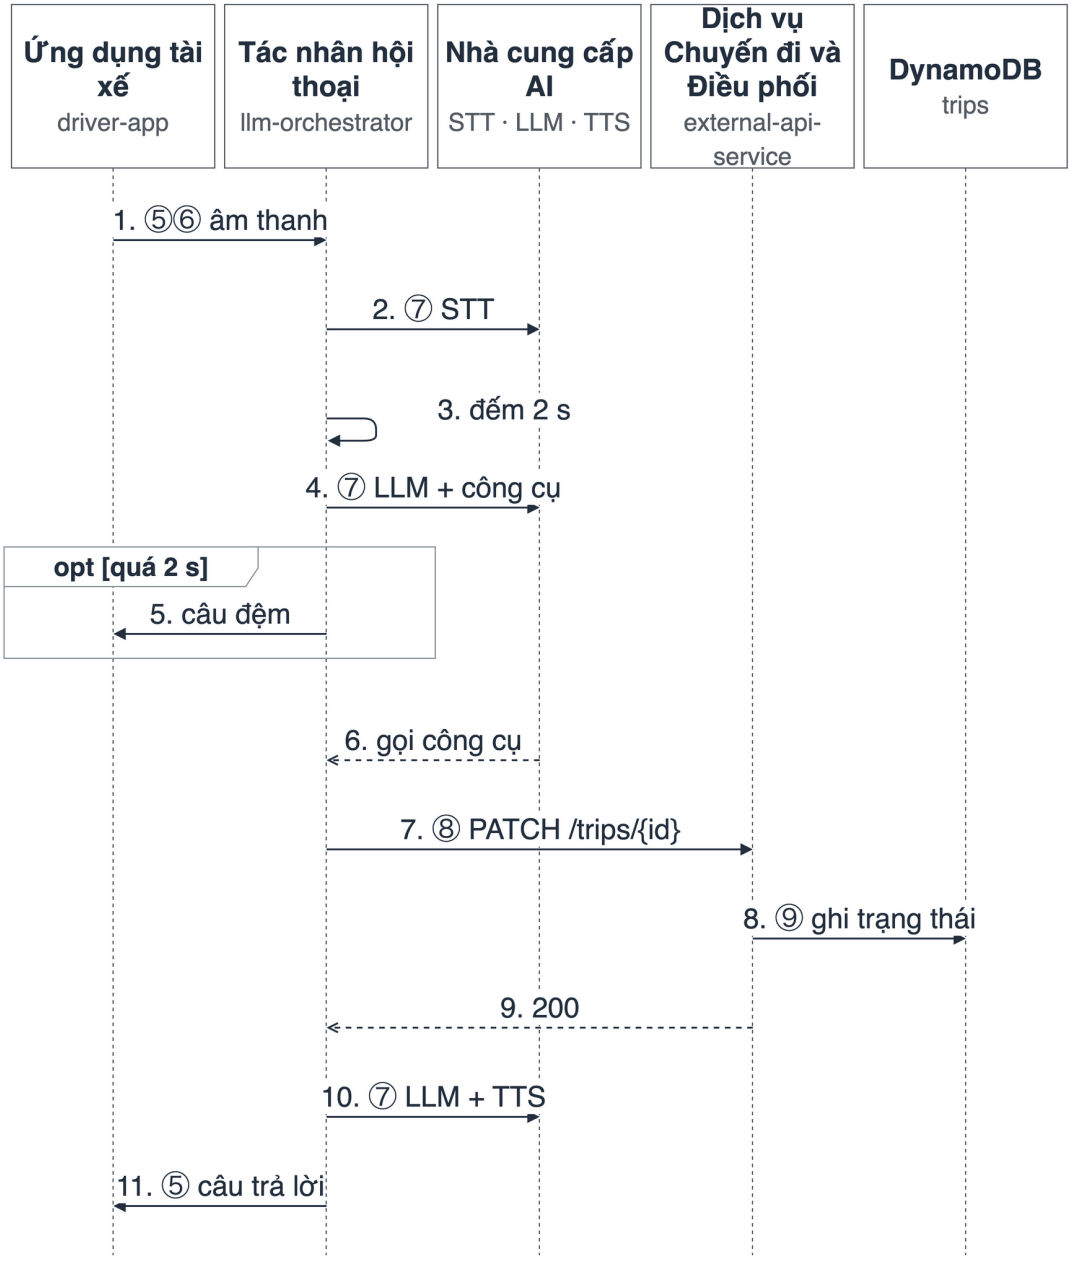
Hình 4.3. Sequence S2: khởi tạo phiên trợ lý trong ứng dụng

Bảng 4.7. Các bước của sequence S2

Bước	Từ → Đến	Thông điệp	Ghi chú
1 ③	Ứng dụng tài xế → Dịch vụ Chuyến đi và Điều phối	POST /api/v1/voice/token với tham số driver_phone, lang; tiêu đề Authorization mang JWT	JWT không hợp lệ: 401
2	Dịch vụ Chuyến đi và Điều phối → Redis	Đọc phiên đang mở của tài xế	—

Bước	Từ → Đến	Thông điệp	Ghi chú
3	Redis → Dịch vụ Chuyến đi và Điều phối	Tên phòng đang mở, hoặc không có	Có phòng: kiểm tra tác nhân còn trong phòng
4 ④	Dịch vụ Chuyến đi và Điều phối → LiveKit Cloud	Chỉ khi chưa có phòng: tạo phòng driver-{số điện thoại}-{UUID} với metadata ngôn ngữ	Phòng còn nhưng mất tác nhân: phân công lại
5	Dịch vụ Chuyến đi và Điều phối	Ký token LiveKit (thời hạn 3600 giây)	—
6 ④	Dịch vụ Chuyến đi và Điều phối → LiveKit Cloud	Yêu cầu phân công tác nhân (agent dispatch) cho phòng	Lỗi phân công chỉ ghi nhật ký
7	Dịch vụ Chuyến đi và Điều phối → Ứng dụng tài xế	200: token, room_name, livekit_url	—
8 ⑤	Ứng dụng tài xế → LiveKit Cloud	Tham gia phòng qua WebRTC	—
9 ⑥	LiveKit Cloud → Tác nhân hội thoại	Giao việc cho một bản sao tác nhân đang rảnh	Tác nhân phân loại phiên theo tên phòng và metadata
10 ⑧	Tác nhân hội thoại → Dịch vụ Chuyến đi và Điều phối	PUT /api/v1/drivers/me/session, thân room_name	Chạy song song; lỗi chỉ ghi nhật ký
11 ⑤	Tác nhân hội thoại → Ứng dụng tài xế	Phát lời chào ngắn cố định	Không chờ tải xong ngữ cảnh
12 ⑧	Tác nhân hội thoại → Dịch vụ Chuyến đi và Điều phối	GET /api/v1/drivers/me/context	—
13	Dịch vụ Chuyến đi và Điều phối → Tác nhân hội thoại	Ngữ cảnh: chuyến, thu nhập, cài đặt	Lưu vào trạng thái phiên
14 ⑤	Tác nhân hội thoại → Ứng dụng tài xế	Hỏi tài xế cần hỗ trợ gì	Sẵn sàng nhận phát ngôn

4.5.3. S3 — Xử lý một lượt hội thoại (Tác nhân hội thoại giọng nói)



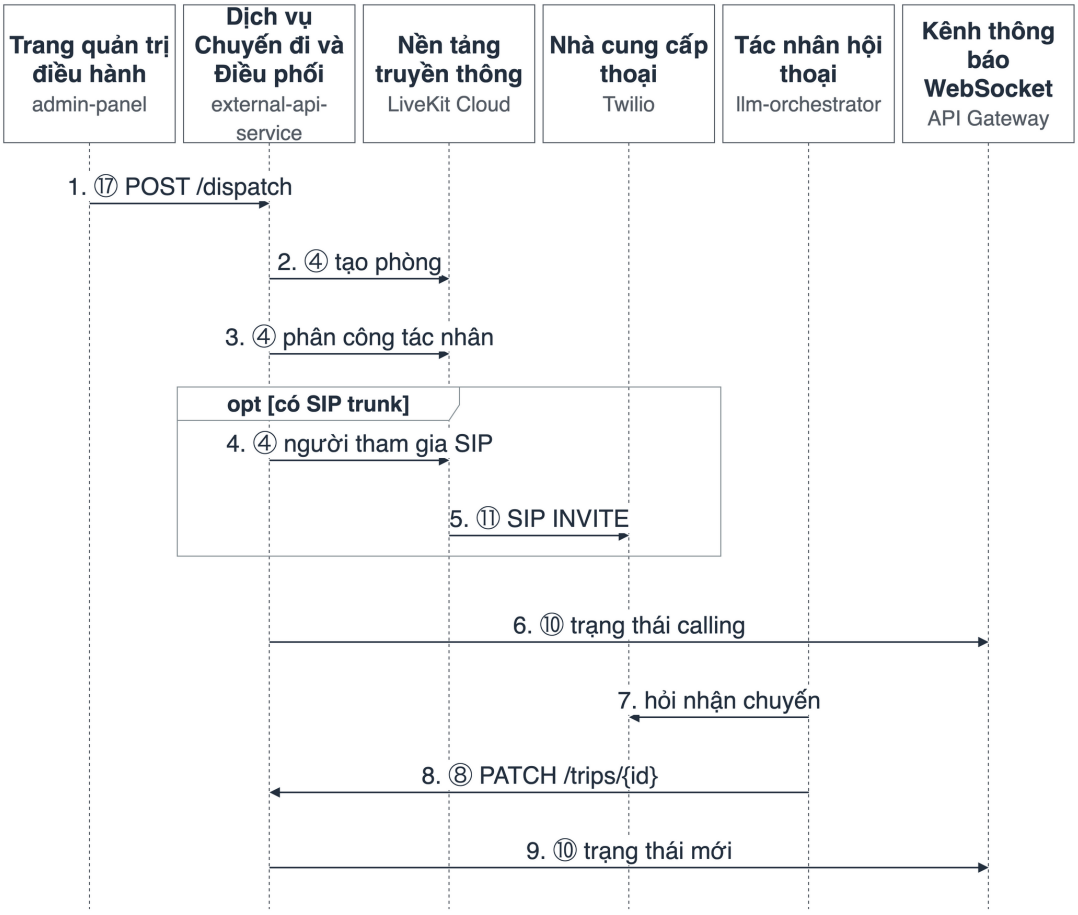
Hình 4.4. Sequence S3: xử lý một lượt hội thoại có gọi công cụ, câu đệm và dự phòng nhà cung cấp

Bảng 4.8. Các bước của sequence S3 (ví dụ tài xế yêu cầu cập nhật trạng thái đã đón khách)

Bước	Từ → Đến	Thông điệp	Ghi chú
1 ⑤⑥	Ứng dụng tài xế → Tác nhân hội thoại	Luồng âm thanh phát ngôn của tài xế	—

Bước	Từ → Đến	Thông điệp	Ghi chú
2 ⑦	Tác nhân hội thoại → Nhà cung cấp STT	Nhận dạng giọng nói; phát hiện kết thúc phát ngôn	Nhà cung cấp chính lỗi hoặc quá 5 giây: chuyển sang nhà cung cấp dự phòng
3	Tác nhân hội thoại	Bắt đầu đếm thời gian cho câu đệm	—
4 ⑦	Tác nhân hội thoại → Nhà cung cấp LLM	Gửi lịch sử hội thoại, lời nhắc hệ thống và lược đồ công cụ của loại phiên	Cơ chế dự phòng như bước 2
5	Tác nhân hội thoại → Ứng dụng tài xế	Tùy chọn: sau 2 giây chưa có âm thanh trả lời thì phát câu đệm một lần	Hủy nếu câu trả lời thật đã bắt đầu
6	Nhà cung cấp LLM → Tác nhân hội thoại	Yêu cầu gọi công cụ update_trip_status với tham số trạng thái	—
7 ⑧	Tác nhân hội thoại → Dịch vụ Chuyến đi và Điều phối	PATCH /api/v1/trips/{tripId}, thân status; thời gian chờ 8 giây	API lỗi: tác nhân thông báo không cập nhật được, phiên tiếp tục
8 ⑨	Dịch vụ Chuyến đi và Điều phối → DynamoDB trips	Ghi trạng thái mới	Trước khi ghi: kiểm tra trạng thái hợp lệ và tài xế cách điểm đón không quá 1 000 m (mặc định); sai: 409
9	Dịch vụ Chuyến đi và Điều phối → Tác nhân hội thoại	200: chuyển sau cập nhật	—
10 ⑦	Tác nhân hội thoại → Nhà cung cấp LLM, TTS	Sinh câu xác nhận ngắn và tổng hợp giọng nói	Chỉ xác nhận sau khi API thành công
11 ⑤	Tác nhân hội thoại → Ứng dụng tài xế	Phát âm thanh trả lời	Độ trễ phản hồi đo từ bước 2 đến bước này

4.5.4. S4 — Mời nhận chuyến qua cuộc gọi điện thoại (Dịch vụ Chuyến đi và Điều phối)



Hình 4.5. Sequence S4: mời tài xế nhận chuyến qua cuộc gọi điện thoại

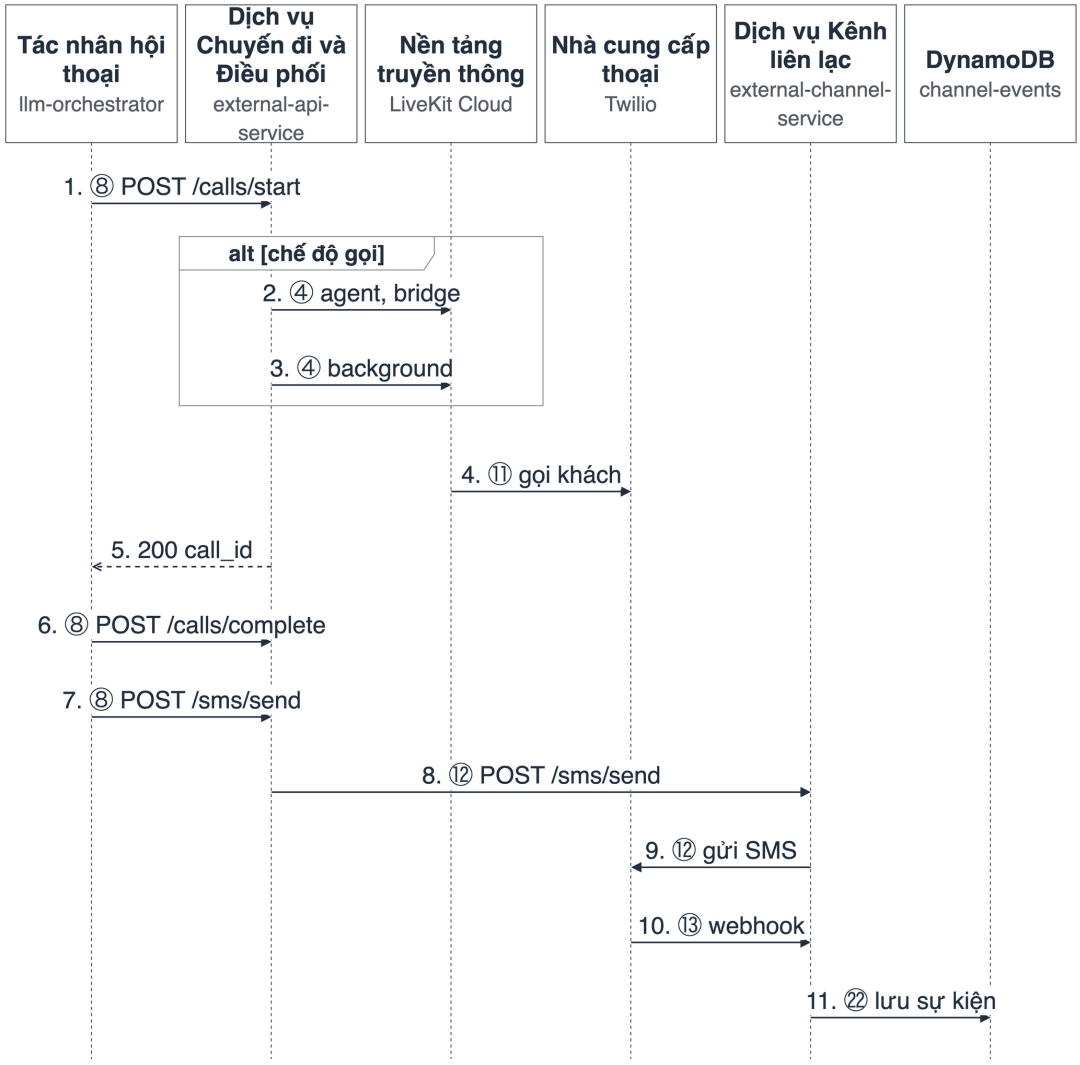
Bảng 4.9. Các bước của sequence S4

Bước	Từ → Đến	Thông điệp	Ghi chú
1 ⑰	Trang quản trị điều hành → Dịch vụ Chuyến đi và Điều phối	POST /api/v1/trips/{tripId}/dispatch	Trạng thái chuyến không hợp lệ: 409; thiếu số tài xế: 400
2 ④	Dịch vụ Chuyến đi và Điều phối → LiveKit Cloud	Tạo phòng driver-{số}-{thời điểm} với metadata chuyến và sip_identity	—
3 ④	Dịch vụ Chuyến đi và Điều phối → LiveKit Cloud	Phân công tác nhân cho phòng	Lỗi phân công không làm dừng luồng
4 ④	Dịch vụ Chuyến đi và Điều phối → LiveKit Cloud	Tạo người tham gia SIP	Chỉ khi đã cấu hình SIP trunk
5 ⑪	LiveKit Cloud → Twilio	SIP INVITE tới điện thoại tài xế	Chỉ khi đã cấu hình SIP trunk

Bước	Từ → Đến	Thông điệp	Ghi chú
6 ⑩	Dịch vụ Chuyến đi và Điều phối → Ứng dụng tài xế (WebSocket)	Trạng thái calling, thông báo đẩy	—
7	Tác nhân hội thoại → điện thoại tài xế (qua Twilio)	Sau khi tài xế nhấc máy: đọc điểm đón, hỏi có nhận chuyến không	Phiên chỉ có confirm_trip, reject_trip
8 ⑧	Tác nhân hội thoại → Dịch vụ Chuyến đi và Điều phối	PATCH /api/v1/trips/{tripId}, status = confirmed hoặc rejected	Không nghe rõ: hỏi lại
9 ⑩	Dịch vụ Chuyến đi và Điều phối → Ứng dụng tài xế (WebSocket)	Thông báo trạng thái mới	—

Khi tài xế đang có phiên trợ lý mở trong ứng dụng, chuyến mới được thông báo vào phòng hiện có thay vì tạo cuộc gọi điện thoại; nếu không có phiên, thông báo được lưu tạm và phát khi tài xế mở trợ lý lần sau.

4.5.5. S5 — Gọi khách hàng và gửi tin nhắn (Dịch vụ Chuyến đi và Điều phối, Dịch vụ Kênh liên lạc)



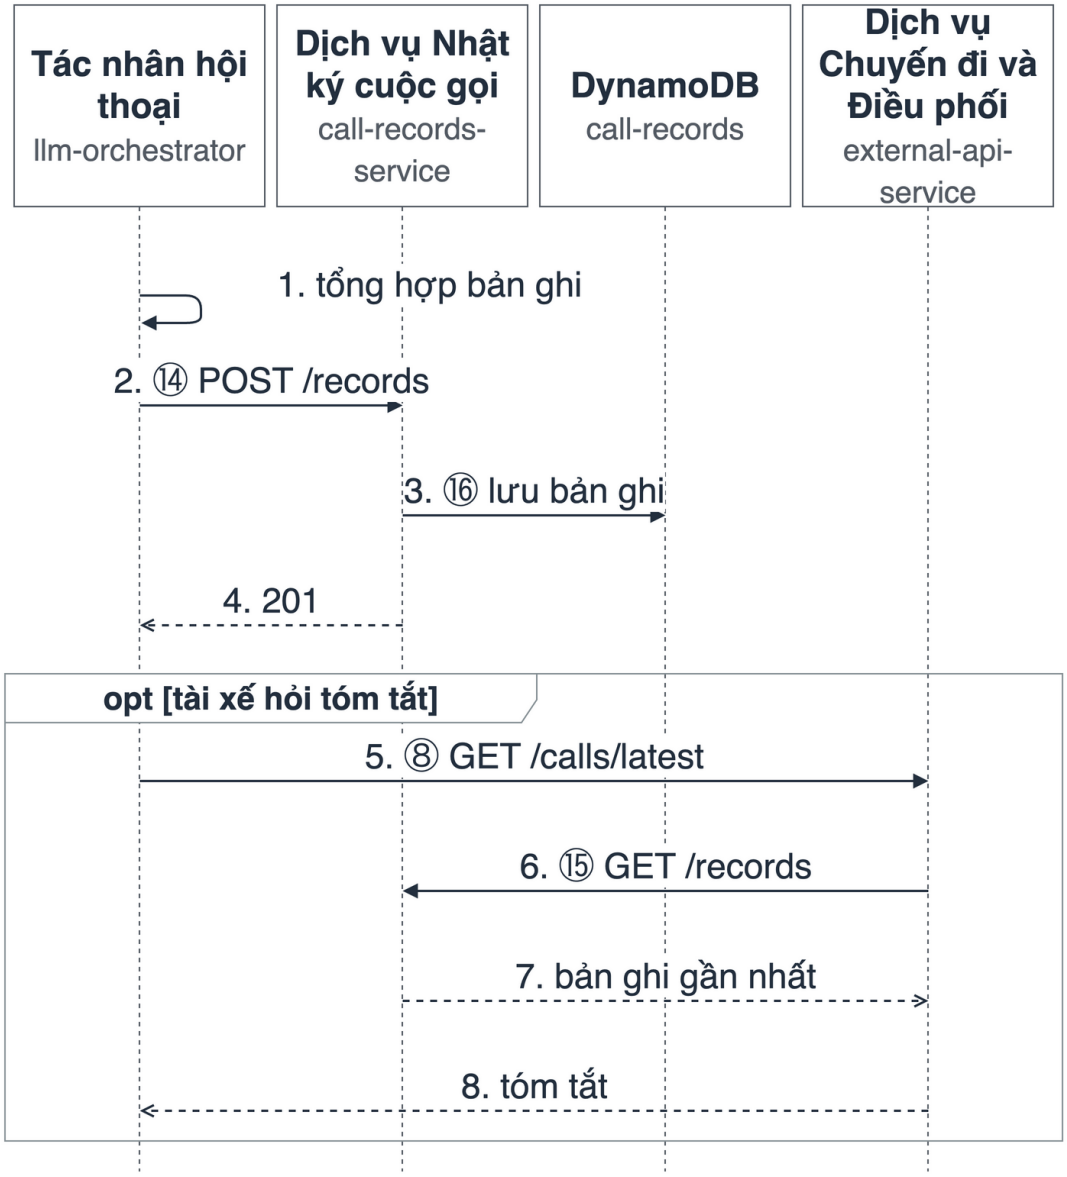
Hình 4.6. Sequence S5: gọi khách hàng theo ba chế độ và gửi tin nhắn SMS

Bảng 4.10. Các bước của sequence S5

Bước	Từ → Đến	Thông điệp	Ghi chú
1 ⑧	Tác nhân hội thoại → Dịch vụ Chuyến đi và Điều phối	POST /api/v1/calls/start, thân gồm driverId, tripId, mode, roomName, lang; thời gian chờ 25 giây	Số ngoài chuyến: xác nhận trước; chuyến không có số khách: 400
2 ④	Dịch vụ Chuyến đi và Điều phối → LiveKit Cloud	Chế độ agent, bridge: tạo người tham gia SIP trong chính phòng của tài xế	Tài xế nghe được cuộc gọi
3 ④	Dịch vụ Chuyến đi và Điều phối → LiveKit Cloud	Chế độ background: tạo phòng riêng custcall-…, quay số SIP, phân công tác nhân riêng	Không chiếm kênh âm thanh của tài xế

Bước	Từ → Đến	Thông điệp	Ghi chú
4 ⑪	LiveKit Cloud → Twilio	Quay số SIP tới điện thoại khách	—
5	Dịch vụ Chuyến đi và Điều phối → Tác nhân hội thoại	200: call_id, trạng thái, chế độ	—
6 ⑧	Tác nhân hội thoại → Dịch vụ Chuyến đi và Điều phối	POST /api/v1/calls/complete (kết thúc cuộc gọi nền)	Tóm tắt gửi về phòng của tài xế
7 ⑧	Tác nhân hội thoại → Dịch vụ Chuyến đi và Điều phối	POST /api/v1/sms/send	Lỗi gửi: tác nhân thông báo thất bại (Bảng 5.3)
8 ⑫	Dịch vụ Chuyến đi và Điều phối → Dịch vụ Kênh liên lạc	POST /api/v1/sms/send	—
9 ⑫	Dịch vụ Kênh liên lạc → Twilio	Gửi SMS	—
10 ⑬	Twilio → Dịch vụ Kênh liên lạc	Webhook trạng thái	—
11 ㉒	Dịch vụ Kênh liên lạc → DynamoDB channel-events	Lưu sự kiện webhook và kết quả gửi SMS	Lỗi lưu chỉ ghi nhật ký, không làm hỏng webhook

4.5.6. S6 — Ghi nhật ký và tóm tắt cuộc gọi (Dịch vụ Nhật ký cuộc gọi)



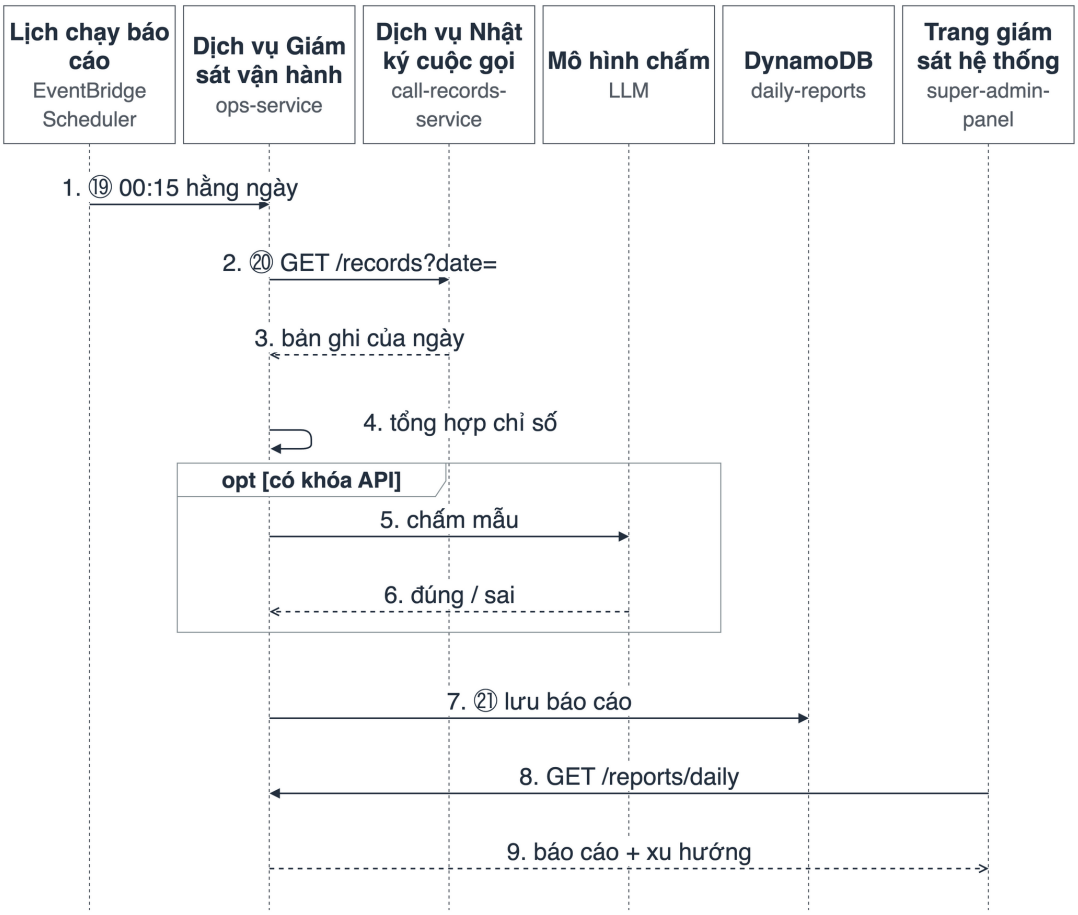
Hình 4.7. Sequence S6: lưu bản ghi hội thoại và tra cứu tóm tắt cuộc gọi

Bảng 4.11. Các bước của sequence S6

Bước	Từ → Đến	Thông điệp	Ghi chú
1	Tác nhân hội thoại	Khi phiên kết thúc: tổng hợp bản ghi hội thoại và tóm tắt	—
2 ⑭	Tác nhân hội thoại → Dịch vụ Nhật ký cuộc gọi	POST /api/v1/records; thời gian chờ 10 giây, thử lại có giới hạn	Dịch vụ lỗi hoặc chưa cấu hình: bản ghi ghi vào nhật ký tác nhân, phiên không bị ảnh hưởng

Bước	Từ → Đến	Thông điệp	Ghi chú
3 ⑯	Dịch vụ Nhật ký cuộc gọi → DynamoDB call-records	Lưu bản ghi	—
4	Dịch vụ Nhật ký cuộc gọi → Tác nhân hội thoại	201	—
5 ⑧	Tác nhân hội thoại → Dịch vụ Chuyến đi và Điều phối	Khi tài xế hỏi tóm tắt: GET /api/v1/calls/latest	—
6 ⑮	Dịch vụ Chuyến đi và Điều phối → Dịch vụ Nhật ký cuộc gọi	GET /api/v1/records?caller={số tài xế}&limit=1	—
7	Dịch vụ Nhật ký cuộc gọi → Dịch vụ Chuyến đi và Điều phối	Bản ghi gần nhất	Chưa có bản ghi: thông báo chưa có
8	Dịch vụ Chuyến đi và Điều phối → Tác nhân hội thoại	Tóm tắt cuộc gọi	Tác nhân đọc tóm tắt ngắn cho tài xế

4.5.7. S7 — Lập báo cáo vận hành ngày (Dịch vụ Giám sát vận hành)



Hình 4.8. Sequence S7: lập báo cáo vận hành ngày từ bản ghi hội thoại và chỉ số phiên

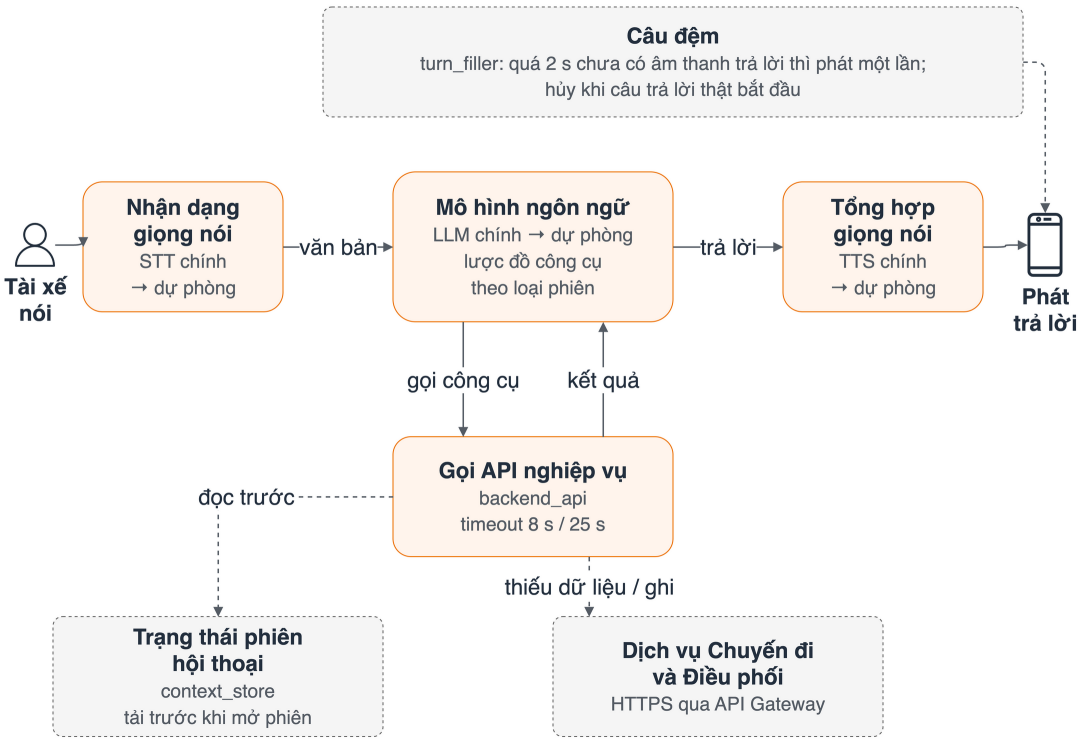
Bảng 4.12. Các bước của sequence S7

Bước	Từ → Đến	Thông điệp	Ghi chú
1 ⑲	EventBridge Scheduler → Dịch vụ Giám sát vận hành	Sự kiện theo lịch lúc 00:15 giờ Việt Nam (source = ops.schedule)	Người vận hành cũng có thể gọi POST /api/v1/ reports/daily/{date}/ rebuild
2 ⑳	Dịch vụ Giám sát vận hành → Dịch vụ Nhật ký cuộc gọi	GET /api/v1/records?date= {ngày}&limit=500, lặp theo con trỏ phân trang	Dùng chỉ mục record_ date-started_at-index
3	Dịch vụ Nhật ký cuộc gọi → Dịch vụ Giám sát vận hành	Bản ghi: lời thoại, loại phiên, chỉ số phiên	—
4	Dịch vụ Giám sát vận hành	Tổng hợp: số phiên, số tài xế, độ trễ trung bình/P50/P95, tỷ lệ công cụ thành công, tỷ lệ API lỗi, lỗi theo loại	Phiên không có chỉ số chỉ tính vào phần hoạt động
5	Dịch vụ Giám sát vận hành → Mô hình chấm (LLM)	Chấm một mẫu cố định theo ngày các cặp (câu tài xế, câu trả lời)	Chỉ khi có khóa API; không có thì ghi chú trong báo cáo
6	Mô hình chấm → Dịch vụ Giám sát vận hành	Kết quả: correct, incorrect hoặc unclear	—
7 ㉑	Dịch vụ Giám sát vận hành → DynamoDB daily-reports	Lưu báo cáo theo khóa report_date	Lập lại thì ghi đè
8	Trang giám sát hệ thống → Dịch vụ Giám sát vận hành	GET /api/v1/reports/daily?date= hoặc ?from=&to=	Chỉ tài khoản quản trị hệ thống
9	Dịch vụ Giám sát vận hành → Trang giám sát hệ thống	Báo cáo ngày và xu hướng 7 ngày	Hình 5.6

4.6. Thiết kế xử lý một lượt hội thoại

4.6.1. Chuỗi xử lý và câu đệm

Mỗi phát ngôn của tài xế đi qua cùng một chuỗi xử lý: STT, LLM kèm gọi công cụ và TTS (Hình 4.9). Khi phản hồi chưa bắt đầu phát sau 2 giây kể từ lúc tài xế kết thúc phát ngôn, tác nhân phát một câu đệm ngắn như "Đợi mình một chút". Câu đệm không chứa dữ liệu nghiệp vụ và bị hủy nếu câu trả lời thật đã bắt đầu. Tác nhân tải trước ngữ cảnh phiên và khởi động trước các thành phần (gói ngôn ngữ, mô hình phát hiện giọng nói) khi tiến trình khởi động để giảm độ trễ của lượt đầu tiên.



Hình 4.9. Chuỗi xử lý một lượt hội thoại: STT, LLM kèm gọi công cụ, TTS, câu đệm và dự phòng nhà cung cấp

4.6.2. Trạng thái phiên hội thoại

Trạng thái phiên (session state) là dữ liệu tác nhân giữ trong bộ nhớ của mình suốt một phiên hội thoại và bị xóa khi phiên kết thúc; dữ liệu gốc vẫn nằm ở các dịch vụ nghiệp vụ. Sau bước tải trước, trạng thái phiên gồm các nhóm thông tin trong Bảng 4.13. Khi trả lời, công cụ đọc dữ liệu trong trạng thái phiên trước; nếu thiếu thì gọi API để làm mới. Tác nhân không được tự tạo dữ liệu nghiệp vụ không có trong trạng thái phiên hoặc trong kết quả API.

Bảng 4.13. Nội dung trạng thái phiên hội thoại

Nhóm	Nội dung	Mục đích
Hồ sơ và cài đặt	Chế độ gọi khách mặc định, tùy chọn kích hoạt	Chọn chế độ gọi; cá nhân hóa
Chuyến đi	Chuyến sắp tới, chuyến hiện tại, lịch sử gần	Trả lời câu hỏi về chuyến; cập nhật tiến độ
Thu nhập	Thu nhập trong ngày, tóm tắt theo kỳ	Trả lời câu hỏi thu nhập
Cuộc gọi	Trạng thái đang gọi, cuộc gọi gần nhất	Tránh mở cuộc gọi chồng; tóm tắt cuộc gọi

Nhóm	Nội dung	Mục đích
Hành động chờ xác nhận	Hủy chuyến đang chờ xác nhận; số điện thoại chờ xác nhận; hành động tác nhân vừa đề xuất	Thực hiện xác nhận hai bước

4.6.3. Phân loại phiên và tập công cụ

Tác nhân xác định loại phiên từ tên phòng và metadata, mỗi loại phiên có tập công cụ riêng (Bảng 4.14). Thiết kế này hiện thực FR-L03 và giảm rủi ro chọn nhầm công cụ, chẳng hạn trong phiên mời nhận chuyến qua điện thoại, tác nhân không có công cụ hủy chuyến đang chạy.

Bảng 4.14. Loại phiên và tập công cụ

Loại phiên	Nhận biết	Tập công cụ
Tài xế trong ứng dụng	Phòng driver-… không có metadata chuyến	39 công cụ của tài xế
Mời nhận chuyến	Phòng driver-… có metadata chuyến và sip_identity	confirm_trip, reject_trip
Gọi khách nền	Phòng custcall-…	Tác nhân riêng trao đổi với khách hàng
Khách hàng	Phòng customer-…	7 công cụ của khách hàng

Với ba chế độ gọi khách (Bảng 3.2): ở chế độ tác nhân gọi thay, khách được kết nối vào phòng của tài xế và tác nhân trao đổi với khách; ở chế độ nói trực tiếp, tác nhân ngừng phát âm cho tới khi tài xế nói cụm từ kết thúc; ở chế độ gọi nền, cuộc gọi diễn ra trong phòng riêng và tóm tắt được gửi về phòng của tài xế khi kết thúc (sequence S5).

4.7. Thiết kế cho khả năng phục hồi, bảo mật và khả năng quan sát

Bảng 4.15 tổng hợp các cơ chế thiết kế đáp ứng NFR-04, NFR-05, ràng buộc CON-04 và yêu cầu FR-O01.

Bảng 4.15. Cơ chế thiết kế cho khả năng phục hồi, bảo mật và khả năng quan sát

Cơ chế	Mô tả	Yêu cầu
Thời gian chờ khi gọi API	Mọi lời gọi HTTP của tác nhân có thời gian chờ (8 giây với API chuyển, 25 giây với khởi tạo cuộc gọi); lỗi được chuyển thành câu thông báo ngắn	NFR-04
Dự phòng nhà cung cấp AI	STT, LLM, TTS được cấu hình dưới dạng chuỗi nhà cung cấp chính và dự phòng; nhà cung cấp chính lỗi hoặc quá thời gian chờ thì chuyển sang dự phòng; sự kiện chuyển đổi được ghi nhật ký	NFR-04
Cô lập dịch vụ phụ trợ	Lỗi ghi bản ghi cuộc gọi, lỗi gửi tin nhắn hoặc lỗi phân công tác nhân không làm dừng luồng hội thoại chính	NFR-04
Tự khôi phục bản sao tác nhân	ECS duy trì số bản sao mong muốn, tự thay thế tác vụ bị dừng; phòng còn nhưng mất tác nhân thì được phân công lại khi tài xế kết nối	NFR-04
Xử lý im lặng	Sau khoảng 15 giây im lặng, tác nhân hỏi tài xế còn đó không; tối đa hai lần rồi kết thúc lịch sự để giải phóng phiên	FR-L02, NFR-04
Định danh tập trung	Chỉ Dịch vụ Định danh phát hành JWT; các dịch vụ xác minh bằng khóa bí mật dùng chung; tác nhân dùng token dịch vụ riêng	NFR-05, CON-03
Bảo vệ bí mật	Tham số bí mật trong hạ tầng dạng mã được đánh dấu ẩn, không ghi vào mã nguồn; vai trò IAM riêng từng dịch vụ	NFR-05
Nhật ký gắn mã phòng	Mọi dòng nhật ký gắn mã phòng và mã hội thoại để theo dõi một yêu cầu xuyên qua các dịch vụ; mức độ che dữ liệu cá nhân trong nhật ký được kiểm tra ở Chương 6	CON-04, NFR-05
Chỉ số phiên và báo cáo ngày	Tác nhân gửi chỉ số chất lượng của phiên kèm bản ghi hội thoại; Dịch vụ Giám sát vận hành tổng hợp theo ngày để phát hiện suy giảm độ trễ, lỗi và tỷ lệ trả lời đúng	NFR-04, FR-O01

4.8. Thiết kế trải nghiệm trên ứng dụng tài xế

Ở mức thiết kế, ứng dụng tài xế cần:

- Nút mở trợ lý dễ thấy, thể hiện rõ trạng thái đang kết nối, đang nghe, đang xử lý và đang nói.
- Lời thoại hiển thị đồng bộ với lời nói để tài xế xem lại khi dừng xe.
- Từ khóa đánh thức chỉ để mở phiên, không thay thế khâu hiểu ngôn ngữ của tác nhân.
- Cài đặt chế độ gọi khách mặc định để trợ lý không phải hỏi lại mỗi lần khi đang lái.

Các thiết kế này phục vụ NFR-01.

4.9. Đối chiếu yêu cầu với thiết kế

Bảng 4.16 liên kết từng yêu cầu phi chức năng (và yêu cầu giám sát vận hành) với quyết định thiết kế và vị trí trên Hình 4.1, làm căn cứ cho các kịch bản đánh giá ở Chương 6.

Bảng 4.16. Đối chiếu yêu cầu phi chức năng với thiết kế

Yêu cầu	Quyết định thiết kế	Thành phần / luồng trên Hình 4.1	Kịch bản đánh giá
NFR-01 Usability	Phân loại phiên; xác nhận hai bước; phản hồi ngắn	Tác nhân hội thoại	Danh mục kiểm tra hành vi khi lái
NFR-02 Performance	ADR-02; tải trước ngữ cảnh; tác nhân chạy dài hạn trên Fargate	Luồng ⑤⑥⑦⑧	Đo P50, P95 độ trễ phản hồi
NFR-03 Scalability	ADR-01; nhân bản tác nhân; Lambda và DynamoDB tự mở rộng	Tác nhân hội thoại (ECS), các Lambda	SC-01 đến SC-03
NFR-04 Resilience	Cô lập dịch vụ; dự phòng nhà cung cấp; thời gian chờ; tự khôi phục	Luồng ⑦⑧⑭	RS-01 đến RS-05
NFR-05 Security	Định danh tập trung; bí mật ẩn; IAM riêng	Luồng ①②; Cross-cutting	Danh mục kiểm tra bảo mật
FR-O01, FR-O02	Báo cáo ngày do Dịch vụ Giám sát vận hành sở hữu; lịch chạy EventBridge	Luồng ⑲⑳㉑	UC11

Kết luận chương

Chương 4 đã lập luận lựa chọn kiến trúc microservices từ các yêu cầu phi chức năng, trình bày kiến trúc tổng thể trên AWS với các luồng được đánh số, phân chia hệ thống thành các dịch vụ theo năng lực nghiệp vụ, mô tả luồng hoạt động chính của từng dịch vụ bằng bảy sequence diagram, thiết kế xử lý một lượt hội thoại và các cơ chế bảo đảm khả năng phục hồi, bảo mật và khả năng quan sát. Chương 5 trình bày hiện thực các thiết kế này.

Chương 5. Triển khai

Chương này trình bày hiện thực nguyên mẫu theo thiết kế ở Chương 4: công nghệ sử dụng, tổ chức mã nguồn, hiện thực tác nhân hội thoại, các dịch vụ backend và ứng dụng tài xế, cấu hình triển khai trên AWS, và bảng đối chiếu quyết định thiết kế với vị trí mã nguồn để phục vụ phân tích kết quả ở Chương 6.

5.1. Công nghệ sử dụng

Công nghệ được chọn theo vai trò của từng lớp trong kiến trúc (Bảng 5.1).

Bảng 5.1. Công nghệ sử dụng theo lớp kiến trúc

Lớp	Công nghệ	Vai trò
Máy khách	React Native (Expo), TypeScript, Tamagui; React (Vite) cho trang web	Ứng dụng tài xế, ứng dụng khách hàng, trang quản trị
Hội thoại AI	Python, LiveKit Agents	Tác nhân hội thoại: STT, LLM kèm gọi công cụ, TTS
Microservices	Node.js 20, TypeScript, Express, serverless-http	Các dịch vụ nghiệp vụ, chạy cục bộ bằng Express và trên AWS Lambda
Truyền thông thời gian thực	LiveKit Cloud (WebRTC, SIP), Twilio (SIP trunk, SMS)	Phòng hội thoại, cuộc gọi ra mạng điện thoại
Dữ liệu	Amazon DynamoDB; Redis (tùy chọn)	Dữ liệu nghiệp vụ; trạng thái phiên ngắn hạn
Truy xuất tri thức	LlamaIndex, tài liệu hướng dẫn dạng Markdown	Trả lời câu hỏi về cách sử dụng ứng dụng
Hạ tầng dạng mã	AWS SAM, AWS CloudFormation, Docker	Định nghĩa và triển khai tài nguyên AWS

Nhà cung cấp STT, LLM và TTS được chọn bằng cấu hình thông qua lớp trừu tượng nhà cung cấp của tác nhân (mục 5.3.4), nên việc thay nhà cung cấp không làm thay đổi kiến trúc.

5.2. Tổ chức mã nguồn

Mã nguồn được tổ chức thành một kho đơn (monorepo) gồm ba nhánh: src/backend/ chứa các dịch vụ, src/frontend/ chứa ứng dụng và trang quản trị, src/e2e/ chứa kịch bản kiểm thử đầu cuối; thư mục infra/ chứa hạ tầng dạng mã. Bảng 5.2 liệt

kê các thư mục chính; bảng ánh xạ tên thư mục với tên thành phần dùng trong luận văn ở Phụ lục G.

Bảng 5.2. Tổ chức mã nguồn

Nhánh	Thư mục	Thành phần
Backend	llm-orchestrator	Tác nhân hội thoại giọng nói
Backend	identity-service	Dịch vụ Định danh
Backend	external-api-service	Dịch vụ Chuyến đi và Điều phối
Backend	external-channel-service	Dịch vụ Kênh liên lạc
Backend	call-records-service	Dịch vụ Nhật ký cuộc gọi
Backend	ops-service	Dịch vụ Giám sát vận hành
Frontend	driver-app	Ứng dụng tài xế
Frontend	customer-app, customer-web	Ứng dụng khách hàng
Frontend	admin-panel	Trang quản trị điều hành
Frontend	super-admin-panel	Trang giám sát hệ thống
Kiểm thử	e2e	Kịch bản kiểm thử đầu cuối và dữ liệu mẫu
Hạ tầng	infra	Template SAM/CloudFormation và kịch bản triển khai cho từng dịch vụ

Mỗi dịch vụ Node.js có hai điểm vào: src/local.ts chạy máy chủ Express khi phát triển cục bộ và src/index.ts bọc cùng ứng dụng Express thành hàm Lambda. Nhờ đó, cùng một mã nguồn chạy được ở cả hai môi trường.

5.3. Hiện thực tác nhân hội thoại giọng nói

5.3.1. Khởi tạo phiên và phân loại phòng

Điểm vào của tác nhân (app/agent/session.py) phân loại phiên theo tên phòng và metadata (Bảng 4.14): phòng driver-… là phiên tài xế, có metadata chuyến thì là phiên mời nhận chuyến; phòng custcall-… là cuộc gọi khách nền; phòng customer-… là phiên khách hàng. Tập công cụ tương ứng được định nghĩa trong gói ngôn ngữ (voicebot/locales/vn/agent.py, voicebot/locales/en/agent.py).

Với phiên tài xế trong ứng dụng, tác nhân đăng ký phiên với Dịch vụ Chuyến đi và Điều phối (chạy song song, lỗi chỉ ghi nhật ký), phát lời chào cố định, sau đó

tải trước ngữ cảnh tài xế vào trạng thái phiên (processors/context_store.py) rồi hỏi tài xế cần hỗ trợ gì (sequence S2). Khi tiến trình khởi động, tác nhân nạp trước gói ngôn ngữ và mô hình phát hiện giọng nói để giảm độ trễ của phiên đầu tiên.

5.3.2. Xử lý lượt hội thoại và câu đệm

Mọi phát ngôn của tài xế được đưa qua mô hình ngôn ngữ kèm lược đồ công cụ của loại phiên. Mô-đun nhận dạng ý định (processors/intent_classify.py, processors/spoken_intent.py) chỉ gán nhãn cho phát ngôn để loại bỏ mảnh nhận dạng thừa ở cuối câu và nhận biết câu xác nhận cho hành động đang chờ; mô-đun này không gọi công cụ và không quyết định câu trả lời. Nhánh gọi thẳng công cụ theo ý định từng được dùng trong đợt đo 05–06/09/2026 (Chương 6) đã bị loại khỏi mã nguồn.

Câu đệm được hiện thực trong processors/turn_filler.py với ngưỡng FILLER_DELAY_S = 2.0 giây tính từ lúc tài xế kết thúc phát ngôn; câu đệm phát tối đa một lần mỗi lượt và bị hủy nếu câu trả lời thật đã bắt đầu. Hành động chờ xác nhận (processors/pending_action.py) lưu thao tác tác nhân vừa đề xuất; khi tài xế xác nhận ("được", "gọi đi"), tác nhân thực thi thao tác đó.

5.3.3. Gọi API nghiệp vụ

Mọi thao tác đọc và ghi dữ liệu nghiệp vụ đi qua mô-đun services/backend_api.py. Mô-đun dùng một HTTP client dùng chung trong mỗi phiên (tối đa 20 kết nối giữ sống), đặt thời gian chờ cho từng lời gọi (8 giây với API chuyến đi, 25 giây với khởi tạo cuộc gọi), gắn token dịch vụ vào tiêu đề và ghi nhật ký thời gian, mã trạng thái của mỗi lời gọi. Lỗi API được công cụ chuyển thành câu thông báo ngắn; tác nhân chỉ xác nhận thao tác sau khi API trả về thành công. Tác nhân không có kết nối cơ sở dữ liệu (CON-01).

Bảng 5.3 minh họa một lượt thực tế trích từ nhật ký tác nhân ngày 06/09/2026, trong đó yêu cầu gửi SMS thất bại ở phía máy chủ. Lượt này cho thấy cách một câu nói đi qua các khâu, và cách lỗi của một dịch vụ phụ trợ được xử lý mà không làm dừng phiên.

Bảng 5.3. Một lượt thực tế: tài xế nhờ nhắn tin cho khách khi dịch vụ gửi SMS gặp lỗi

Bước	Khâu	Dữ liệu thực tế trong nhật ký
1	Nhận dạng giọng nói (STT)	"Nhắn cho khách là 15 phút nữa tôi đến đón."; phát hiện kết thúc câu sau 1,54 giây
2	Mô hình ngôn ngữ (LLM)	Chọn công cụ send_sms_to_customer với nội dung "Tôi sẽ đến đón bạn trong khoảng 15 phút nữa."; thời gian sinh token đầu 3,48 giây
3	Gọi API nghiệp vụ	POST /api/v1/sms/send tới Dịch vụ Chuyến đi và Điều phối; việc chuyển tiếp sang Dịch vụ Kênh liên lạc thất bại nên dịch vụ trả mã 503 sau 1,31 giây
4	Xử lý lỗi trong công cụ	Công cụ bắt lỗi HTTP, ghi nhật ký ok=false, trả câu thông báo lỗi soạn sẵn (ERR_SMS_SEND_FAILED) thay vì để mô hình tự diễn đạt
5	Tổng hợp giọng nói (TTS)	Tác nhân nói "Không thể gửi tin nhắn lúc này. Vui lòng thử lại."; âm thanh đầu tiên sau 0,17 giây
6	Tiếp tục phiên	Phiên không bị ngắt; tài xế tiếp tục cập nhật trạng thái chuyến, báo khách không có mặt, hỏi thu nhập và đặt nhắc việc trong các lượt sau

Lượt này chậm (khoảng 5 giây từ lúc tài xế dứt câu) chủ yếu do thời gian mô hình ngôn ngữ sinh token đầu; nhật ký được ghi khi nguyên mẫu còn nhánh rút gọn theo ý định, nhưng riêng lượt này đã đi qua mô hình ngôn ngữ như thiết kế hiện hành.

5.3.4. Lớp trừu tượng và dự phòng nhà cung cấp AI

Nhà cung cấp STT, LLM, TTS được tạo qua hàm factory trong app/providers/__init__.py theo biến cấu hình STT_PROVIDER, LLM_PROVIDER, TTS_PROVIDER. Khi cấu hình thêm nhà cung cấp dự phòng (STT_FALLBACK, LLM_FALLBACK, TTS_FALLBACK), factory tạo chuỗi nhà cung cấp và bọc bằng FallbackAdapter của LiveKit Agents (app/providers/fallback.py): mỗi lần thử với STT và LLM có thời gian chờ 5 giây, nhà cung cấp lỗi được đánh dấu không khả dụng và yêu cầu chuyển sang nhà cung cấp kế tiếp; sự kiện chuyển đổi và phục hồi được ghi nhật ký với nhãn provider_fallback. Nhà cung cấp dự phòng dùng mô hình và giọng mặc định của chính nó để tránh gửi tên mô hình không tương thích.

5.3.5. Xử lý im lặng và kết thúc phiên

Tác nhân theo dõi thời gian im lặng của tài xế: sau 15 giây im lặng, tác nhân hỏi tài xế còn đó không; sau hai lần liên tiếp không có phản hồi, tác nhân chào kết thúc

và gọi API kết thúc phiên thoại. Khi phiên kết thúc, tác nhân gửi bản ghi và tóm tắt hội thoại tới Dịch vụ Nhật ký cuộc gọi với thời gian chờ 10 giây và số lần thử lại giới hạn; nếu dịch vụ không khả dụng, bản ghi được ghi vào nhật ký thay vì làm lỗi phiên (sequence S6).

5.3.6. Chỉ số chất lượng của phiên

Mô-đun services/session_metrics.py thu chỉ số của từng phiên để phục vụ báo cáo vận hành ngày (FR-O01). Bộ thu được tạo khi phiên bắt đầu và gắn vào biến ngữ cảnh (ContextVar), nên mọi tác vụ phát sinh sau đó trong phiên đều ghi vào cùng một bộ thu. Nguồn dữ liệu là các sự kiện có cấu trúc sẵn có của tác nhân: độ trễ từng lượt, lời gọi HTTP (mã trạng thái), câu đệm, chuyển nhà cung cấp dự phòng, mọi sự kiện lỗi, và sự kiện function_tools_executed của LiveKit Agents (công cụ đã chạy, có lỗi hay không). Khi phiên kết thúc, ảnh chụp chỉ số (loại phiên, số lượt, mẫu độ trễ, trung bình, P50, P95, số lượt chậm, công cụ thành công và lỗi theo tên, lỗi HTTP theo đường dẫn, số lần dự phòng) được gửi kèm bản ghi hội thoại tới Dịch vụ Nhật ký cuộc gọi. Mẫu độ trễ được gửi nguyên để phân vị của cả ngày được tính đúng, không lấy trung bình của các phân vị.

5.4. Hiện thực các dịch vụ backend

5.4.1. Dịch vụ Chuyến đi và Điều phối

Dịch vụ là nguồn dữ liệu chuẩn cho chuyến đi và là điểm khởi tạo phiên thoại, cuộc gọi. Bảng 5.4 liệt kê các nhóm API phục vụ trợ lý.

Bảng 5.4. Nhóm API của Dịch vụ Chuyến đi và Điều phối phục vụ trợ lý

Nhóm	API	Mục đích
Phiên thoại	POST /api/v1/voice/token, POST /api/v1/voice/end-session, PUT và DELETE /api/v1/drivers/me/session	Cấp token LiveKit, kết thúc phiên, đăng ký phiên đang mở
Ngữ cảnh	GET /api/v1/drivers/me/context	Tải trước chuyến, thu nhập, cài đặt
Chuyến đi	GET /api/v1/drivers/me/trips/upcoming, GET /api/v1/drivers/me/trips/current, PATCH /api/v1/trips/{tripId}, POST /api/v1/trips/{tripId}/dispatch	Tra cứu, cập nhật trạng thái, mời nhận chuyến

Nhóm	API	Mục đích
Sự cố và chờ đón	POST /api/v1/trips/{tripId}/no-show, /issues, /extend-wait	Báo khách không có mặt, báo sự cố, gia hạn chờ
Cuộc gọi, tin nhắn	POST /api/v1/calls/start, POST /api/v1/calls/complete, GET /api/v1/calls/latest, POST /api/v1/sms/send	Gọi khách, kết thúc cuộc gọi nền, tra cứu cuộc gọi, gửi SMS
Thu nhập, trạng thái	GET /api/v1/drivers/me/earnings/today, /earnings/summary; PATCH /api/v1/drivers/me/status	Thu nhập, bật/tắt nhận chuyến
Nhắc việc	POST /api/v1/reminders	Tạo nhắc việc

Cuộc gọi thoại được khởi tạo qua SIP của LiveKit Cloud (services/telephony/livekit.ts) với SIP trunk nối tới Twilio; tin nhắn SMS được chuyển tiếp tới Dịch vụ Kênh liên lạc (services/smsService.ts). Khi có chuyến mới và tài xế đang mở phiên, thông báo được gửi vào phòng hiện có (services/driverReachService.ts); nếu không, thông báo được lưu tạm và phát khi tài xế mở trợ lý. Thông báo đẩy tới ứng dụng dùng thư viện WebSocket khi chạy cục bộ và API Gateway WebSocket khi chạy trên AWS.

5.4.2. Dịch vụ Định danh

Tài xế đăng nhập bằng số điện thoại và mật khẩu (vai trò driver); mật khẩu được lưu dưới dạng băm bcrypt. Dịch vụ phát hành access token và refresh token; giá trị băm của refresh token được lưu để có thể thu hồi. Cài đặt tài xế, trong đó có trường default_customer_call_mode (chế độ gọi khách mặc định), được lưu ở bảng riêng và đưa vào ngữ cảnh phiên.

5.4.3. Dịch vụ Kênh liên lạc, Dịch vụ Nhật ký cuộc gọi và Dịch vụ Giám sát vận hành

– **Dịch vụ Kênh liên lạc:** gửi SMS qua Twilio và tiếp nhận webhook trạng thái, tin nhắn đến từ Twilio. Các webhook của Twilio không yêu cầu JWT; các API còn lại yêu cầu JWT. Sự kiện nhà cung cấp (webhook, lượt quay số, kết quả gửi SMS) được lưu qua một cổng lưu trữ (services/events/store.ts) có hai bộ điều hợp: bảng DynamoDB channel-events khi cấu hình EVENTS_TABLE (môi trường triển khai), tệp JSONL cục bộ khi chạy phát triển. Việc ghi được chờ

xong trước khi trả lời webhook vì trên Lambda, tác vụ còn chạy sau khi trả lời có thể bị dừng; lỗi ghi chỉ được ghi nhật ký.

– **Dịch vụ Nhật ký cuộc gọi:** lưu và truy vấn bản ghi hội thoại (/api/v1/records) trên bảng DynamoDB riêng. Mỗi bản ghi được gán trường record_date (ngày theo giờ Việt Nam) khi lưu; truy vấn GET /api/v1/records?date= dùng chỉ mục phụ record_date-started_at-index, có phân trang bằng con trỏ, và tự chuyển sang quét có lọc khi bảng cũ chưa có chỉ mục. Cấu trúc một bản ghi được trình bày ở Bảng 5.5.

– **Dịch vụ Giám sát vận hành:** thăm dò tình trạng các dịch vụ qua điểm cuối /health, cung cấp nhật ký, cấu hình tác nhân và báo cáo ngày cho trang giám sát hệ thống; chỉ tài khoản quản trị hệ thống được truy cập. Mô-đun báo cáo (services/reports/) gồm hàm tổng hợp thuần, bộ chấm LLM trên mẫu cố định theo ngày (xáo trộn có hạt giống là ngày báo cáo nên lập lại cho cùng kết quả), cổng lưu trữ với bộ điều hợp DynamoDB daily-reports hoặc tệp JSON cục bộ, và API GET /api/v1/reports/daily, POST /api/v1/reports/daily/{date}/rebuild. Trên AWS, hàm Lambda của dịch vụ nhận hai loại sự kiện: yêu cầu HTTP qua API Gateway và sự kiện theo lịch từ EventBridge Scheduler. Vì không đọc được tệp của các dịch vụ khác, trên AWS dịch vụ đọc nhật ký từ CloudWatch Logs, kiểm tra tác nhân qua số tác vụ ECS đang chạy, và dùng ảnh chụp cấu hình tác nhân được đóng gói lúc triển khai.

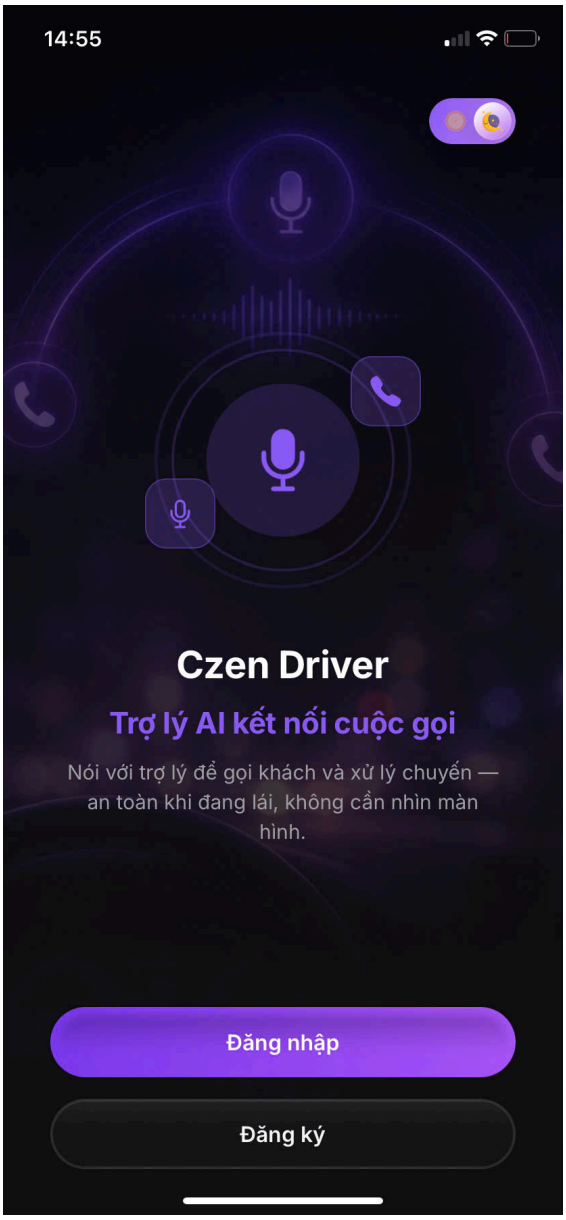
Bảng 5.5. Cấu trúc một bản ghi trong bảng call-records (giá trị ví dụ lấy từ phiên ngày 06/09/2026, số điện thoại đã che)

Trường	Ý nghĩa	Giá trị ví dụ
call_id	Mã phiên, trùng tên phòng hội thoại; khóa chính	driver-0888xxx798-509f5d25-…
caller	Số điện thoại tài xế hoặc khách	0888xxx798
started_at, ended_at, duration_seconds	Thời điểm bắt đầu, kết thúc và thời lượng phiên	06/09/2026 19:07:45–19:13:41, 355 giây
record_date	Ngày theo giờ Việt Nam, dùng cho chỉ mục truy vấn theo ngày	2026-09-06 (bản ghi ví dụ tạo trước khi có trường này; dịch vụ tính từ started_at khi truy vấn)

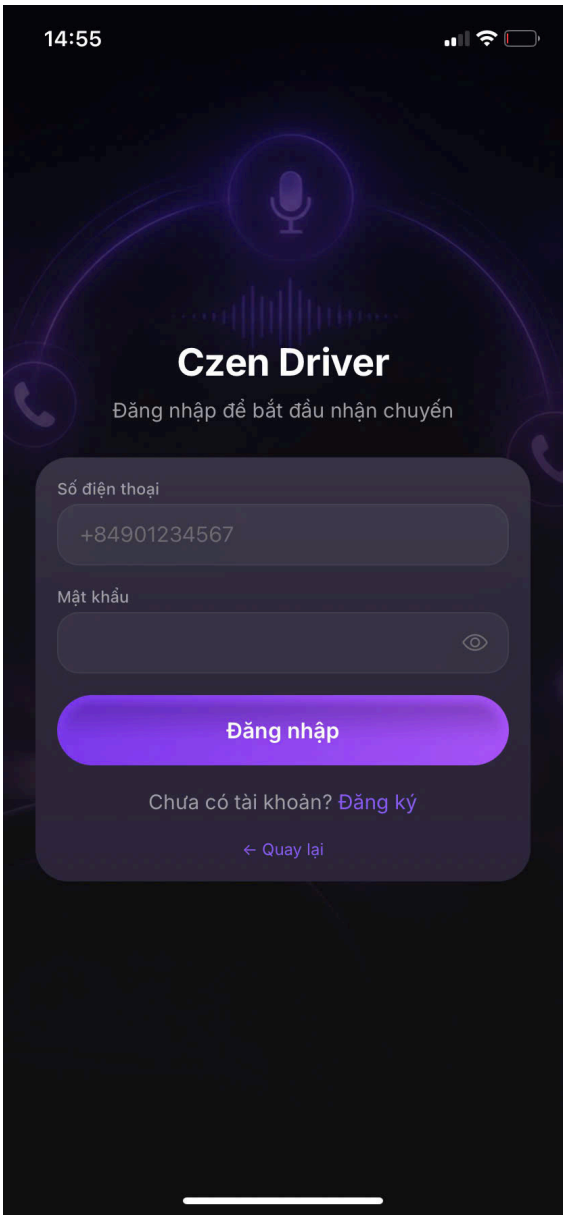
Trường	Ý nghĩa	Giá trị ví dụ
turns	Danh sách lượt nói theo thứ tự: vai (user/assistant), nội dung, thời điểm	61 lượt, ví dụ user: "Hôm nay tôi có bao nhiêu chuyến?" – assistant: "Bạn có 13 chuyến sắp tới."
summary	Tóm tắt hội thoại do mô hình ngôn ngữ sinh khi kết thúc phiên	"Trong cuộc hội thoại, tài xế yêu cầu trợ lý AI kiểm tra lịch trình chuyến đi, thông tin khách hàng, và thực hiện gọi điện cho khách hàng…"
stt_provider, llm_provider, llm_model	Nhà cung cấp và mô hình đã dùng trong phiên	google, openai, gpt-5.6-luna
mode, metrics	Loại phiên và chỉ số chất lượng phiên (mục 5.3.6); chỉ có ở bản ghi tạo sau khi triển khai chỉ số phiên	Không có ở bản ghi ví dụ này
ttl	Thời điểm DynamoDB tự xóa bản ghi	Tùy chọn

5.5. Hiện thực ứng dụng tài xế

Ứng dụng tài xế hiện thực các yêu cầu thiết kế ở mục 4.8. Màn hình chào giới thiệu vai trò trợ lý và hai lối vào đăng nhập, đăng ký (Hình 5.1); tài xế đăng nhập bằng số điện thoại và mật khẩu (Hình 5.2).

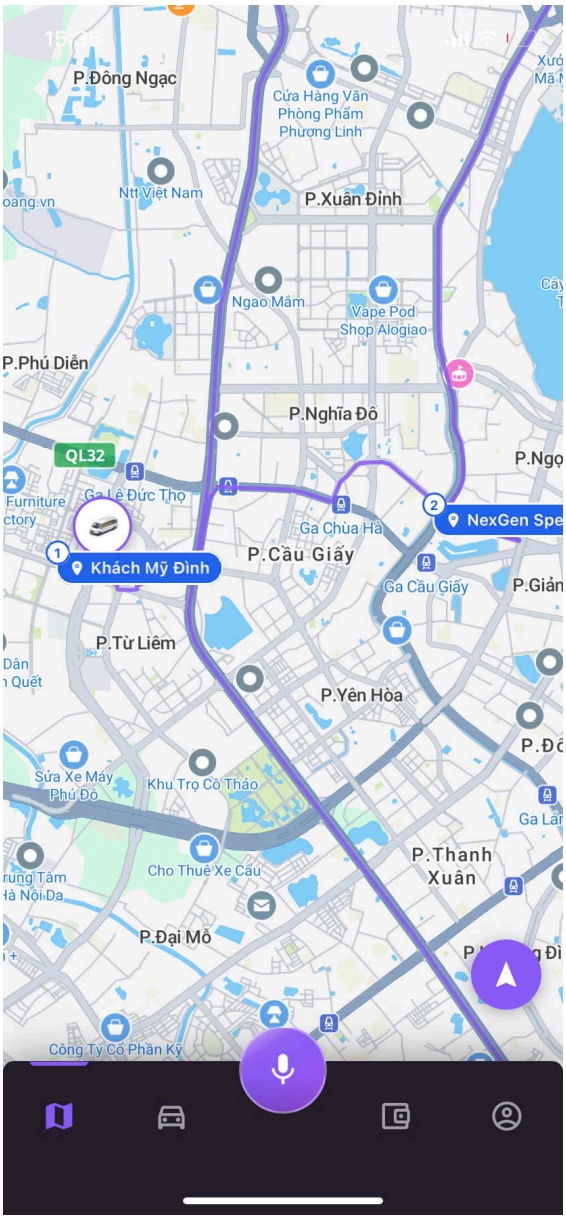


Hình 5.1. Màn hình chào của ứng dụng tài xế

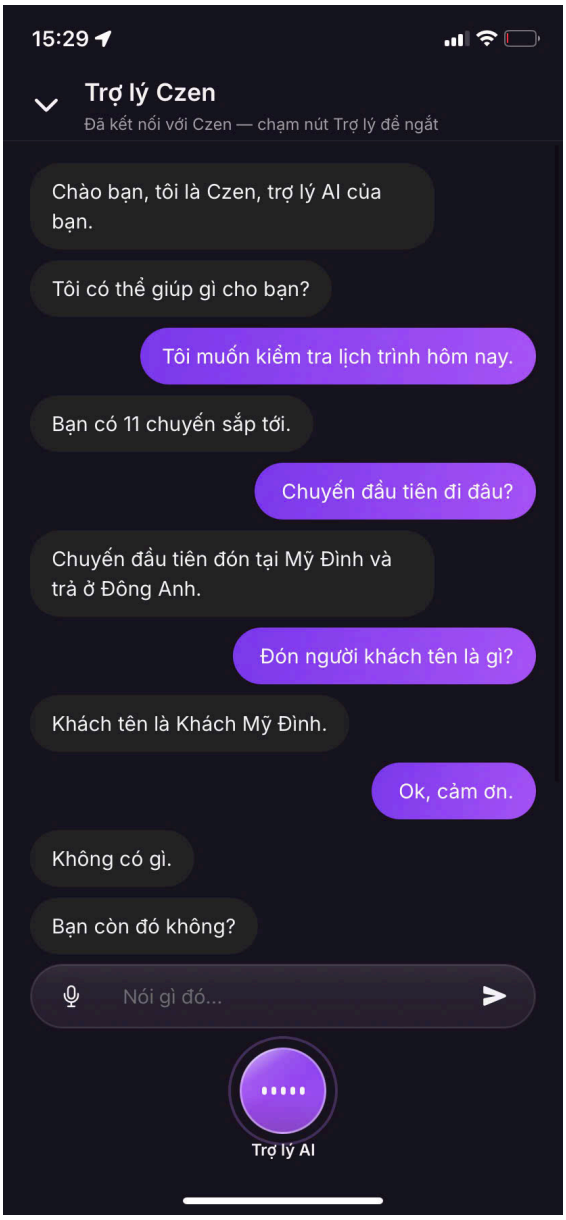


Hình 5.2. Màn hình đăng nhập tài xế bằng số điện thoại và mật khẩu

Sau khi đăng nhập, màn hình chính hiển thị bản đồ, trạng thái hoạt động và điểm đón, trả của chuyến (Hình 5.3). Khi mở trợ lý, ứng dụng xin token thoại, tham gia phòng hội thoại (features/home/stores/voiceSessionStore.ts) và hiển thị biểu tượng trợ lý thay đổi theo trạng thái phiên (Hình 5.4).

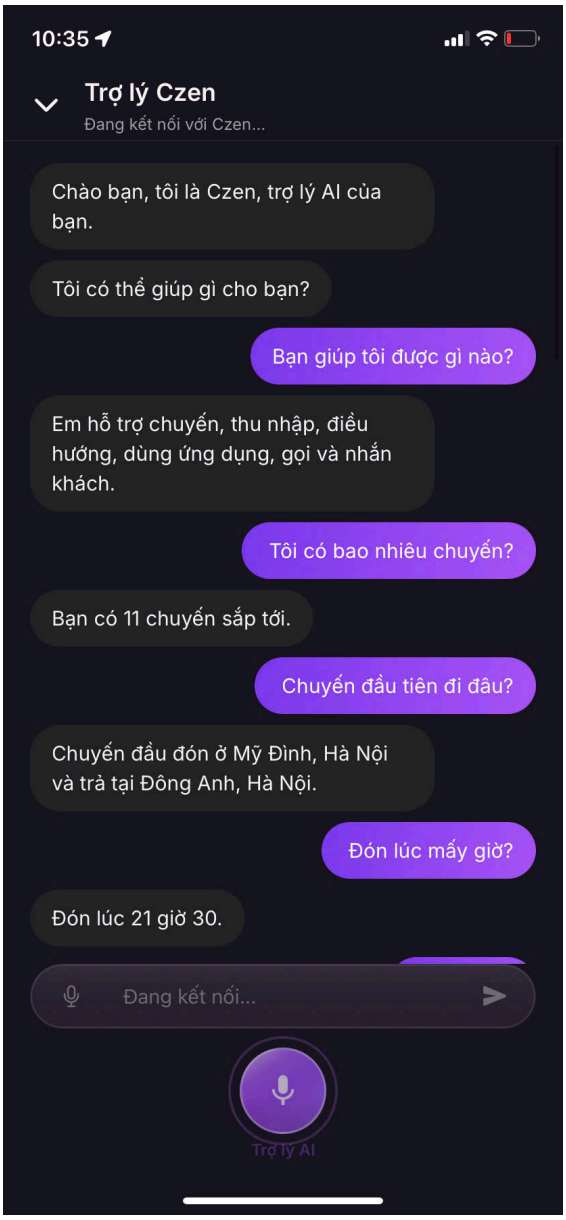


Hình 5.3. Màn hình bản đồ sau khi đăng nhập và bật trạng thái hoạt động



Hình 5.4. Phiên trợ lý giọng nói với biểu tượng trợ lý ở trạng thái đang xử lý

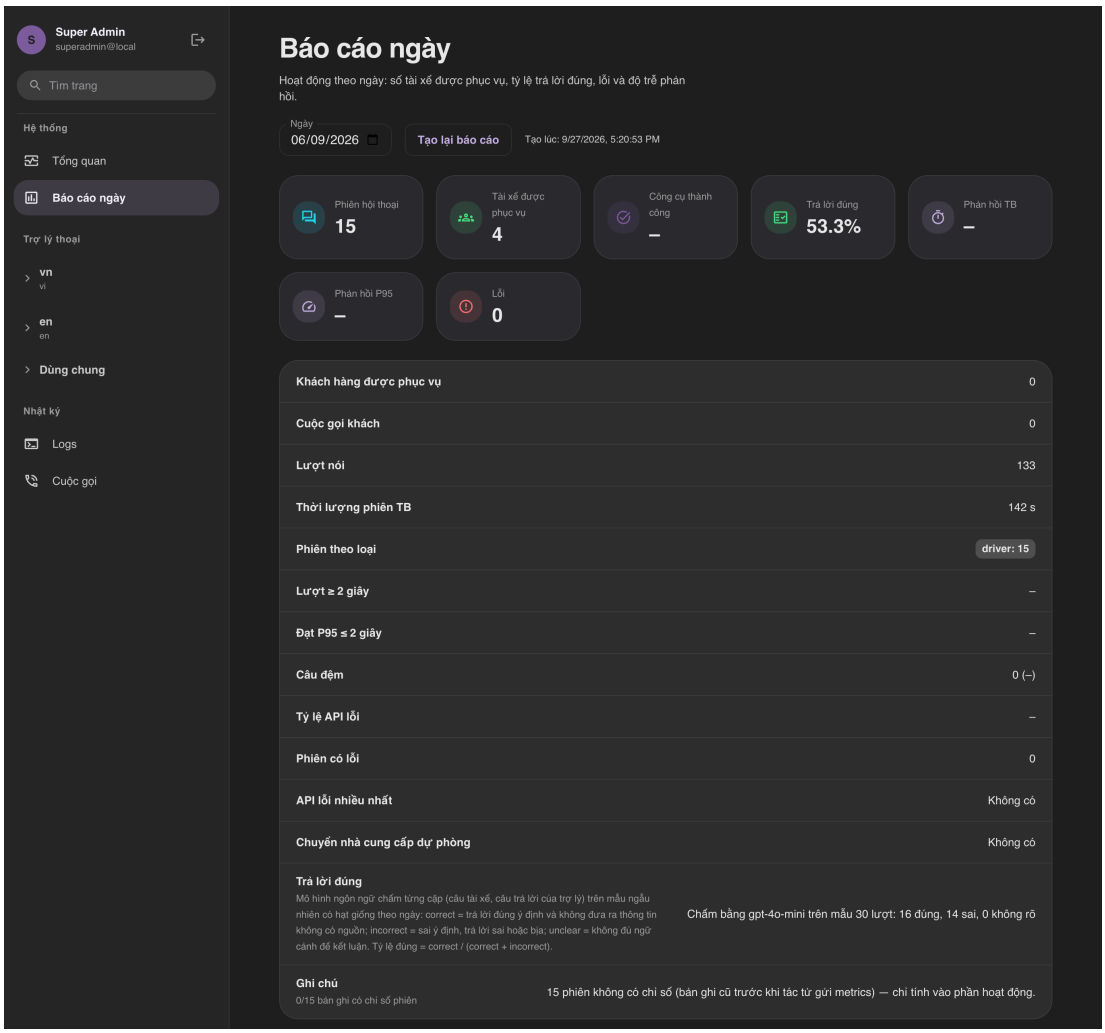
Bản ghi hội thoại được hiển thị đồng bộ với lời nói để tài xế đối chiếu khi dừng xe (Hình 5.5).



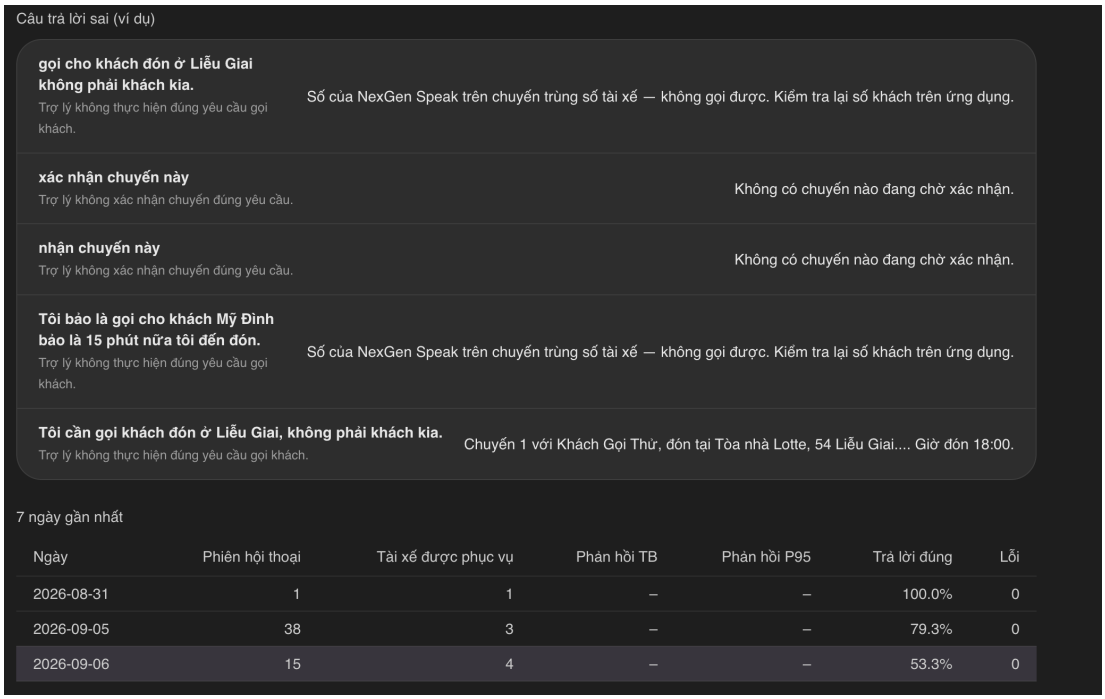
Hình 5.5. Hội thoại mẫu: tra cứu lịch trình và thông tin chuyến bằng giọng nói

Trang giám sát hệ thống có thêm trang "Báo cáo ngày" (super-admin-panel/src/pages/ReportsPage.tsx) hiển thị các nhóm chỉ số (Hình 5.6), ví dụ câu trả lời bị chấm sai và bảng xu hướng 7 ngày (Hình 5.7). Ảnh chụp dùng dữ liệu thật của ngày 06/09/2026 trong bảng nhật ký cuộc gọi của môi trường phát triển: 15 phiên, 4 tài xế, 133 lượt nói; mô hình chấm đánh giá mẫu 30 lượt với 16 đúng và 14 sai (tỷ lệ 53,3%). Các ô độ trễ và tỷ lệ công cụ thành công để trống vì những bản ghi này được tạo trước khi tác nhân gửi kèm chỉ số phiên (mục 5.3.6); báo cáo nêu rõ điều này ở dòng "Ghi chú" thay vì ước lượng. Với bản ghi cũ chưa có trường loại phiên, dịch vụ

suy ra loại phiên từ tiền tố tên phòng trong mã cuộc gọi (driver-, trip-, customer-, custcall-), cùng quy ước với tác nhân hội thoại (app/agent/session.py).



Hình 5.6. Trang báo cáo vận hành ngày: các chỉ số tổng hợp (dữ liệu ngày 06/09/2026)



Hình 5.7. Trang báo cáo vận hành ngày: ví dụ câu trả lời bị chấm sai và xu hướng 7 ngày (dữ liệu ngày 06/09/2026)

Trang cài đặt trợ lý (app/(app)/assistant-settings.tsx) cho phép chọn ngôn ngữ và chế độ gọi khách mặc định. Từ khóa đánh thức được nhận dạng trên thiết bị bằng thư viện Vosk (features/assistant-wakeword/wakeWordService.ts); khi khớp từ khóa, ứng dụng mở phiên theo cùng luồng như khi bấm nút và không gửi đoạn âm thanh đánh thức tới mô hình ngôn ngữ. Các ảnh giao diện khác đặt ở Phụ lục C.

5.6. Triển khai trên AWS

5.6.1. Hạ tầng dạng mã

Mỗi dịch vụ có một stack hạ tầng dạng mã riêng trong thư mục infra/<tên dịch vụ>/, triển khai độc lập với các dịch vụ khác. Tài nguyên được đặt tên theo quy ước <môi trường>-driver-assistant-<tên dịch vụ>-<vai trò> và gắn các thẻ app, env, service, layer, component; giá trị thẻ layer trùng tên lớp trên Hình 4.1 để đối chiếu sơ đồ với tài nguyên thực tế. API Gateway chuyển mọi đường dẫn (ANY /{proxy+}) tới ứng dụng Express của dịch vụ, nên thêm API mới không phải sửa template. Bảng 5.6 tóm tắt tài nguyên của từng stack.

Bảng 5.6. Tài nguyên AWS theo stack

Stack	Tài nguyên AWS	Cấu hình chính	Yêu cầu đáp ứng
identity-service	API Gateway REST; Lambda; DynamoDB (accounts, driver-settings); CloudWatch Logs	Node.js 20, 256 MB; DynamoDB PAY_PER_REQUEST	NFR-03, NFR-05
external-api-service	API Gateway REST và WebSocket; Lambda (API, kết nối và ngắt kết nối WebSocket); DynamoDB (trips, ws-connections); CloudWatch Logs	Node.js 20, 256 MB; DynamoDB PAY_PER_REQUEST	NFR-02, NFR-03
external-channel-service	API Gateway REST; Lambda; DynamoDB (channel-events, TTL 90 ngày); CloudWatch Logs	Node.js 20, 256 MB	NFR-04
call-records-service	API Gateway REST; Lambda; DynamoDB (call-records, chỉ mục theo người gọi và theo ngày, TTL); CloudWatch Logs	Node.js 20, 256 MB	NFR-04, FR-O01
ops-service	API Gateway REST; Lambda; DynamoDB (daily-reports); EventBridge Scheduler (00:15, múi giờ Asia/Ho_Chi_Minh); quyền đọc CloudWatch Logs và ECS; CloudWatch Logs	Node.js 20, 512 MB, thời gian chạy tối đa 120 giây	FR-O01, NFR-04
llm-orchestrator	Amazon ECR; ECS cluster, task definition, service trên Fargate; security group; vai trò IAM; CloudWatch Logs	1 vCPU, 2 GB; DesiredCount điều chỉnh số bản sao; public subnet, chỉ kết nối chiều ra	NFR-02, NFR-03, NFR-04
frontend	Amazon S3	Lưu trữ tĩnh trang quản trị và ứng dụng web	—

Tham số bí mật (khóa API, khóa JWT, thông tin LiveKit, Twilio) được khai báo với thuộc tính NoEcho trong template và nạp từ tệp môi trường cục bộ không nằm trong kho mã nguồn (NFR-05). Kịch bản infra/deploy-all.sh triển khai các stack theo thứ tự phụ thuộc (Dịch vụ Định danh, Dịch vụ Nhật ký cuộc gọi, Dịch vụ Kênh liên lạc, Dịch vụ Chuyến đi và Điều phối, tác nhân hội thoại, Dịch vụ Giám sát vận hành) và ghi địa chỉ API của stack trước vào tệp môi trường của stack sau; phần xây dựng, triển khai và gỡ bỏ dùng chung thư viện infra/lib/sam.sh; infra/scale-ecs.sh điều chỉnh số bản sao tác nhân.

5.6.2. Môi trường phát triển và thử nghiệm

Trong quá trình phát triển và thực nghiệm, các dịch vụ Node.js chạy cục bộ bằng Express, tác nhân hội thoại chạy cục bộ và kết nối LiveKit Cloud; ứng dụng tài xế trỏ tới địa chỉ dịch vụ qua biến môi trường EXPO_PUBLIC_. Cấu hình không bí mật của tác nhân (nhà cung cấp, mô hình, giọng đọc, địa chỉ dịch vụ) nằm trong tệp envs/config.<môi trường>.toml; khóa bí mật nằm trong tệp .env không đưa vào kho mã nguồn. Tệp mẫu envs/.env.example và envs/config.example.toml được cung cấp để tái lập môi trường (Phụ lục D). Bảng 5.7 liệt kê các thành phần tối thiểu để chạy nguyên mẫu đầu cuối.

Bảng 5.7. Thành phần tối thiểu để chạy nguyên mẫu đầu cuối

Thành phần	Cần cho	Ghi chú
Dịch vụ Định danh, Dịch vụ Chuyến đi và Điều phối	Đăng nhập, token thoại, ngữ cảnh	Bắt buộc
Tác nhân hội thoại, LiveKit Cloud	Hội thoại trong ứng dụng	Tác nhân phải đăng ký thành công với LiveKit
Ứng dụng tài xế	Giao diện, micro, loa	Thiết bị thật hoặc trình giả lập
SIP trunk (Twilio)	Mời nhận chuyến qua điện thoại, gọi khách	Có thể bỏ qua nếu chỉ thử trong ứng dụng
Dịch vụ Kênh liên lạc	Gửi SMS	Có thể bỏ qua
Dịch vụ Nhật ký cuộc gọi	Lưu và tóm tắt cuộc gọi	Tắt không ảnh hưởng hội thoại

5.7. Đối chiếu thiết kế và hiện thực

Bảng 5.8 đối chiếu các quyết định thiết kế ở Chương 4 với vị trí hiện thực trong mã nguồn, làm căn cứ khoanh vùng lỗi khi phân tích kết quả ở Chương 6.

Bảng 5.8. Đối chiếu quyết định thiết kế và hiện thực

Quyết định thiết kế	Hiện thực
Tác nhân chỉ gọi API (CON-01)	llm-orchestrator/app/services/backend_api.py
Khởi tạo phiên, lời chào, tải trước ngữ cảnh (S2)	llm-orchestrator/app/agent/session.py; processors/prefetch.py; processors/context_store.py
Cấp token và tái sử dụng phòng (S2)	external-api-service/src/routes/voice.ts

Quyết định thiết kế	Hiện thực
Luồng xử lý đơn (ADR-02)	llm-orchestrator/app/voicebot/processors/spoken_intent.py, intent_classify.py
Câu đệm 2 giây	llm-orchestrator/app/voicebot/processors/turn_filler.py
Dự phòng nhà cung cấp AI	llm-orchestrator/app/providers/__init__.py, fallback.py
Phân loại phiên và tập công cụ	session.py (_parse_room); voicebot/locales/{vn,en}/agent.py
Mời nhận chuyến (S4)	external-api-service/src/services/dispatchService.ts
Gọi khách ba chế độ (S5)	external-api-service/src/services/callService.ts; services/telephony/livekit.ts
Nhật ký cuộc gọi (S6)	llm-orchestrator/app/services/conversation_service.py; call-records-service/src/routes
Đăng nhập, JWT (S1)	identity-service/src/routes/auth.ts
Từ khóa đánh thức	driver-app/src/features/assistant-wakeword/wakeWordService.ts
Trả lời câu hỏi thường gặp	Công cụ answer_app_faq; llm-orchestrator/app/rag/; requirements/knowledge/
Chỉ số phiên	llm-orchestrator/app/services/session_metrics.py; app/devlog.py
Lưu sự kiện nhà cung cấp thoại	external-channel-service/src/services/events/
Truy vấn bản ghi theo ngày	call-records-service/src/services/recordService.ts (listByDate)
Báo cáo vận hành ngày (S7)	ops-service/src/services/reports/; ops-service/src/routes/reports.ts; super-admin-panel/src/pages/ReportsPage.tsx
Hạ tầng AWS	infra/<tên dịch vụ>/sam.yaml, infra/llm-orchestrator/cfn.yaml, infra/lib/sam.sh, infra/deploy-all.sh

Kết luận chương

Chương 5 đã trình bày công nghệ, tổ chức mã nguồn, hiện thực tác nhân hội thoại với lớp trừu tượng và dự phòng nhà cung cấp AI, các dịch vụ backend, ứng dụng tài xế, hạ tầng dạng mã trên AWS và bảng đối chiếu thiết kế với hiện thực. Chương 6 đánh giá nguyên mẫu theo từng yêu cầu đã đặc tả ở Chương 3.

Chương 6. Thực nghiệm và đánh giá

Chương này đánh giá nguyên mẫu đã triển khai ở Chương 5 theo từng yêu cầu đã đặc tả ở Chương 3 và trả lời các câu hỏi nghiên cứu RQ1–RQ4. Mỗi yêu cầu được đánh giá bằng kịch bản, chỉ số và ngưỡng đã xác định trước (Bảng 3.12). Chương trình bày ma trận đánh giá, môi trường thực nghiệm, định nghĩa chỉ số, kết quả theo từng yêu cầu, tổng hợp và thảo luận theo câu hỏi nghiên cứu, và các yếu tố ảnh hưởng đến độ tin cậy của kết luận.

Ghi chú liêm chính số liệu: Số liệu độ trễ, tỷ lệ lỗi từ và độ chính xác gọi công cụ được trích từ nhật ký phiên thật (trường room) và bộ kiểm thử tự động trong cửa sổ hai ngày 05 và 06 tháng 9 năm 2026. Số liệu khả năng mở rộng và khả năng phục hồi được thu từ môi trường mô phỏng cục bộ (mục 6.2.2). Các ô chưa có số liệu được đánh dấu 「—」, không suy đoán giá trị.

6.1. Mục tiêu và ma trận đánh giá

Bảng 6.1 liên kết từng yêu cầu với câu hỏi nghiên cứu, kịch bản, chỉ số, ngưỡng và mục trình bày kết quả.

Bảng 6.1. Ma trận đánh giá theo yêu cầu

Yêu cầu	Câu hỏi nghiên cứu	Kịch bản	Chỉ số	Ngưỡng	Mục
NFR-02 Performance	RQ2	Phiên hội thoại UC01, UC03, UC04, UC07	P50, P95 độ trễ phản hồi	P95 ≤ 2 giây	6.4
Nhận dạng giọng nói	RQ3	Bộ câu tham chiếu, hai điều kiện âm thanh	Tỷ lệ lỗi từ	So sánh tương đối	6.5
FR-T, FR-C, FR-E, FR-F	RQ4	UC01–UC08	Độ chính xác gọi công cụ; tỷ lệ hoàn thành nghiệp vụ	Báo cáo theo nhóm	6.6
NFR-01 Usability	RQ4	UC01–UC06, UC09	Danh mục kiểm tra hành vi khi lái	100% thao tác rủi ro có xác nhận	6.7
NFR-03 Scalability	RQ1	SC-01, SC-02, SC-03	P95 và tỷ lệ lỗi theo số phiên đồng thời	Tăng P95 ≤ 20%; lỗi < 1%	6.8

Yêu cầu	Câu hỏi nghiên cứu	Kịch bản	Chỉ số	Ngưỡng	Mục
NFR-04 Resilience	RQ1	RS-01 đến RS-05	Tỷ lệ phiên duy trì; thời gian khôi phục	100% phiên duy trì	6.9
NFR-05 Security	—	Kiểm tra mã nguồn, cấu hình, nhật ký	Danh mục kiểm tra bảo mật	100% mục đạt	6.10
Luồng khách hàng	RQ4	Bộ trường hợp kiểm thử khách hàng	Tỷ lệ trường hợp kiểm thử đạt	Đạt / không đạt	6.11
FR-O01, FR-O02	—	Kiểm thử tự động mô-đun chỉ số phiên và báo cáo ngày	Tỷ lệ trường hợp kiểm thử đạt	Đạt / không đạt	6.11

Ngoài phạm vi đánh giá: khảo sát trải nghiệm của khách hàng thật; đo an toàn giao thông thực địa; so sánh quy mô lớn giữa các nhà cung cấp STT, LLM, TTS; thử tải trên hạ tầng AWS thực tế.

6.2. Môi trường thực nghiệm

6.2.1. Môi trường đo hội thoại

Bảng 6.2 mô tả môi trường dùng để đo độ trễ, tỷ lệ lỗi từ và độ chính xác gọi công cụ.

Bảng 6.2. Môi trường đo hội thoại

Thành phần	Cấu hình	Ghi chú
Ứng dụng tài xế	Thiết bị thật hoặc trình giả lập	Ưu tiên thiết bị thật khi đo micro, loa
Tác nhân hội thoại	Chạy cục bộ, kết nối LiveKit Cloud	Nhật ký gắn mã phòng
Dịch vụ backend	Dịch vụ Định danh, Dịch vụ Chuyến đi và Điều phối chạy cục bộ	Cấu hình không chứa bí mật ở Phụ lục D
Truyền thông	LiveKit Cloud, WebRTC; SIP khi đo UC02, UC04	—
Mô hình AI	LLM gpt-5.6-luna; STT Google chirp_3 (vi-VN); TTS Google vi-VN-Chirp3-HD-Kore	Cố định trong suốt cửa sổ đo
Dữ liệu	Tài khoản và chuyến thử nghiệm nội bộ	Che thông tin cá nhân trên nhật ký và ảnh

Thành phần	Cấu hình	Ghi chú
Kiểm thử tự động	pytest trong thư mục kiểm thử của tác nhân	Bổ trợ trường hợp kiểm thử khách hàng

Số liệu độ trễ được trích từ nhật ký turn_metrics của tác nhân trong hai ngày 2026-09-05 và 2026-09-06 (n = 341 lượt), kênh WebRTC trong ứng dụng. Mô hình gpt-5.6-luna là mô hình họ GPT truy cập qua giao diện tương thích OpenAI (bí danh nội bộ của dự án); kết luận về thời gian sinh token đầu gắn với mô hình này. Kịch bản do tác giả đọc; script trích xuất extract_ch6_metrics.py đi kèm để tái lập.

6.2.2. Môi trường mô phỏng thử tải và tiêm lỗi

Khả năng mở rộng và khả năng phục hồi được đánh giá trên môi trường mô phỏng cục bộ, trong đó mỗi thành phần AWS được thay bằng một thành phần tương đương (Bảng 6.3). Nhà cung cấp STT, LLM, TTS được thay bằng bộ giả lập có độ trễ cấu hình được để kết quả phản ánh tính chất kiến trúc, không phụ thuộc biến động của nhà cung cấp bên ngoài.

Bảng 6.3. Ánh xạ thành phần AWS sang môi trường mô phỏng

Trên AWS	Môi trường mô phỏng
API Gateway và Lambda của từng dịch vụ	Tiến trình Node.js của từng dịch vụ, mỗi dịch vụ một cổng
Amazon DynamoDB	DynamoDB Local hoặc chế độ lưu trữ cục bộ của dịch vụ
ECS Fargate với DesiredCount = N	N tiến trình tác nhân cùng đăng ký vào một máy chủ LiveKit
LiveKit Cloud	Máy chủ LiveKit chạy ở chế độ phát triển
Nhà cung cấp STT, LLM, TTS	Bộ giả lập có độ trễ và tỷ lệ lỗi cấu hình được
Twilio	Bộ giả lập HTTP có thể cấu hình trả lỗi
Lỗi mạng giữa các dịch vụ	Công cụ toxiproxy chèn độ trễ, ngắt kết nối, lỗi

Công cụ tạo tải gồm k6 (kiểm thử tải API) và LiveKit CLI (tạo nhiều người tham gia giả lập phát âm thanh vào phòng).

6.3. Định nghĩa chỉ số

Độ trễ phản hồi. Thời gian từ lúc tài xế kết thúc phát ngôn đến lúc tác nhân bắt đầu phát âm thanh trả lời, ghi trong nhật ký với tên user_stop_to_agent_speak. Các mốc phụ trong một lượt (phát hiện kết thúc phát ngôn, thời gian sinh token đầu của LLM, thời gian đến âm thanh đầu của TTS) dùng để phân tích điểm nghẽn. Báo cáo P50 và P95 theo giây.

Tỷ lệ lỗi từ. WER = (S + D + I) / N, trong đó S, D, I là số từ bị thay thế, bị xóa, bị chèn so với câu tham chiếu và N là số từ của câu tham chiếu.

Độ chính xác gọi công cụ. Một lượt được tính là đúng khi tên công cụ thuộc tập kỳ vọng của trường hợp sử dụng, tham số chính đúng và không có lời gọi công cụ gây sai nghiệp vụ.

Tỷ lệ hoàn thành nghiệp vụ. Một trường hợp sử dụng được tính là hoàn thành khi thỏa điều kiện thành công ở Bảng 3.8; câu trả lời trôi chảy nhưng dữ liệu phía backend không thay đổi đúng vẫn tính là không hoàn thành.

Chỉ số khả năng mở rộng. Mức tăng tương đối của P95 độ trễ phản hồi và tỷ lệ phiên lỗi khi tăng số phiên đồng thời, với số bản sao tác nhân tương ứng.

Chỉ số khả năng phục hồi. Tỷ lệ phiên không bị kết thúc bất thường khi tiêm lỗi; tỷ lệ lượt vẫn được phản hồi; thời gian từ khi bản sao tác nhân bị dừng đến khi phiên mới được phục vụ.

6.4. Kết quả hiệu năng — NFR-02 (RQ2)

Số liệu độ trễ hiện có thuộc đợt đo ngày 05–06/09/2026, khi nguyên mẫu còn nhánh xử lý rút gọn theo ý định (Bảng 6.4). Sau đợt đo, nhánh này đã bị loại bỏ theo ADR-02 (mục 4.2.2); các con số của nhánh rút gọn không còn là kết quả của thiết kế hiện hành mà là bằng chứng cho thấy thời gian sinh token đầu của LLM là điểm nghẽn chính.

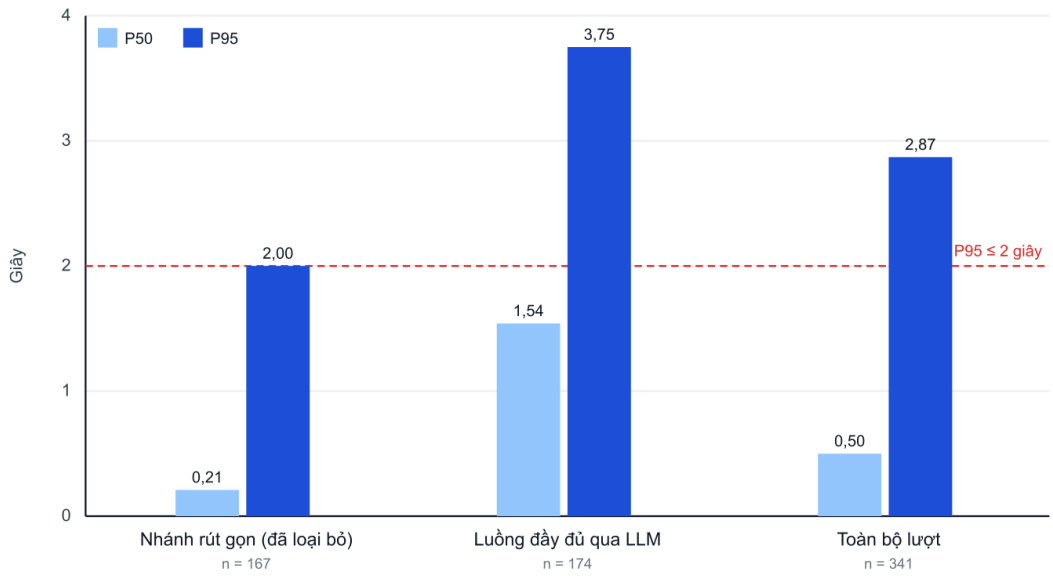
Bảng 6.4. Độ trễ phản hồi theo nhánh xử lý (giây, nhật ký 05–06/09/2026, gpt-5.6-luna)

Nhánh xử lý	n	P50	P90	P95	Tỷ lệ lượt ≥ 2 giây	Đạt P95 ≤ 2 giây
Nhánh rút gọn theo ý định (không qua LLM)	167	0,21	1,48	2,00	5,4%	Đạt (sát ngưỡng)
Luồng đầy đủ qua LLM	174	1,54	2,78	3,75	30,5%	Chưa đạt
Toàn bộ lượt	341	0,50	2,29	2,87	18,2%	Chưa đạt

Nhánh xử lý được gán theo việc mô-đun nhận dạng ý định có kích hoạt trong lượt hay không (cách gán xấp xỉ, xem mục 6.13). Nhóm UC03 và UC07 không đủ mẫu để tách riêng.

Bảng 6.5. Phân tích điểm nghẽn độ trễ trong một lượt (mili-giây)

Chặng	P50	P95	Nhận xét
Phát hiện kết thúc phát ngôn	935	1 700	Phụ thuộc mô hình phát hiện lượt và độ dài câu
LLM sinh token đầu	1 249	2 487	Chi phí lớn nhất của mọi lượt qua LLM
TTS đến âm thanh đầu	161	288	Không đáng kể



Hình 6.1. P50 và P95 độ trễ phản hồi theo nhánh xử lý, đợt đo 05–06/09/2026 (n = 341 lượt)

Kết quả cho thấy: nhánh rút gọn đạt ngưỡng sát biên (P95 = 2,00 giây); luồng đầy đủ qua LLM chưa đạt (P95 = 3,75 giây), với thời gian sinh token đầu (P95 ≈ 2,5 giây) là nguyên nhân chính. Trong thiết kế hiện hành, mọi lượt đều đi qua LLM, vì vậy câu đệm sau 2 giây được dùng để báo hiệu hệ thống đang xử lý, còn tải trước ngữ cảnh rút ngắn thời gian thực thi công cụ.

Bảng 6.6. Độ trễ phản hồi trên thiết kế hiện hành (luồng xử lý đơn và câu đệm)

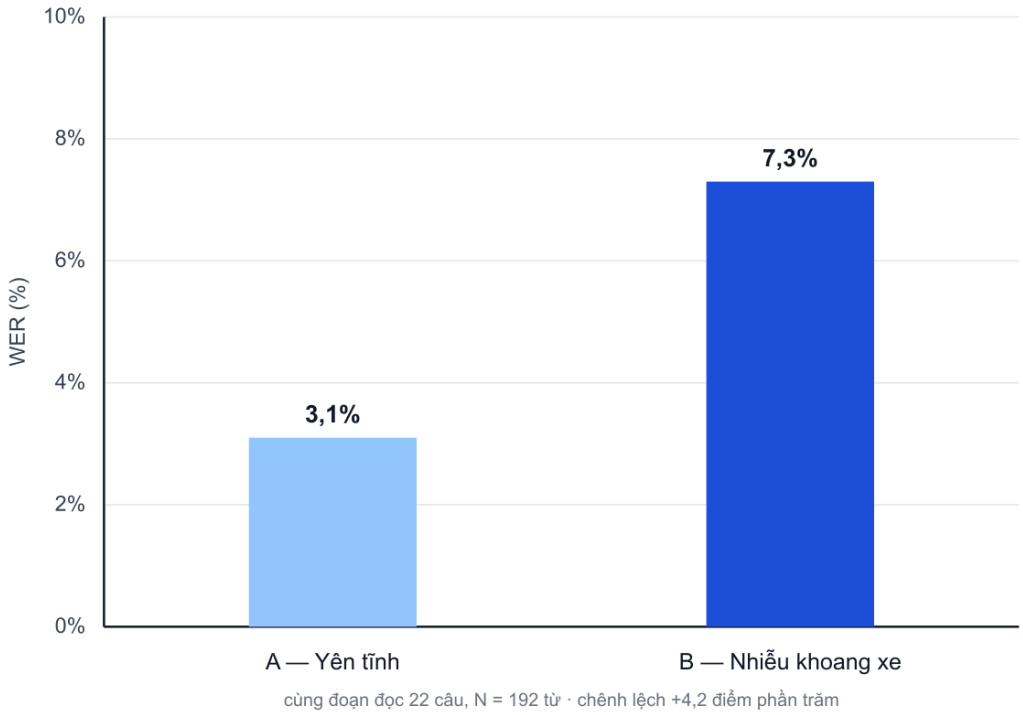
Nhóm trường hợp sử dụng	n	P50	P95	Tỷ lệ lượt có câu đệm	Đạt P95 ≤ 2 giây
UC01 Xem lịch	⌜—⌟	⌜—⌟	⌜—⌟	⌜—⌟	⌜—⌟
UC03 Cập nhật tiến độ	⌜—⌟	⌜—⌟	⌜—⌟	⌜—⌟	⌜—⌟
UC04 Gọi khách	⌜—⌟	⌜—⌟	⌜—⌟	⌜—⌟	⌜—⌟
UC07 Hỏi đáp	⌜—⌟	⌜—⌟	⌜—⌟	⌜—⌟	⌜—⌟

6.5. Kết quả nhận dạng giọng nói (RQ3)

Bảng 6.7. Tỷ lệ lỗi từ theo điều kiện âm thanh (một người đọc, một lượt mỗi điều kiện)

Điều kiện	Số câu / số từ	S / D / I	WER
A — Yên tĩnh	22 câu / 192 từ	1 / 5 / 0	3,1%
B — Nhiễu mô phỏng khoang xe	22 câu / 192 từ	3 / 5 / 6	7,3%
Chênh lệch B − A			+4,2 điểm phần trăm

Thiết lập. Cùng một bộ 22 câu (tra cứu chuyến, xác nhận, gọi và nhắn tin cho khách, hai địa chỉ có số nhà, mốc giờ) được đọc một lượt ở mỗi điều kiện, cùng thiết bị và micro. Ở điều kiện B, tiếng ồn nền mô phỏng khoang xe được phát từ một thiết bị khác để tránh bộ khử tiếng vọng của điện thoại loại bỏ tín hiệu. Văn bản nhận dạng lấy từ sự kiện stt_final trong nhật ký, chuẩn hóa chữ số và dấu câu trước khi so sánh bằng script compute_wer.py.



Hình 6.2. Tỷ lệ lỗi từ ở điều kiện yên tĩnh và điều kiện nhiễu mô phỏng khoang xe

Tỷ lệ lỗi từ tăng hơn gấp đôi khi có nhiễu, từ 3,1% lên 7,3%. Ở điều kiện nhiễu xuất hiện các lỗi thay từ mang nghĩa ("thu nhập" thành "phim Nhật"), sai chữ số trong địa chỉ và mất các hư từ ngắn. Nhận dạng vẫn dùng được cho câu lệnh ngắn nhưng độ tin cậy giảm, phù hợp với giới hạn không huấn luyện lại mô hình nhận dạng nêu ở Chương 1.

6.6. Kết quả tính đúng chức năng (RQ4)

Bảng 6.8. Độ chính xác gọi công cụ và tỷ lệ hoàn thành nghiệp vụ (đánh giá thủ công, một người đánh giá, nhật ký 2026-09-05 đến 2026-09-06)

Nhóm nghiệp vụ	n	Đúng công cụ	Hoàn thành ngay lần đầu	Lỗi quan sát
UC01 Xem lịch, hỏi chuyến	21	≈ 100%	≈ 95%	1 lần địa chỉ bị cắt (E-UX)
UC02 Nhận, từ chối chuyến	4	100%	100%	Không có
UC04 Gọi khách	6	≈ 67%	≈ 50%	Hỏi cách gọi khách bị hiểu thành lệnh gọi (E-INTENT); chuyển lời nhắn sai nghĩa (E-UX)

Nhóm nghiệp vụ	n	Đúng công cụ	Hoàn thành ngay lần đầu	Lỗi quan sát
UC08 Thu nhập	6	≈ 100%	≈ 67%	Hỏi thu nhập theo tháng, theo năm trả về thu nhập trong ngày (E-PARAM)
UC07 Hỏi đáp cách sử dụng	2	100%	100%	Không có
Tổng	≈ 39	≈ 88%	≈ 77%	Xem Bảng 6.9

Lỗi E-INTENT ở UC04 phát sinh từ nhánh rút gọn theo ý định; nhánh này đã bị loại bỏ và kiểm thử test_spoken_intent xác nhận câu hỏi cách gọi khách không còn kích hoạt công cụ gọi. Số liệu theo từng trường hợp sử dụng UC03, UC05, UC06 cần đợt đánh giá có gắn nhãn, kịch bản mù và ít nhất hai người đánh giá.

Bảng 6.9. Phân loại lỗi quan sát (n ≈ 39 lượt)

Mã	Nhóm lỗi	Ví dụ	Khâu nghi ngờ	Số lần
E-INTENT	Nhận dạng đúng nhưng chọn sai thao tác	Hỏi cách gọi khách bị hiểu thành lệnh gọi	Nhánh rút gọn (đã loại bỏ)	≈ 3
E-PARAM	Đúng công cụ, sai tham số	Thu nhập "tháng vừa rồi" trả về thu nhập hôm nay	Ngữ cảnh, LLM	≈ 2
E-UX	Hoàn thành nghiệp vụ nhưng câu nói khó nghe khi lái	Địa chỉ bị cắt; lời nhắn chuyển sai nghĩa	Lời nhắc hệ thống, TTS	≈ 3
E-CONFIRM	Đáp lời nhưng chưa gọi công cụ	Trả lời "Vâng" nhưng không thực hiện cho tới khi tài xế hỏi lại	Lời nhắc hệ thống, hành động chờ xác nhận	≈ 2
E-STT	Nhận dạng sai tên riêng	"NexGen Speak" thành "Nick Jan Speed"	STT, nhiễu	≈ 2
E-API	Đúng công cụ nhưng API lỗi	Gửi SMS trả mã 503; tác nhân báo không gửi được, phiên tiếp tục (Bảng 5.3)	Dịch vụ Kênh liên lạc, backend	1

6.7. Kết quả khả năng sử dụng — NFR-01

Bảng 6.10. Danh mục kiểm tra hành vi khi lái

STT	Tiêu chí	Trường hợp sử dụng	Kết quả	Bằng chứng
1	Hoàn thành nghiệp vụ cốt lõi không cần chạm màn hình	UC01–UC04	Đạt (mẫu)	Phiên 2026-09-06: hỏi lịch, số chuyến, điểm đón, tên khách không thao tác màn hình
2	Mỗi câu trả lời một ý chính	UC01, UC03	Đạt	Độ dài câu TTS trên toàn nhật ký: trung vị 44 ký tự, 93% câu ≤ 120 ký tự (n = 2 638 câu)
3	Thao tác rủi ro có bước xác nhận	UC05, UC06	Đạt	Kiểm thử test_confirm_trip, test_pending_action đạt
4	Không đưa ra dữ liệu chuyến, thu nhập, vị trí không có nguồn	UC01, UC08	Đạt (mẫu)	Câu trả lời khớp dữ liệu ngữ cảnh từ API; không quan sát thấy dữ liệu không có nguồn
5	Im lặng được nhắc, sau đó kết thúc phiên	UC09	Đạt	Phiên mẫu: tác nhân hỏi "Bạn còn đó không?", chào kết thúc và gọi API kết thúc phiên (mã 200)

6.8. Kết quả khả năng mở rộng — NFR-03 (RQ1)

Bảng 6.11. Kết quả thử tải trên môi trường mô phỏng

Mã	Kịch bản	Cấu hình	P50 (giây)	P95 (giây)	Mức tăng P95 so với 1 phiên	Tỷ lệ phiên lỗi	Đạt
SC-01	1, 5, 10, 20 phiên đồng thời	1 bản sao tác nhân	⌜—⌟	⌜—⌟	⌜—⌟	⌜—⌟	⌜—⌟
SC-02	20 phiên đồng thời	2 và 4 bản sao tác nhân	⌜—⌟	⌜—⌟	⌜—⌟	⌜—⌟	⌜—⌟
SC-03	Tải tăng dần 10 đến 200 người dùng ảo trên API ngữ cảnh và cập nhật chuyến	Dịch vụ Chuyến đi và Điều phối	⌜—⌟	⌜—⌟	⌜—⌟	⌜—⌟	⌜—⌟

6.9. Kết quả khả năng phục hồi — NFR-04 (RQ1)

Bảng 6.12. Kết quả tiêm lỗi trên môi trường mô phỏng

Mã	Lỗi được tiêm	Kỳ vọng	Tỷ lệ phiên duy trì	Chỉ số bổ sung	Đạt
RS-01	Dừng Dịch vụ Nhật ký cuộc gọi giữa phiên	Phiên tiếp tục; bản ghi được ghi vào nhật ký	「—」	「—」	「—」
RS-02	Dịch vụ Chuyến đi và Điều phối trả lỗi 5xx hoặc quá thời gian chờ	Tác nhân thông báo không thực hiện được; phiên tiếp tục	「—」	「—」	「—」
RS-03	Dừng một bản sao tác nhân khi đang có phiên	Phiên mới được phục vụ bởi bản sao khác	「—」	Thời gian khôi phục: 「—」	「—」
RS-04	Nhà cung cấp dịch vụ thoại trả lỗi	Tác nhân thông báo không gọi được	「—」	「—」	「—」
RS-05	Nhà cung cấp STT, LLM hoặc TTS chính lỗi	Chuyển sang nhà cung cấp dự phòng; lượt vẫn được phản hồi	「—」	Độ trễ tăng thêm: 「—」	「—」

Trong khi chờ đợt tiêm lỗi có kiểm soát, nhật ký phát triển đã ghi nhận một trường hợp lỗi thật tương ứng kịch bản RS-02: ngày 06/09/2026, trong khoảng 235 lời gọi HTTP của tác nhân có một lời gọi gửi SMS trả mã 503 (Bảng 5.3). Tác nhân thông báo "Không thể gửi tin nhắn lúc này", phiên không bị ngắt và tài xế tiếp tục thực hiện thêm các nghiệp vụ khác (cập nhật trạng thái, báo khách không có mặt, hỏi thu nhập, đặt nhắc việc) trong cùng phiên. Quan sát này mới là một mẫu, chưa thay thế được Bảng 6.12.

6.10. Kết quả bảo mật — NFR-05

Bảng 6.13. Danh mục kiểm tra bảo mật

STT	Kiểm tra	Kỳ vọng	Kết quả	Bằng chứng
1	JWT đăng nhập chỉ do Dịch vụ Định danh phát hành	Dịch vụ khác chỉ xác minh	Đạt	Chỉ identity-service/src/services/ tokenService.ts ký access token và refresh token của người dùng; Dịch vụ Chuyến đi và Điều phối, Dịch vụ Giám sát vận hành và tác nhân chỉ ký token dịch vụ cho lời gọi giữa các dịch vụ
2	Tham số bí mật không nằm trong mã nguồn	Khai báo NoEcho, nạp từ tệp môi trường ngoài kho mã	Đạt	Template SAM/CloudFormation; tệp .env nằm trong danh sách bỏ qua của git
3	Nhật ký không chứa token hoặc mật khẩu	Chỉ mã phòng và mã lỗi	Đạt	Tìm kiếm trong nhật ký không thấy Bearer, chuỗi JWT, password, khóa API
4	Nhật ký không chứa số điện thoại đầy đủ	Số điện thoại được che	「—」	Cần kiểm tra lại: một số dòng nhật ký của tác nhân ghi số điện thoại khi đăng ký phiên
5	Tác nhân không truy cập cơ sở dữ liệu (CON-01)	Chỉ gọi HTTP	Đạt	Mã tác nhân không có trình điều khiển cơ sở dữ liệu
6	Vị trí khách chỉ lấy từ dữ liệu chuyến	Không đưa ra vị trí không có nguồn	Đạt (mẫu)	Câu trả lời vị trí trong phiên mẫu lấy từ API chuyến

6.11. Kết quả luồng khách hàng và giám sát vận hành qua trường hợp kiểm thử

Bảng 6.14. Kết quả trường hợp kiểm thử phía khách hàng và giám sát vận hành

Nhóm trường hợp kiểm thử	Nội dung kiểm tra	Trường hợp kiểm thử	Kết quả
Gọi khách từ tài xế	Đúng chế độ; không quay số khi thiếu chuyến	test_call_customer, test_ outbound_call_modes	Đạt
Tác nhân trao đổi với khách	Mở đầu đúng; không đưa ra thời gian đến hoặc giá khi thiếu dữ liệu; tóm tắt về tài xế	test_customer_outbound_ opening, test_customer_call_faq	Đạt
Ghi nhận yêu cầu khách	Yêu cầu chờ thêm, ghi chú được lưu và gửi tóm tắt	test_record_customer_ request, test_resolve_ customer_trip	Đạt
Chỉ số phiên (FR-O01)	Đếm độ trễ, câu đệm, công cụ, lỗi HTTP, dự phòng; không lỗi khi chưa có bộ thu	test_session_metrics (4 ca)	Đạt

Nhóm trường hợp kiểm thử	Nội dung kiểm tra	Trường hợp kiểm thử	Kết quả
Báo cáo ngày (FR-O01)	Số phiên, số tài xế, độ trễ trung bình/P95, tỷ lệ công cụ thành công, tỷ lệ API lỗi, lỗi hàng đầu, mẫu chấm lặp lại được, đếm kết quả chấm, suy ra loại phiên của bản ghi cũ	ops-service selfcheck báo cáo (npm run verify:ops)	Đạt
Báo cáo ngày trên dữ liệu thật (FR-O01, FR-O02)	Dựng lại báo cáo 5 ngày có dữ liệu (30/08–10/09/2026) từ bảng nhật ký cuộc gọi; trang giám sát hiển thị đúng số liệu (Hình 5.6)	Chạy cục bộ ops-service + call-records-service	Đạt; độ trễ chưa có vì bản ghi trước ngày có chỉ số phiên
Truy vấn bản ghi theo ngày	Quy đổi ngày giờ Việt Nam, biên ngày theo UTC	call-records-service selfcheck (npm run verify:records)	Đạt

Bộ kiểm thử tự động của tác nhân tại ngày 2026-09-06: 451/452 ca đạt (ca còn lại kiểm tra độ dài lời nhắc hệ thống); tại ngày 2026-09-27, sau khi bổ sung chỉ số phiên và dự phòng nhà cung cấp: 476/476 ca đạt. Kết quả đạt trường hợp kiểm thử chứng minh luồng khách hàng hoạt động trong phạm vi đã thiết kế, không suy ra mức hài lòng của khách hàng thật.

6.12. Tổng hợp và thảo luận theo câu hỏi nghiên cứu

Bảng 6.15. Tổng hợp kết quả theo yêu cầu

Yêu cầu	Kết quả chính	Trạng thái
NFR-02 Performance	Đợt đo 05–06/09/2026: luồng đầy đủ qua LLM P95 = 3,75 giây; thiết kế hiện hành: 「—」	Chưa đạt ở đợt đo 05–06/09; chờ đo lại
Nhận dạng giọng nói	WER 3,1% (yên tĩnh), 7,3% (nhiễu)	Đã đo (mẫu nhỏ)
FR (tính đúng chức năng)	≈ 88% đúng công cụ, ≈ 77% hoàn thành lần đầu	Đã đo (mẫu nhỏ)
NFR-01 Usability	5/5 tiêu chí đạt	Đạt
NFR-03 Scalability	「—」	Chờ số liệu
NFR-04 Resilience	「—」	Chờ số liệu

Yêu cầu	Kết quả chính	Trạng thái
NFR-05 Security	5/6 mục đạt; 1 mục cần kiểm tra lại	Đạt một phần
Luồng khách hàng	Các trường hợp kiểm thử đạt	Đạt
FR-O01, FR-O02	Kiểm thử tự động đạt; báo cáo dựng trên dữ liệu thật (Hình 5.6); chỉ số độ trễ có từ ngày triển khai chỉ số phiên	Đạt

RQ1 (kiến trúc, khả năng mở rộng và khả năng phục hồi). 「—」 Kết luận được rút ra sau khi có số liệu Bảng 6.11 và Bảng 6.12.

RQ2 (độ trễ). Trên 341 lượt của đợt đo 05–06/09/2026, luồng đầy đủ qua LLM chưa đạt ngưỡng (P95 = 3,75 giây), điểm nghẽn chính là thời gian LLM sinh token đầu (P95 ≈ 2,5 giây). Thiết kế hiện hành đưa mọi lượt qua LLM để bảo đảm tính đúng nghiệp vụ và dùng câu đệm để giảm cảm nhận chờ; hướng cải thiện là rút gọn lời nhắc hệ thống, giảm số vòng gọi công cụ hoặc dùng mô hình có thời gian sinh token đầu thấp hơn. Kết luận cuối cùng cho RQ2 phụ thuộc số liệu Bảng 6.6.

RQ3 (nhận dạng giọng nói). Tỷ lệ lỗi từ tăng từ 3,1% lên 7,3% khi có nhiễu mô phỏng khoang xe; nhiễu làm tăng lỗi thay từ mang nghĩa và sai chữ số trong địa chỉ.

RQ4 (gọi công cụ, hoàn thành nghiệp vụ). Khoảng 88% lượt chọn đúng công cụ và 77% hoàn thành đúng ngay lần đầu trên mẫu 39 lượt. Các nhóm lỗi chính là chọn sai thao tác với phát ngôn không rõ ý định, sai phạm vi tham số, câu nói khó nghe khi lái và chưa thực hiện thao tác sau khi xác nhận bằng lời.

6.13. Hạn chế và yếu tố ảnh hưởng đến độ tin cậy của kết luận

Điều kiện thử nghiệm thuận lợi hơn thực tế. Người đọc kịch bản biết trước câu nói nên phát âm trôi chảy hơn tài xế thật phải ứng biến; nhiễu mô phỏng không đại diện cho mọi khoang xe.

Môi trường mô phỏng cho thử tải và tiêm lỗi. Thử nghiệm khả năng mở rộng và khả năng phục hồi chạy trên một máy, không có độ trễ mạng thật giữa các vùng, nhà cung cấp AI được giả lập. Kết quả chứng minh tính chất kiến trúc (mở rộng theo chiều ngang, cô lập lỗi), không phải năng lực tải của hệ thống trên AWS thực tế.

Chỉ số không bao phủ mọi khái niệm. Độ trễ phản hồi đo trải nghiệm hội thoại, không đo an toàn giao thông thực địa; danh mục kiểm tra hành vi không thay thế khảo sát mức hài lòng dài hạn.

Cỡ mẫu nhỏ. Tỷ lệ lỗi từ đo với một người đọc; độ chính xác gọi công cụ đánh giá trên khoảng 39 lượt bởi một người. Luận văn nêu rõ cỡ mẫu và tránh kết luận tuyệt đối.

Số liệu độ trễ lấy từ nhật ký phát triển. 341 lượt trong hai ngày, một tài khoản thử nghiệm, kịch bản do tác giả đọc, còn lẫn một số lượt tự kiểm thử; việc phân loại nhánh xử lý dựa trên mô-đun nhận dạng ý định chỉ áp dụng cho đợt đo này; một lượt ngoại lệ khoảng 21 giây do nghẽn mạng vẫn được tính vào thống kê.

Phụ thuộc nhà cung cấp mô hình. Kết quả gắn với cấu hình STT, LLM, TTS của buổi đo (Phụ lục D).

Thiên lệch người đánh giá. Đợt đánh giá chính thức cần ít nhất hai người đánh giá độc lập theo cùng tiêu chí ở Bảng 6.9 và Bảng 6.10.

Kết luận chương

Chương 6 đã đánh giá nguyên mẫu theo từng yêu cầu. Kết quả hiện có cho thấy: luồng đầy đủ qua LLM chưa đạt ngưỡng độ trễ trong đợt đo 05–06/09/2026 với điểm nghẽn ở thời gian sinh token đầu; tỷ lệ lỗi từ tăng hơn gấp đôi trong điều kiện nhiễu; khoảng 88% lượt chọn đúng công cụ; các tiêu chí khả năng sử dụng và luồng khách hàng đạt; bảo mật đạt một phần. Số liệu khả năng mở rộng, khả năng phục hồi và độ trễ trên thiết kế hiện hành sẽ được bổ sung sau đợt thử nghiệm trên môi trường mô phỏng.

Kết luận và hướng phát triển

Luận văn đã thực hiện chu trình thiết kế – xây dựng – đánh giá cho một trợ lý AI bằng giọng nói hỗ trợ tài xế xe công nghệ. Từ các nghiệp vụ thường xuyên của tài xế, Chương 3 xác định các yêu cầu chức năng gắn với thành phần phụ trách và năm yêu cầu phi chức năng (khả năng sử dụng, hiệu năng, khả năng mở rộng, khả năng phục hồi, bảo mật) được phân loại theo ISO/IEC 25010 và đặc tả dưới dạng kịch bản đo được. Các yêu cầu phi chức năng này là động lực để Chương 4 lựa chọn kiến trúc microservices trên AWS, trong đó tác nhân hội thoại chạy trên container tách khỏi các dịch vụ nghiệp vụ chạy trên FaaS, mỗi dịch vụ sở hữu dữ liệu riêng. Chương 5 hiện thực kiến trúc này thành nguyên mẫu chạy đầu cuối trên WebRTC và SIP, kèm hạ tầng dạng mã cho từng dịch vụ.

Kết quả đánh giá ở Chương 6 được nêu kèm nguồn và cỡ mẫu. Trên 341 lượt hội thoại trích từ nhật ký phát triển (05–06/09/2026), các lượt đi qua mô hình ngôn ngữ có P95 độ trễ phản hồi 3,75 giây, chưa đạt ngưỡng 2 giây; thành phần lớn nhất là thời gian mô hình sinh token đầu (Bảng 6.4, 6.5). Tỷ lệ lỗi từ tăng từ 3,1% lên 7,3% khi thêm nhiễu mô phỏng khoang xe (một người đọc, 22 câu). Trên mẫu khoảng 39 lượt do một người đánh giá, 88% lượt chọn đúng công cụ và 77% hoàn thành nghiệp vụ ngay lần đầu. Các tiêu chí khả năng sử dụng, luồng khách hàng và báo cáo vận hành ngày đạt ở mức kiểm thử; danh mục bảo mật đạt 5/6 mục (mục che số điện thoại trong nhật ký còn phải kiểm tra lại). Số liệu khả năng mở rộng, khả năng phục hồi và độ trễ trên thiết kế hiện hành sẽ được bổ sung sau đợt thử nghiệm trên môi trường mô phỏng.

Các hạn chế chính của luận văn:

- Cỡ mẫu nhỏ, dữ liệu lấy từ môi trường phát triển, chưa khảo sát trên đường thật.
- Thử tải và cố ý gây lỗi thực hiện trên môi trường mô phỏng, không trên hạ tầng AWS thật.
- Kết quả phụ thuộc mô hình STT, LLM, TTS của nhà cung cấp bên ngoài.
- Chưa huấn luyện lại mô hình nhận dạng giọng nói cho tiếng Việt trong khoang xe.

Hướng phát triển:

- Đo lại độ trễ trên thiết kế hiện hành với kịch bản có gắn nhãn, kịch bản mù và nhiều người đọc.
- Giảm thời gian sinh token đầu: rút gọn lời nhắc hệ thống, giảm số vòng gọi công cụ hoặc dùng mô hình nhanh hơn.
- Thử tải trên hạ tầng AWS thật với tự động điều chỉnh số bản sao tác nhân.
- Bổ sung ngôn ngữ và giọng vùng miền.
- Thử nghiệm thực địa có kiểm soát an toàn để đo tác động tới thao tác nhìn và chạm khi lái.

Tài liệu tham khảo

Danh mục dưới đây gồm các nguồn được trích dẫn trong luận văn, xếp theo thứ tự chữ cái của tác giả.

[1] Alvarado Contreras, R. E., Escobedo, L., & Beltrán, J. (2024). AI Companions in Ride-Hailing: Enhancing Sense of Safety with Voice Chatbots. Avances en Interacción Humano-Computadora, 9(1), 11–15. https://doi.org/10.47756/aihc.y9i1.138

[2] Alvestrand, H. (2021). Overview: Real-Time Protocols for Browser-Based Applications (RFC 8825). IETF. https://www.rfc-editor.org/rfc/rfc8825

[3] Amazon Web Services. (2024). AWS Well-Architected Framework (Reliability Pillar; Performance Efficiency Pillar). https://docs.aws.amazon.com/wellarchitected/latest/framework/

[4] Bass, L., Clements, P., & Kazman, R. (2021). Software Architecture in Practice (4th ed.). Addison-Wesley. ISBN 978-0-13-688597-9

[5] Chen, Y., Yue, X., Zhang, C., Gao, X., Tan, R. T., & Li, H. (2024). VoiceBench: Benchmarking LLM-Based Voice Assistants. arXiv:2410.17196. https://arxiv.org/abs/2410.17196

[6] Dingus, T. A., Guo, F., Lee, S., Antin, J. F., Perez, M., Buchanan-King, M., & Hankey, J. (2016). Driver crash risk factors and prevalence evaluation using naturalistic driving data. Proceedings of the National Academy of Sciences, 113(10), 2636–2641. https://doi.org/10.1073/pnas.1513271113

[7] Dragoni, N., Giallorenzo, S., Lluch Lafuente, A., Mazzara, M., Montesi, F., Mustafin, R., & Safina, L. (2017). Microservices: Yesterday, today, and tomorrow. In M. Mazzara & B. Meyer (Eds.), Present and Ulterior Software Engineering (pp. 195–216). Springer. https://doi.org/10.1007/978-3-319-67425-4_12

[8] Insurance Institute for Highway Safety. (n.d.). Distracted driving. https://www.iihs.org/research-areas/distracted-driving

[9] ISO/IEC. (2023). ISO/IEC 25010:2023 Systems and software engineering — Systems and software Quality Requirements and Evaluation (SQuaRE) — Product quality model. https://www.iso.org/standard/78176.html

[10] Jonas, E., Schleier-Smith, J., Sreekanti, V., Tsai, C.-C., Khandelwal, A., Pu, Q., Shankar, V., Carreira, J., Krauth, K., Yadwadkar, N., Gonzalez, J. E., Popa, R. A., Stoica, I., & Patterson, D. A. (2019). Cloud Programming Simplified: A Berkeley View on Serverless Computing. arXiv:1902.03383. https://arxiv.org/abs/1902.03383

[11] Lewis, J., & Fowler, M. (2014, March 25). Microservices: A definition of this new architectural term. https://martinfowler.com/articles/microservices.html

[12] LiveKit Inc. (n.d.). Agents. LiveKit Documentation. https://docs.livekit.io/agents/

[13] Lyu, T., Feng, S., Liu, H., & Yang, H. (2025). LLM-ODDR: A Large Language Model Framework for Joint Order Dispatching and Driver Repositioning. arXiv:2505.22695. https://arxiv.org/abs/2505.22695

[14] National Highway Traffic Safety Administration. (2013). Visual-Manual NHTSA Driver Distraction Guidelines for In-Vehicle Electronic Devices. Federal Register, 78 FR 24817. https://www.transportation.gov/regulations/federal-register-documents/2013-09883

[15] Newman, S. (2021). Building Microservices: Designing Fine-Grained Systems (2nd ed.). O'Reilly Media. ISBN 978-1-492-03402-5

[16] Richardson, C. (2018). Microservices Patterns: With examples in Java. Manning. ISBN 978-1-61729-454-9

[17] Schick, T., Dwivedi-Yu, J., Dessì, R., Raileanu, R., Lomeli, M., Hambro, E., Zettlemoyer, L., Cancedda, N., & Scialom, T. (2023). Toolformer: Language Models Can Teach Themselves to Use Tools. arXiv:2302.04761. https://arxiv.org/abs/2302.04761

[18] Soldani, J., Tamburri, D. A., & Van Den Heuvel, W.-J. (2018). The pains and gains of microservices: A Systematic grey literature review. Journal of Systems and Software, 146, 215–232. https://doi.org/10.1016/j.jss.2018.09.082

[19] Stivers, T., Enfield, N. J., Brown, P., Englert, C., Hayashi, M., Heinemann, T., Hoymann, G., Rossano, F., de Ruiter, J. P., Yoon, K.-E., & Levinson, S. C. (2009). Universals and cultural variation in turn-taking in conversation. Proceedings of the National Academy of Sciences, 106(26), 10587–10592. https://doi.org/10.1073/pnas.0903616106

Phụ lục

Phụ lục gồm: A — danh mục công cụ; B — kịch bản hội thoại mẫu; C — ảnh giao diện; D — cấu hình môi trường (không chứa bí mật); E — ma trận đối chiếu yêu cầu; F — bảng đối chiếu sequence diagram với mã nguồn; G — bảng ánh xạ tên thành phần.

Phụ lục A. Danh mục công cụ của trợ lý giọng nói

Bảng A.1 liệt kê 45 công cụ (function tool) của gói ngôn ngữ tiếng Việt: 39 công cụ cho phiên tài xế trong ứng dụng (trong đó confirm_trip và reject_trip cũng là tập công cụ của phiên mời nhận chuyến) và 7 công cụ cho phiên khách hàng (answer_app_faq dùng chung). Gói tiếng Anh có cùng 39 công cụ cho tài xế. Mô tả rút gọn từ lược đồ công cụ trong mã nguồn (voicebot/locales/vn/tools_definition.py).

Bảng A.1. Danh mục công cụ gói tiếng Việt (45 công cụ)

STT	Tên công cụ	Mô tả ngắn
1	check_upcoming_trips	Đếm/liệt kê chuyến theo phạm vi; mặc định chỉ nói số chuyến rồi hỏi chi tiết chuyến nào.
2	create_walkup_trip	Tài xế tạo chuyến cho khách vãng lai; chuyến được tạo ở trạng thái đã xác nhận.
3	refresh_latest_data	Lấy dữ liệu trực tiếp cho chủ đề vừa trả lời (lịch, thu nhập, chuyến hiện tại…).
4	get_current_trip_info	Thông tin chuyến đang chạy: khách, số điện thoại, điểm đón – trả, giá, thời gian dự kiến, trạng thái.
5	suggest_next_stop	Gợi ý nên đón/trả khách nào tiếp theo dựa trên vị trí tài xế và toàn bộ lịch trình.
6	get_optimal_route	Thứ tự tối ưu để ghé tất cả các điểm đón/trả đang chờ theo khoảng cách đường bộ thực tế.
7	get_trip_traffic	Tình trạng giao thông trên chuyến: kẹt xe, thời gian dự kiến, tuyến đường.
8	update_trip_status	Cập nhật tiến độ của chuyến đã nhận (không dùng để nhận chuyến mới).
9	call_customer	Gọi khách của một chuyến.
10	call_custom_number	Bước 1: gọi tới một số điện thoại bất kỳ do tài xế đọc ra (không phải khách của chuyến).
11	confirm_call_custom_number	Bước 2: thực hiện gọi số tự do sau khi tài xế xác nhận đúng số.

STT	Tên công cụ	Mô tả ngắn
12	find_contact	Bước 1: tìm người trong danh bạ của tài xế theo tên để gọi.
13	select_contact_match	Chọn đúng người khi danh bạ trả về nhiều kết quả trùng tên.
14	confirm_contact_call	Bước cuối: gọi thật tới người trong danh bạ đã xác nhận.
15	send_sms_to_customer	Gửi SMS nội dung tự do cho khách của chuyến đang hoạt động.
16	send_sms_to_custom_number	Bước 1: gửi SMS tới một số bất kỳ do tài xế đọc ra.
17	confirm_send_sms_to_custom_number	Bước 2: gửi SMS tới số tự do sau khi tài xế xác nhận số và nội dung.
18	find_contact_to_message	Bước 1: tìm người trong danh bạ theo tên để nhắn tin.
19	select_contact_match_for_sms	Chọn đúng người khi tìm danh bạ để nhắn tin trả về nhiều kết quả.
20	confirm_send_sms_to_contact	Bước cuối: gửi tin nhắn thật tới người trong danh bạ đã xác nhận.
21	get_customer_location	Lấy địa điểm đón khách hiện tại.
22	confirm_trip_with_customer	Gửi SMS xác nhận chuyến đi cho khách.
23	summarize_last_call	Lấy và đọc tóm tắt cuộc gọi với khách.
24	check_customer_call_status	Kiểm tra cuộc gọi khách chạy nền còn đang diễn ra không.
25	create_reminder	Đặt nhắc nhở tự động trước giờ đón khách.
26	request_cancel_trip	Bước 1: hỏi xác nhận trước khi hủy chuyến đang hoạt động.
27	confirm_cancel_trip	Bước 2: thực hiện hủy chuyến sau khi tài xế xác nhận.
28	get_today_earnings	Xem tổng thu nhập hôm nay: doanh thu, số chuyến, thưởng, giờ online.
29	get_earnings_summary	Xem thu nhập theo tuần (7 ngày) hoặc tháng (30 ngày).
30	check_trip_history	Xem chuyến đã hoàn thành hoặc bị hủy trong hôm nay.
31	get_driver_stats	Xem thống kê tài xế: điểm đánh giá, tỷ lệ nhận, tỷ lệ hoàn thành, tổng số chuyến.
32	report_customer_no_show	Báo cáo khách không xuất hiện tại điểm đón.
33	report_trip_issue	Báo cáo sự cố trong chuyến: hành vi không phù hợp, hư hỏng xe, địa chỉ sai…
34	extend_wait_time	Yêu cầu thêm thời gian chờ khách tại điểm đón.
35	set_driver_status	Chuyển trạng thái tài xế: online (nhận chuyến) hoặc offline (nghỉ).

STT	Tên công cụ	Mô tả ngắn
36	confirm_trip	Xác nhận nhận một chuyến đi mới (đang chờ/thông báo, chưa nhận).
37	reject_trip	Từ chối một chuyến đi mới chưa nhận.
38	book_trip	Đặt một chuyến xe mới cho khách (luồng khách).
39	get_my_trip	Lấy thông tin chuyến hiện tại của khách: trạng thái, tài xế, thời gian dự kiến, địa chỉ.
40	request_cancel_my_trip	Bước 1: hỏi xác nhận trước khi hủy chuyến của khách.
41	confirm_cancel_my_trip	Bước 2: thực hiện hủy chuyến sau khi khách xác nhận.
42	get_driver_eta	Lấy thời gian dự kiến tài xế đến và vị trí tài xế (luồng khách).
43	call_driver	Kết nối trực tiếp khách với tài xế qua điện thoại.
44	answer_app_faq	Tra cứu sổ tay hướng dẫn ứng dụng để trả lời câu hỏi tính năng / cách dùng / quy trình.
45	end_conversation	Chủ động kết thúc cuộc gọi với trợ lý theo yêu cầu tài xế.

Phụ lục B. Kịch bản thoại mẫu

Phụ lục này trích một số lượt thoại thực tế từ nhật ký phiên (đã che thông tin định danh), minh họa một đường STT → LLM kèm công cụ → TTS cho câu quen thuộc, xử lý im lặng và kết thúc phiên lịch sự. Nhãn thời gian là độ trễ cảm nhận (user_stop_to_agent_speak); khi phản hồi chậm khoảng từ hai giây, hệ thống có thể xen câu giữ chỗ ngắn trước câu trả lời thật.

Kịch bản B.1 — Tra cứu lịch trình và thông tin chuyến (phiên trong ứng dụng, 2026-09-06)

Trợ lý: Chào bạn, tôi là Czen, trợ lý AI của bạn.
Trợ lý: Tôi có thể giúp gì cho bạn?
Tài xế: Tôi muốn kiểm tra lịch trình hôm nay. [LLM + công cụ — check_upcoming_trips]
Trợ lý: Bạn có 11 chuyến sắp tới.
Tài xế: Chuyến đầu tiên đi đâu? [LLM + FollowUpKnowledge — 3,4 giây]
Trợ lý: Chuyến đầu tiên đón tại Mỹ Đình và trả ở Đông Anh.
Tài xế: Đón người khách tên là gì? [LLM + FollowUpKnowledge — 2,1 giây]
Trợ lý: Khách tên là Khách Mỹ Đình.
Tài xế: Ok, cảm ơn. [LLM — conversational_ack]

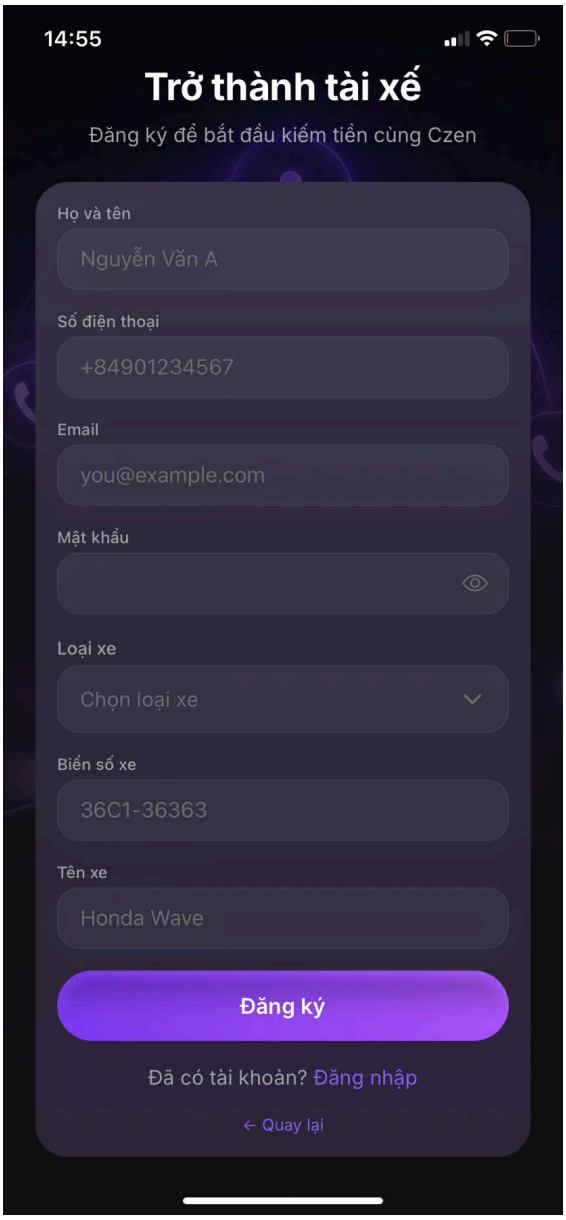
Trợ lý: Không có gì.
(im lặng ~15 giây)
Trợ lý: Bạn còn đó không?
(im lặng lần hai)
Trợ lý: Nếu bạn không còn câu hỏi nào nữa, em xin phép kết thúc cuộc gọi ở đây. Tạm biệt bạn!
Kết quả: hệ thống gọi POST /api/v1/voice/end-session và nhận mã 200.

Kịch bản B.2 — Nhận chuyến qua cuộc gọi mời nhận chuyến (phiên SIP, tập công cụ hẹp)

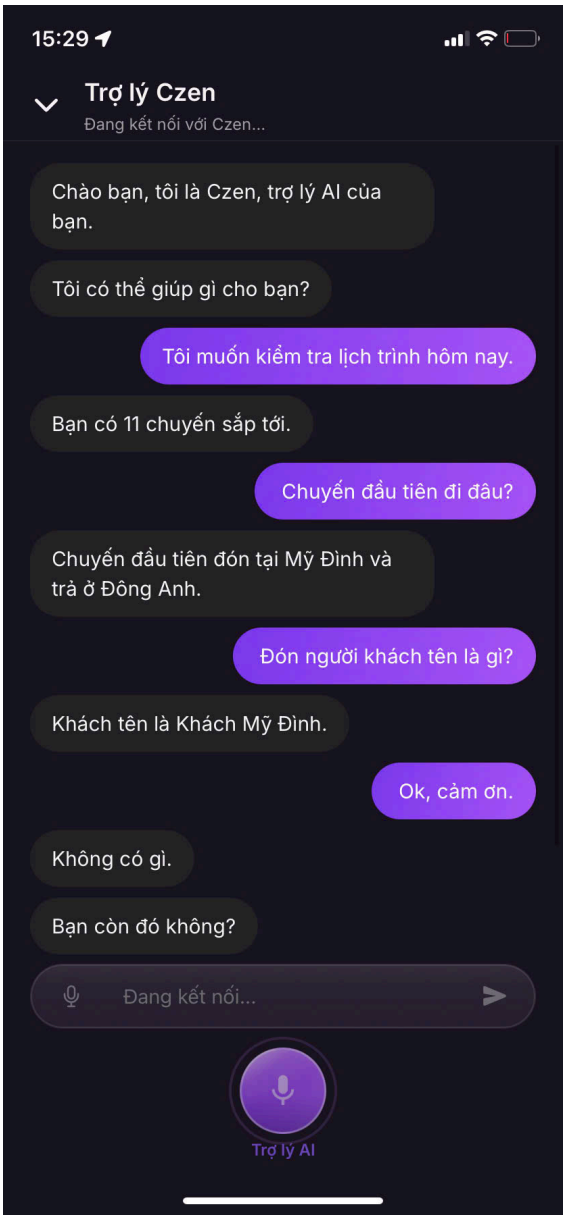
Trợ lý: Có chuyến mới đón tại 88 Pasteur, Quận 3. Bạn có nhận chuyến này không?
Tài xế: Xác nhận nhận chuyến. [LLM + công cụ — confirm_trip]
Trợ lý: Đã nhận chuyến. Chúc bạn đi đường an toàn.

Phụ lục C. Ảnh màn hình ứng dụng và trang quản trị

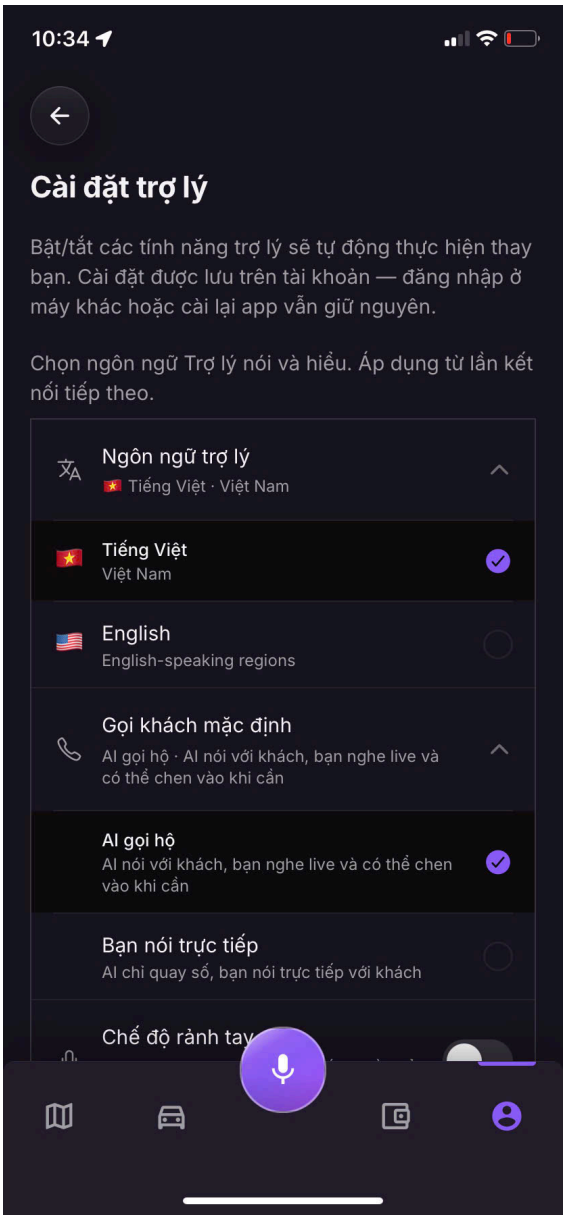
Các ảnh dưới đây minh họa giao diện nguyên mẫu ở thời điểm chụp. Thông tin định danh trong ảnh (số điện thoại, thư điện tử, biển số…) thuộc tài khoản thử nghiệm nội bộ; khi in ấn có thể che trực tiếp trên bản DOCX.



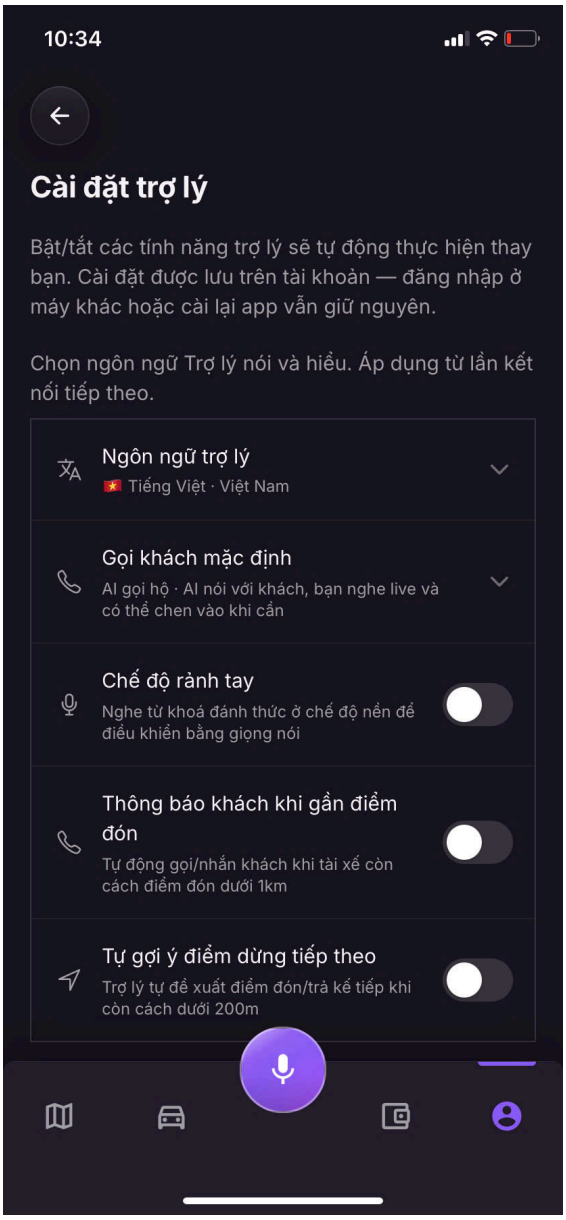
Hình C.1. Màn hình đăng ký trở thành tài xế trên ứng dụng Czen Driver.



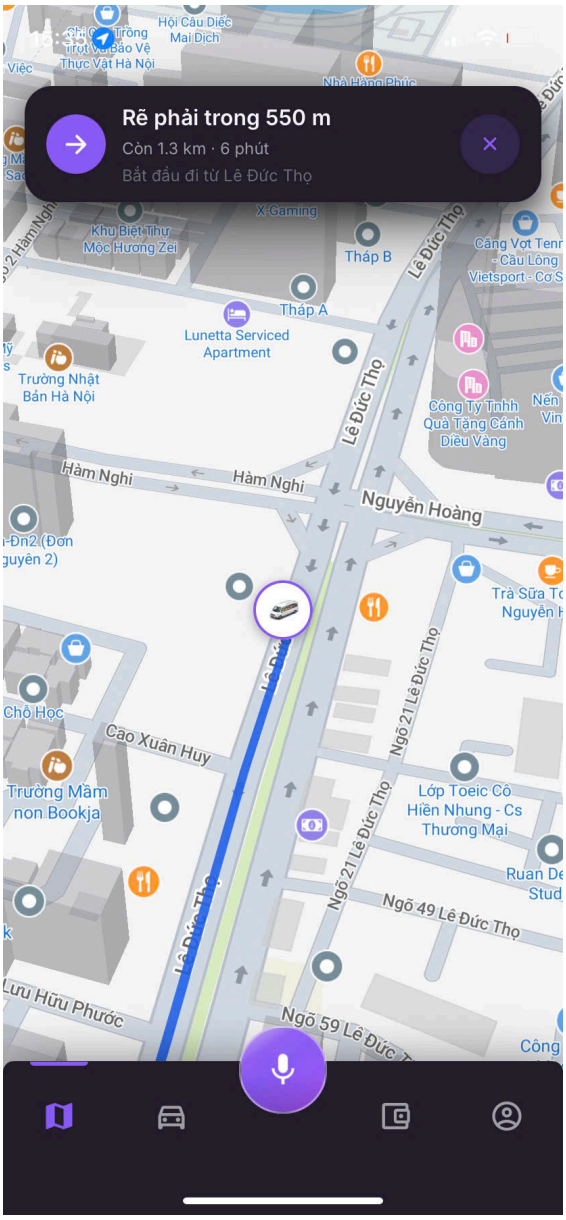
Hình C.2. Biểu tượng trợ lý giọng nói ở trạng thái đang kết nối.



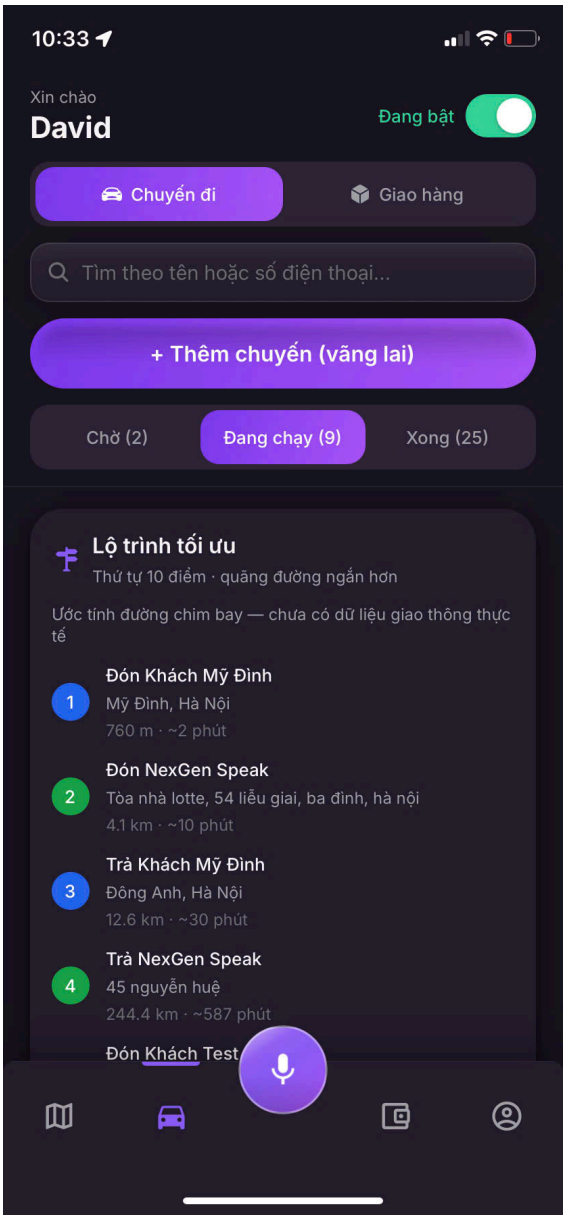
Hình C.3. Cài đặt trợ lý: chọn ngôn ngữ và chế độ gọi khách mặc định (tác nhân gọi thay hoặc tài xế nói trực tiếp).



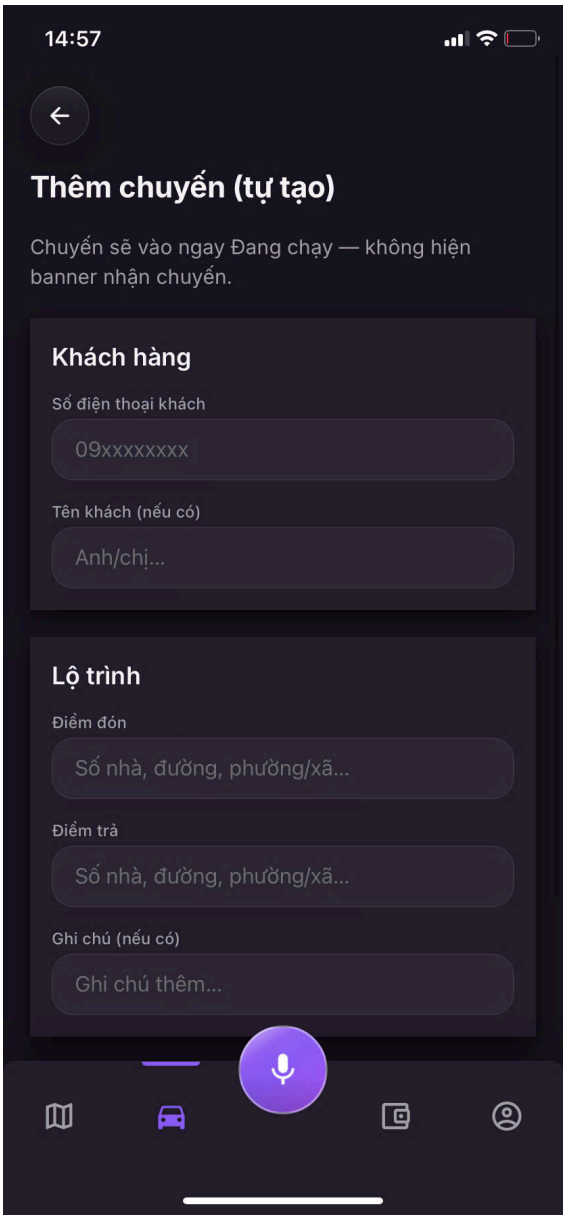
Hình C.4. Cài đặt trợ lý: kích hoạt rảnh tay bằng từ khóa đánh thức và các tùy chọn nhắc khách.



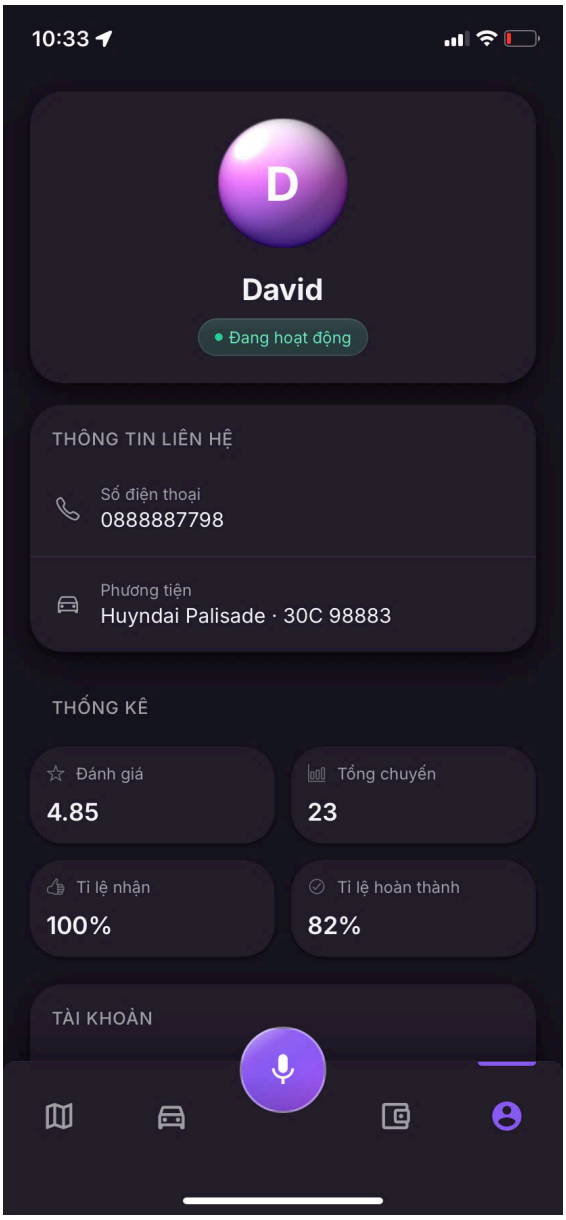
Hình C.5. Màn hình dẫn đường trên bản đồ của ứng dụng tài xế (chức năng bản đồ, không thuộc trợ lý giọng nói): hướng rẽ, khoảng cách và thời gian còn lại.



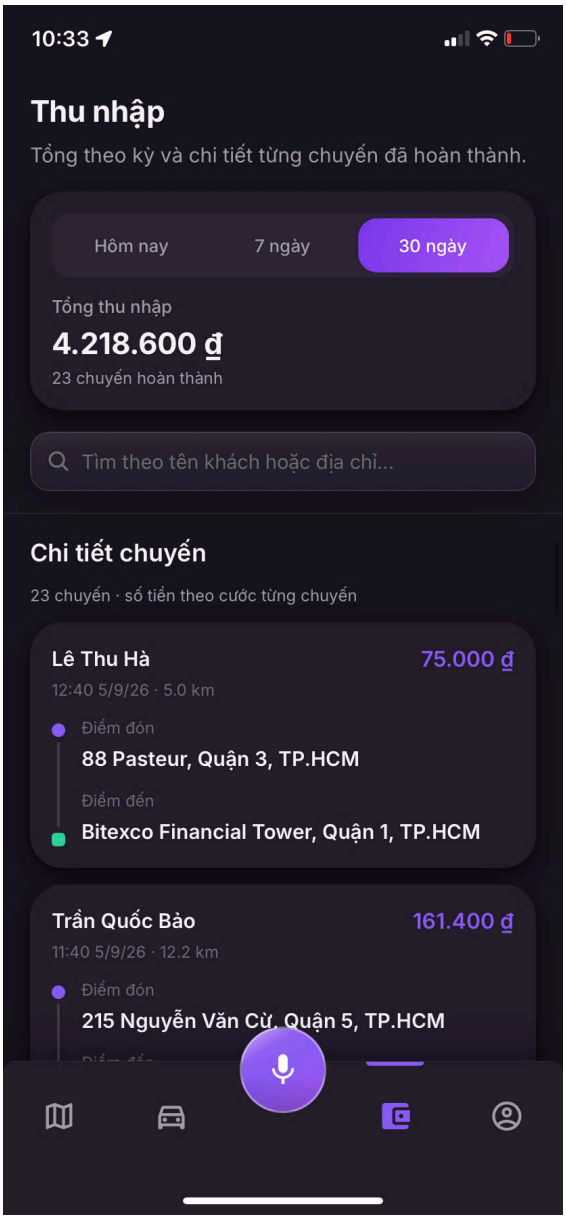
Hình C.6. Gợi ý lộ trình tối ưu cho nhiều điểm đón/trả trong danh sách chuyến đang chạy.



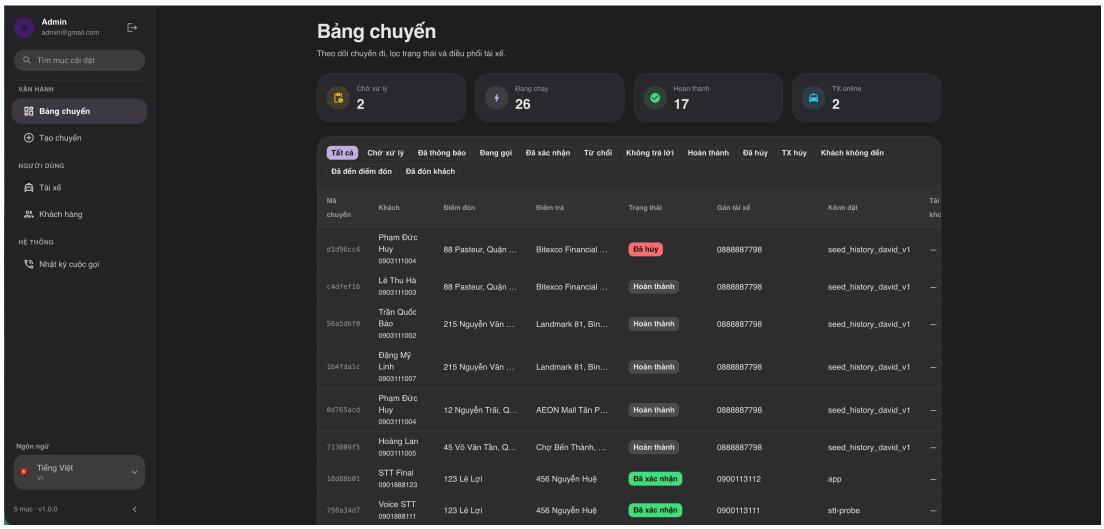
Hình C.7. Tài xế tự tạo chuyến cho khách vãng lai, kèm các yêu cầu đặc biệt (hàng cồng kềnh, đi cùng trẻ em).



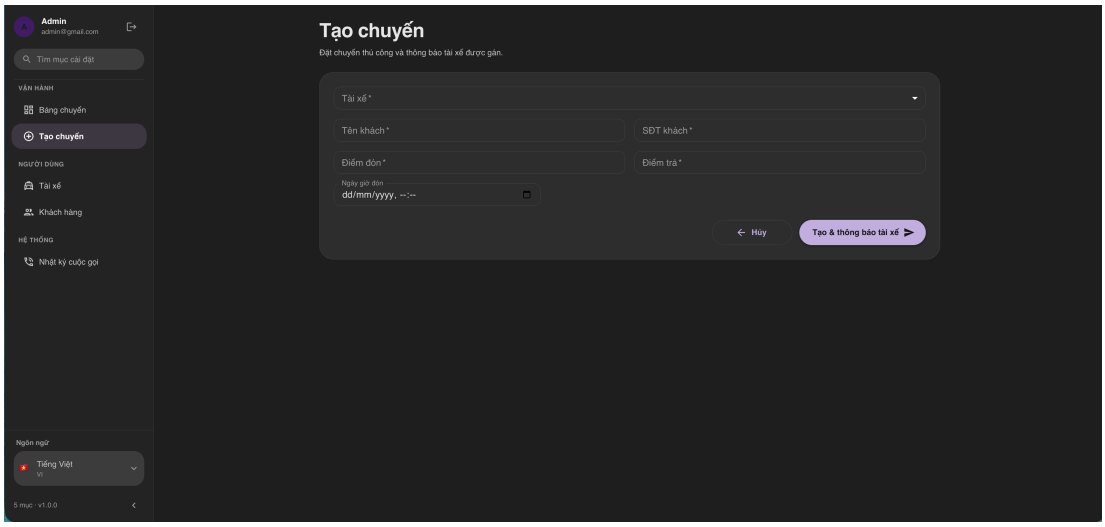
Hình C.8. Màn hình hồ sơ tài xế và các chỉ số vận hành (đánh giá, số chuyến, tỷ lệ nhận/hoàn thành).



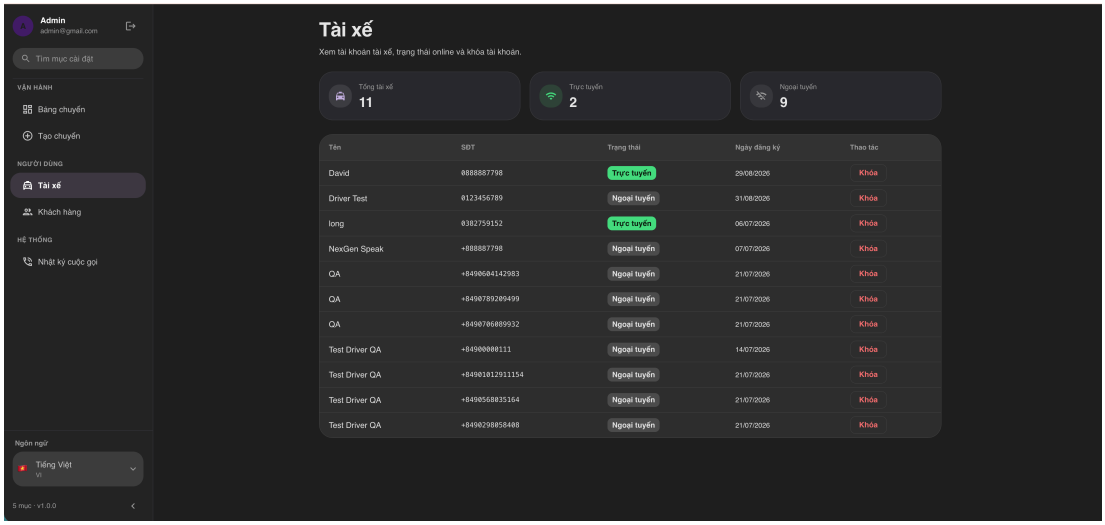
Hình C.9. Màn hình thu nhập theo kỳ và chi tiết cước từng chuyến đã hoàn thành.



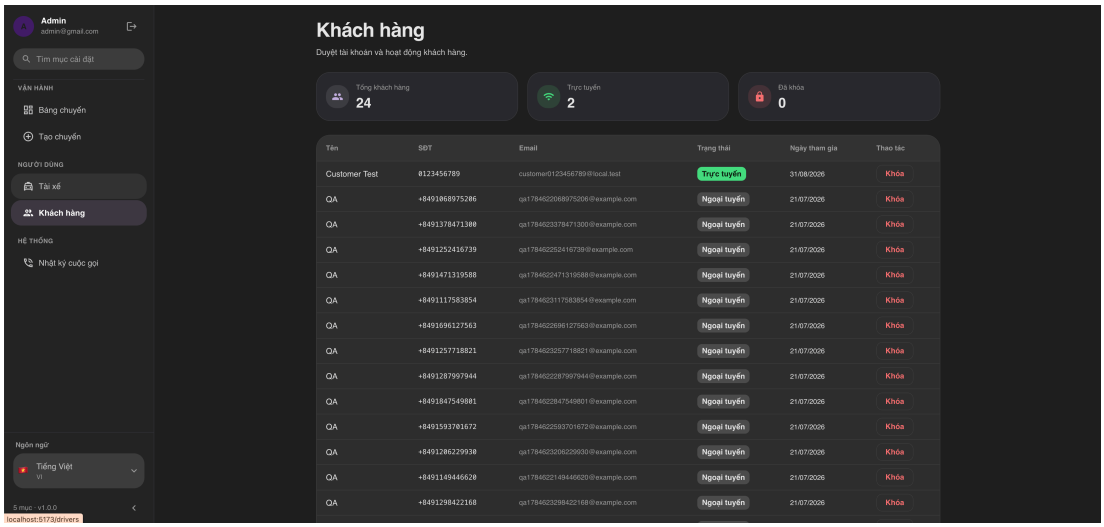
Hình C.10. Trang quản trị: bảng điều phối chuyến, lọc trạng thái và gán tài xế.



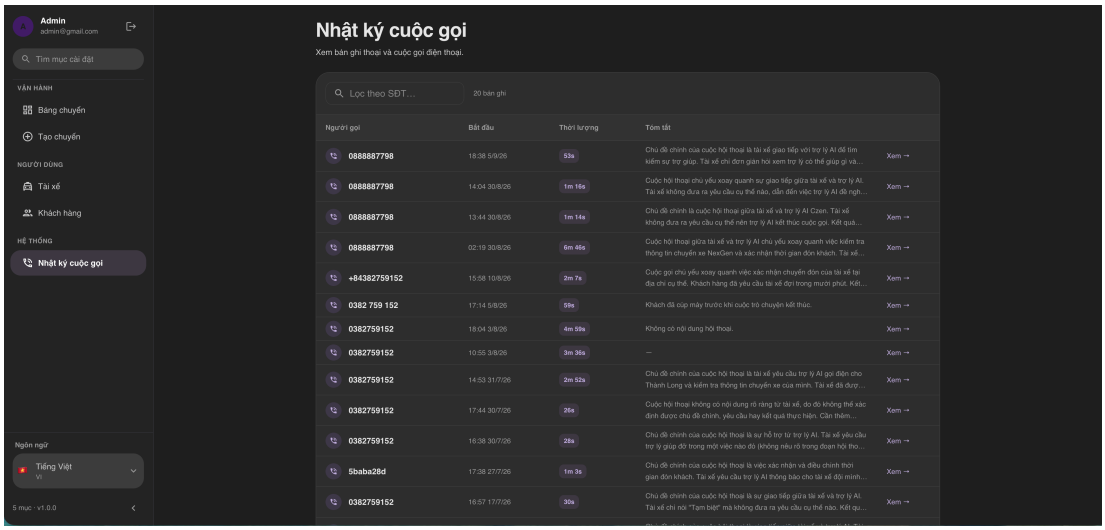
Hình C.11. Trang quản trị: tạo chuyến thử nghiệm và thông báo cho tài xế được gán.



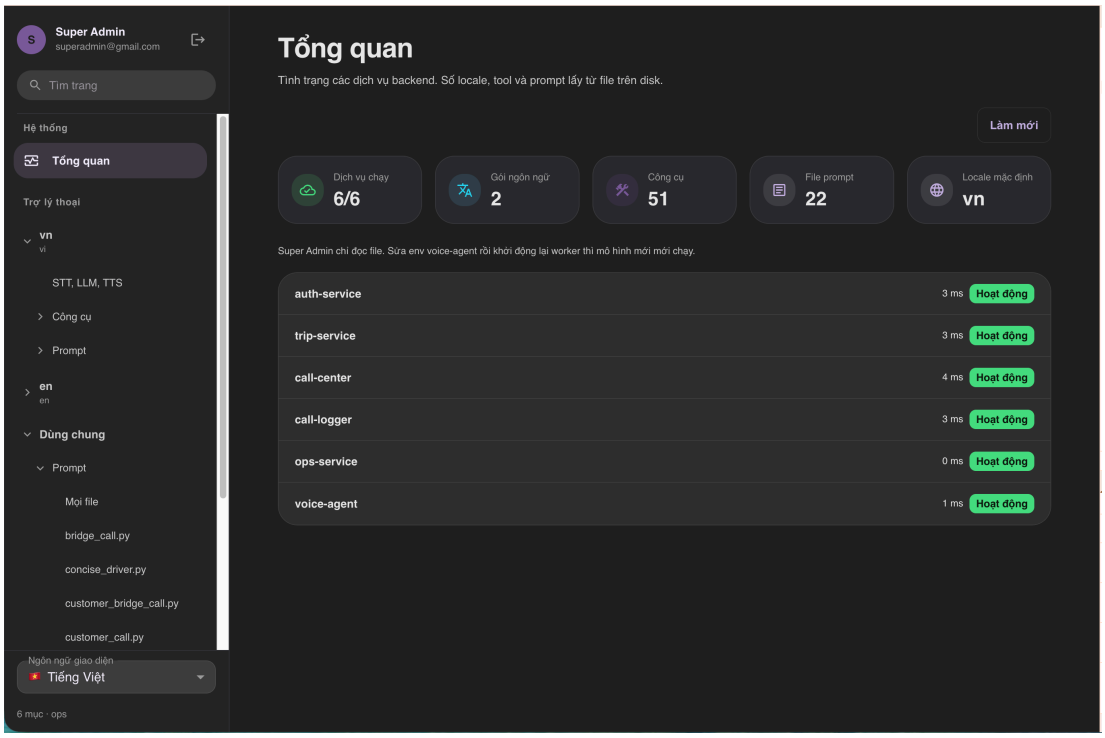
Hình C.12. Trang quản trị: danh sách tài xế, trạng thái trực tuyến và khóa tài khoản.



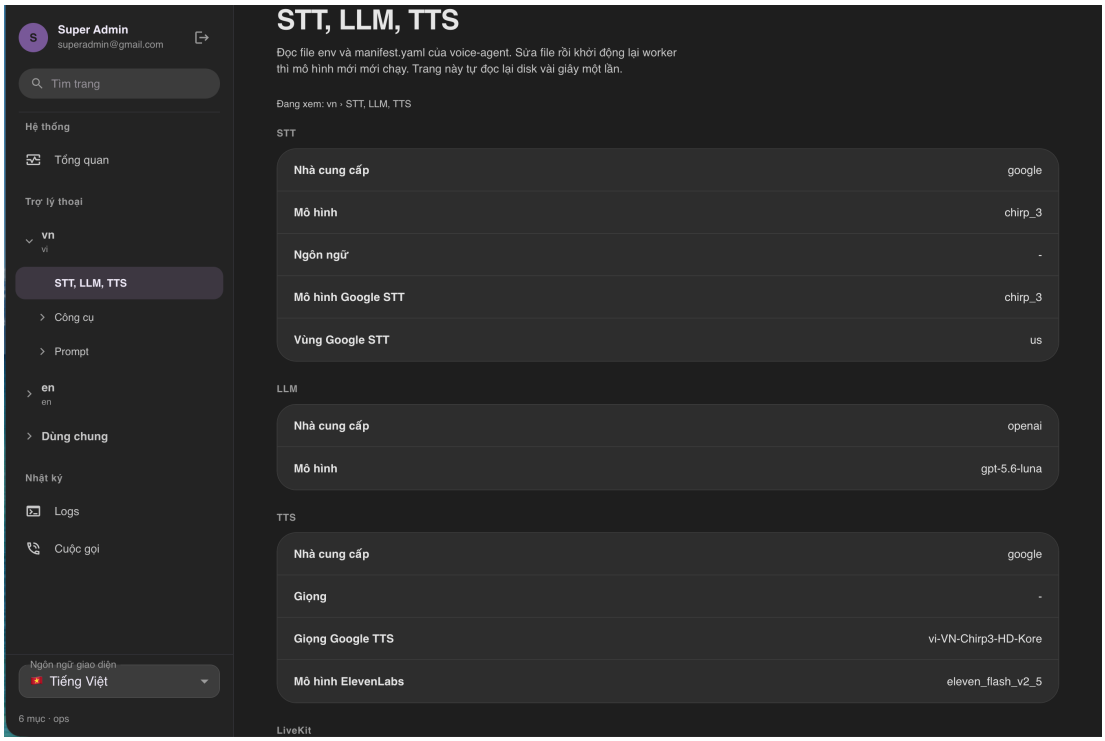
Hình C.13. Trang quản trị: danh sách khách hàng và trạng thái tài khoản.



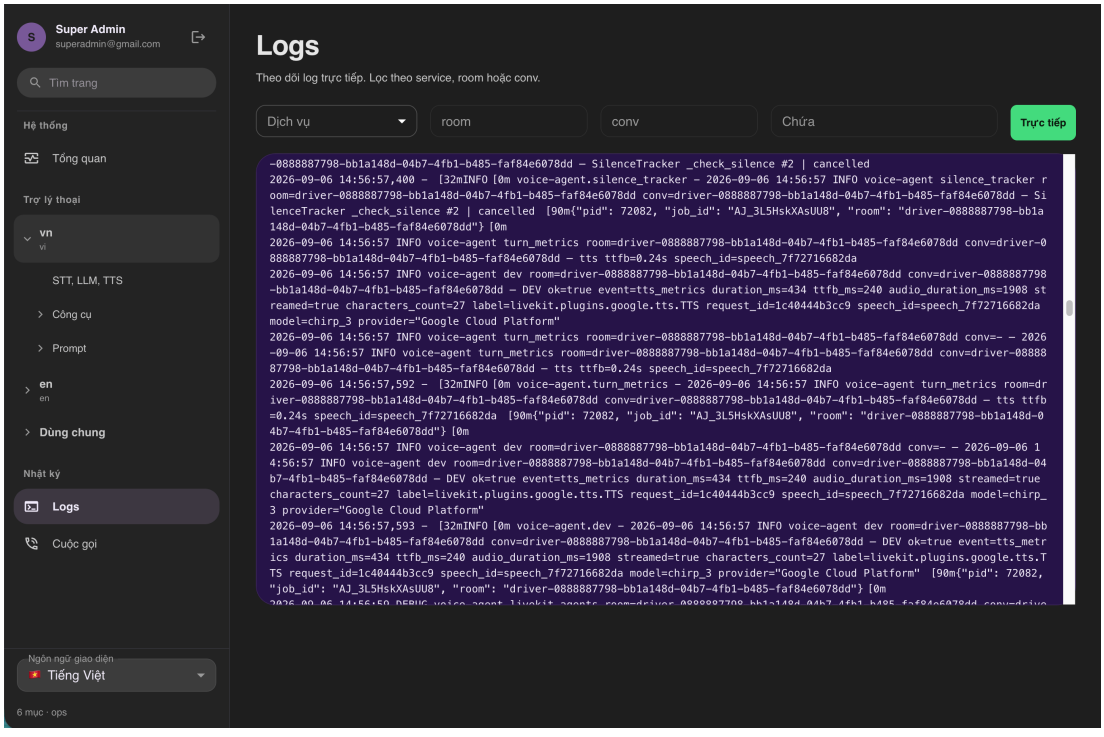
Hình C.14. Trang quản trị: nhật ký cuộc gọi kèm tóm tắt nội dung hội thoại.



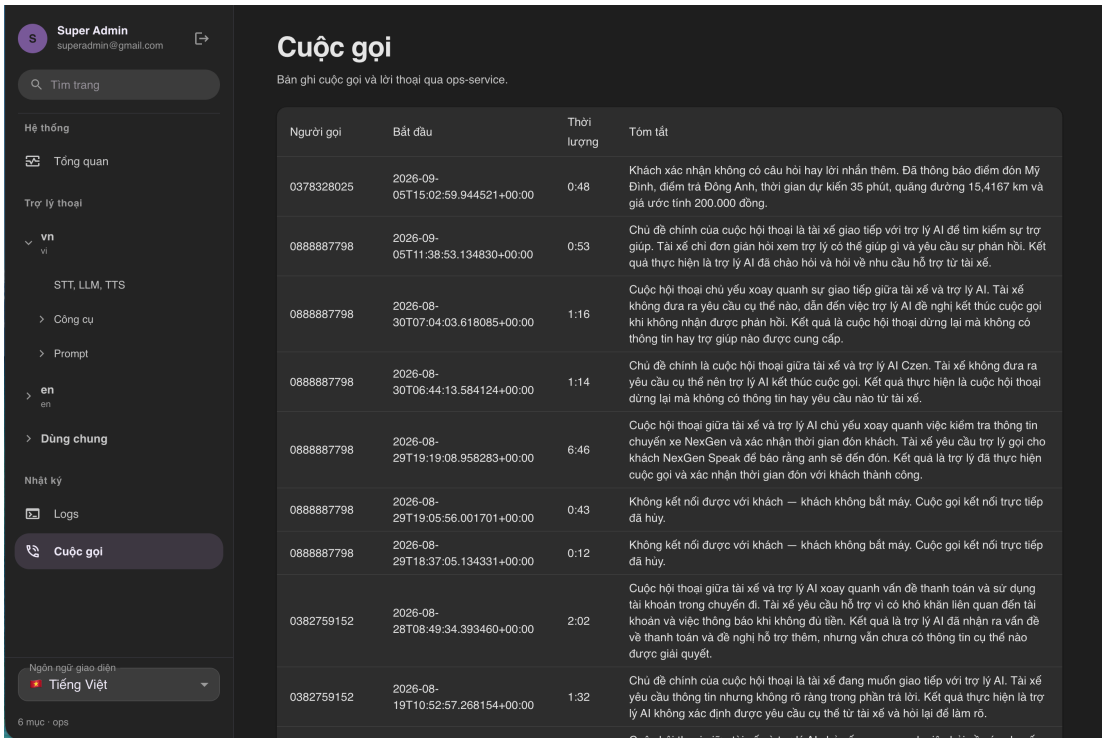
Hình C.15. Trang giám sát hệ thống: tình trạng hoạt động của các dịch vụ backend (6/6 đang chạy).



Hình C.16. Trang giám sát hệ thống: cấu hình chuỗi STT – LLM – TTS của tác nhân hội thoại theo gói ngôn ngữ.



Hình C.17. Trang giám sát hệ thống: nhật ký thời gian thực của các dịch vụ, dùng để đọc độ trễ tổng hợp giọng nói (TTFB).



Hình C.18. Trang giám sát hệ thống: bản ghi và tóm tắt cuộc gọi, lấy qua Dịch vụ Giám sát vận hành.

Phụ lục D. Cấu hình môi trường triển khai

Bảng D.1 tóm tắt cấu hình chính của tác nhân hội thoại. Cấu hình không bí mật nằm trong tệp envs/config.<môi trường>.toml, khóa bí mật nằm trong tệp .env không đưa vào kho mã nguồn; tệp mẫu envs/config.example.toml và envs/.env.example được cung cấp để tái lập môi trường. Cột cuối ghi giá trị dùng cho số liệu Chương 6.

Bảng D.1. Cấu hình chính của tác nhân hội thoại

Biến	Ý nghĩa	Giá trị
AGENT_LANG	Gói ngôn ngữ mặc định của tác nhân	vn (lựa chọn: vn / en)
STT_PROVIDER	Nhà cung cấp nhận dạng giọng nói	google (lựa chọn: openai / deepgram / inference)
GOOGLE_STT_MODEL	Mô hình STT của Google	chirp_3
STT_LANGUAGE	Ngôn ngữ nhận dạng (BCP-47)	vi-VN
LLM_PROVIDER	Nhà cung cấp mô hình ngôn ngữ	openai (lựa chọn: gemini / kimi)
LLM_MODEL	Mô hình ngôn ngữ	gpt-5.6-luna

Biến	Ý nghĩa	Giá trị
TTS_PROVIDER	Nhà cung cấp tổng hợp giọng nói	google (lựa chọn: elevenlabs / gemini / openai)
GOOGLE_TTS_VOICE	Giọng đọc tiếng Việt	vi-VN-Chirp3-HD-Kore
GOOGLE_TTS_SPEAKING_RATE	Tốc độ đọc	0,95
GOOGLE_TTS_PITCH	Cao độ giọng	-2,0
STT_FALLBACK, LLM_FALLBACK, TTS_FALLBACK	Nhà cung cấp dự phòng (danh sách, phân cách bằng dấu phẩy)	Không cấu hình trong đợt đo
EXTERNAL_API_SERVICE_URL	Địa chỉ Dịch vụ Chuyến đi và Điều phối	http://localhost:8002 (cục bộ)
CALL_RECORDS_SERVICE_URL	Địa chỉ Dịch vụ Nhật ký cuộc gọi	http://localhost:8001 (cục bộ)
LIVEKIT_URL	Địa chỉ LiveKit Cloud	wss://<tên-project>.livekit.cloud

Không đưa khóa API, token LiveKit, mật khẩu hay đường dẫn credential vào luận văn.

Phụ lục E. Ma trận đối chiếu yêu cầu

Bảng E.1 liên kết từng yêu cầu với câu hỏi nghiên cứu, thành phần, sequence diagram, hiện thực trong mã nguồn, kịch bản đánh giá và bảng kết quả ở Chương 6.

Bảng E.1. Ma trận đối chiếu yêu cầu

Mã yêu cầu	RQ	Thành phần	Sequence	Hiện thực chính	Kịch bản	Kết quả
FR-T01, FR-T02	RQ4	Tác nhân; Dịch vụ Chuyến đi và Điều phối	S2, S3	check_upcoming_trips, get_current_trip_info; routes/drivers.ts	UC01	Bảng 6.8
FR-T03	RQ4	Tác nhân; Dịch vụ Chuyến đi và Điều phối	S3	update_trip_status; routes/trips.ts	UC03	Không đủ mẫu
FR-T04	RQ4	Dịch vụ Chuyến đi và Điều phối; LiveKit SIP	S4	confirm_trip, reject_trip; dispatchService.ts	UC02	Bảng 6.8

Mã yêu cầu	RQ	Thành phần	Sequence	Hiện thực chính	Kịch bản	Kết quả
FR-T05	RQ4	Tác nhân; Dịch vụ Chuyến đi và Điều phối	S3	request_cancel_trip, confirm_cancel_trip	UC05	Bảng 6.10
FR-T06, FR-T07	RQ4	Dịch vụ Chuyến đi và Điều phối	—	create_walkup_trip; suggest_next_stop, get_optimal_route, get_trip_traffic	—	Chưa đánh giá riêng
FR-C01, FR-C02	RQ4	Tác nhân; Dịch vụ Chuyến đi và Điều phối; LiveKit SIP	S5	call_customer, call_custom_number; callService.ts	UC04	Bảng 6.8, Bảng 6.14
FR-C03	RQ4	Dịch vụ Chuyến đi và Điều phối; Dịch vụ Kênh liên lạc	S5	send_sms_to_customer; smsService.ts	—	Chưa đánh giá riêng
FR-C04	RQ4	Dịch vụ Chuyến đi và Điều phối	—	get_customer_location	—	Bảng 6.13
FR-C05	RQ4	Dịch vụ Nhật ký cuộc gọi	S6	summarize_last_call; conversation_service.py	—	Bảng 6.14
FR-W01, FR-W02	RQ4	Tác nhân; Dịch vụ Chuyến đi và Điều phối	—	create_reminder, extend_wait_time	—	Chưa đánh giá riêng
FR-I01, FR-I02	RQ4	Dịch vụ Chuyến đi và Điều phối	—	report_customer_no_show, report_trip_issue	UC06	Bảng 6.10
FR-E01, FR-E02	RQ4	Dịch vụ Chuyến đi và Điều phối	—	get_today_earnings, get_earnings_summary, set_driver_status	UC08	Bảng 6.8
FR-F01	RQ4	Tác nhân (truy xuất tri thức)	—	answer_app_faq; app/rag	UC07	Bảng 6.8

Mã yêu cầu	RQ	Thành phần	Sequence	Hiện thực chính	Kịch bản	Kết quả
FR-L01	—	Tác nhân	—	voicebot/locales/vn, voicebot/locales/en	—	Chưa đánh giá riêng
FR-L02	RQ4	Tác nhân	—	Theo dõi im lặng trong session.py	UC09	Bảng 6.10
FR-L03	RQ4	Tác nhân	S4	Tập công cụ theo loại phiên trong locales/*/agent.py	UC02	Bảng 6.8
FR-A01	—	Ứng dụng tài xế	S2	wakeWordService.ts	UC10	Chưa đo
FR-A02	—	Tác nhân	S5	Cụm từ kết thúc chế độ nói trực tiếp	—	Chưa đánh giá riêng
FR-O01, FR-O02	—	Dịch vụ Giám sát vận hành; Dịch vụ Nhật ký cuộc gọi; tác nhân	S7	session_metrics.py; ops-service/src/services/ reports; ReportsPage.tsx	UC11	Bảng 6.14
NFR-01	RQ4	Tác nhân	S3	Phân loại phiên; hành động chờ xác nhận	Danh mục hành vi	Bảng 6.10
NFR-02	RQ2	Tác nhân; nhà cung cấp AI	S2, S3	turn_filler.py; prefetch.py; context_store.py	UC01, UC03, UC04, UC07	Bảng 6.4, Bảng 6.6
NFR-03	RQ1	Tác nhân (ECS); các Lambda; DynamoDB	—	infra/llm-orchestrator/ cfn.yaml (DesiredCount); infra/*/sam.yaml	SC-01 đến SC-03	Bảng 6.11
NFR-04	RQ1	Tác nhân; Dịch vụ Nhật ký cuộc gọi; nhà cung cấp AI	S3, S6	providers/fallback.py; backend_api.py; conversation_service.py	RS-01 đến RS-05	Bảng 6.12
NFR-05	—	Dịch vụ Định danh; mọi dịch vụ	S1	tokenService.ts; middleware xác minh JWT; tham số NoEcho	Danh mục bảo mật	Bảng 6.13

Mã yêu cầu	RQ	Thành phần	Sequence	Hiện thực chính	Kịch bản	Kết quả
CON-01	—	Tác nhân	S3	backend_api.py	Kiểm tra mã nguồn	Bảng 6.13
CON-02	—	Mọi dịch vụ	—	Bảng DynamoDB riêng từng stack	Kiểm tra cấu hình	Bảng 5.6
CON-03	—	Dịch vụ Định danh	S1	tokenService.ts	Kiểm tra mã nguồn	Bảng 6.13
CON-04	—	Mọi dịch vụ	—	Nhật ký gắn room và conv	Kiểm tra nhật ký	Bảng 6.13

Phụ lục F. Đối chiếu sequence diagram với mã nguồn

Bảng F.1 ghi vị trí mã nguồn (tệp và dòng, tính từ thư mục src/backend/ tại thời điểm viết) hiện thực các bước của sequence S1–S6 ở mục 4.5.

Bảng F.1. Đối chiếu các bước sequence với mã nguồn

Sequence	Bước	Thông điệp	Vị trí mã nguồn
S1	1	POST /api/v1/auth/login	identity-service/src/routes/auth.ts:109
S1	6	Ký access token, refresh token	identity-service/src/services/tokenService.ts:16, :22
S1	9	POST /api/v1/auth/refresh	identity-service/src/routes/auth.ts:142
S2	1	POST /api/v1/voice/token	external-api-service/src/routes/voice.ts:47
S2	4	Tạo phòng driver-{số}-{UUID}	external-api-service/src/routes/voice.ts:96
S2	5	Ký token LiveKit	external-api-service/src/routes/voice.ts:157
S2	6	Phân công tác nhân	external-api-service/src/routes/voice.ts:160; services/voiceSessionService.ts:38
S2	10	PUT /api/v1/drivers/me/session	llm-orchestrator/app/services/backend_api.py:501; external-api-service/src/routes/drivers.ts:164
S2	12	GET /api/v1/drivers/me/context	llm-orchestrator/app/services/backend_api.py:217; external-api-service/src/routes/drivers.ts:91

Sequence	Bước	Thông điệp	Vị trí mã nguồn
S3	2, 4	Chuỗi nhà cung cấp dự phòng, thời gian chờ 5 giây	llm-orchestrator/app/providers/__init__.py:80, :98, :115
S3	5	Câu đệm sau 2 giây	llm-orchestrator/app/voicebot/processors/turn_filler.py:19
S3	7	PATCH /api/v1/trips/{tripId}, thời gian chờ 8 giây	llm-orchestrator/app/services/backend_api.py:242; external-api-service/src/routes/trips.ts:256
S4	1	POST /api/v1/trips/{tripId}/dispatch	external-api-service/src/routes/trips.ts:540
S4	2–5	Tạo phòng, phân công tác nhân, quay số SIP	external-api-service/src/services/dispatchService.ts:24
S4	8	confirm_trip, reject_trip cập nhật trạng thái	llm-orchestrator/app/voicebot/processors/confirm_trip_flow.py:34
S5	2	POST /api/v1/calls/start, thời gian chờ 25 giây	llm-orchestrator/app/services/backend_api.py:289; external-api-service/src/routes/calls.ts:46
S5	2–4	Ba chế độ gọi, quay số SIP	external-api-service/src/services/callService.ts:123, :148; services/telephony/livekit.ts:19
S5	6	POST /api/v1/calls/complete	llm-orchestrator/app/services/backend_api.py:390; external-api-service/src/routes/calls.ts:127
S5	7–9	POST /api/v1/sms/send	llm-orchestrator/app/services/backend_api.py:322; external-api-service/src/routes/sms.ts:7; services/smsService.ts:5; external-channel-service/src/routes/sms.ts:7
S6	2	POST /api/v1/records, thử lại có giới hạn	llm-orchestrator/app/services/conversation_service.py:270; call-records-service/src/routes/records.ts:6
S6	5–7	GET /api/v1/calls/latest, GET /api/v1/records	external-api-service/src/routes/calls.ts:140; call-records-service/src/routes/records.ts:15, :28
S5	11	Lưu sự kiện vào channel-events	external-channel-service/src/services/twilioMonitor.ts; services/events/dynamoStore.ts
S7	1	Sự kiện theo lịch source=ops.schedule	ops-service/src/index.ts (handler); infra/ops-service/sam.yaml (ScheduleV2)
S7	2–3	GET /api/v1/records?date=&cursor=	ops-service/src/services/reports/index.ts (fetchRecords); call-records-service/src/services/recordService.ts (listByDate)

Sequence	Bước	Thông điệp	Vị trí mã nguồn
S7	4–6	Tổng hợp; chấm LLM trên mẫu	ops-service/src/services/reports/aggregate.ts; judge.ts
S7	7–9	Lưu daily-reports; GET /api/v1/reports/daily	ops-service/src/services/reports/store.ts; ops-service/src/routes/reports.ts

Phụ lục G. Bảng ánh xạ tên thành phần

Thân luận văn dùng tên tiếng Việt theo chức năng; Bảng G.1 đối chiếu với tên thư mục mã nguồn, tài nguyên AWS và lớp trên Hình 4.1.

Bảng G.1. Ánh xạ tên thành phần

Tên trong luận văn	Tên trong mã nguồn	Tài nguyên triển khai	Lớp trên Hình 4.1
Dịch vụ Định danh	identity-service	Lambda, API Gateway REST, DynamoDB (accounts, driver-settings)	Microservices; Data
Dịch vụ Chuyến đi và Điều phối	external-api-service	Lambda, API Gateway REST và WebSocket, DynamoDB (trips, ws-connections)	Microservices; API Gateway; Data
Dịch vụ Kênh liên lạc	external-channel-service	Lambda, API Gateway REST, DynamoDB (channel-events)	Microservices; Data
Dịch vụ Nhật ký cuộc gọi	call-records-service	Lambda, API Gateway REST, DynamoDB (call-records)	Microservices; Data
Dịch vụ Giám sát vận hành	ops-service	Lambda, API Gateway REST, DynamoDB (daily-reports), EventBridge Scheduler	Microservices; Data; Cross-cutting
Tác nhân hội thoại giọng nói	llm-orchestrator	ECS Fargate, ECR, CloudWatch Logs	Real-time Communication & Conversational AI
Nền tảng truyền thông thời gian thực	LiveKit Cloud	Dịch vụ bên ngoài	Real-time Communication & Conversational AI
Ứng dụng tài xế	driver-app	—	Client
Ứng dụng khách hàng	customer-app, customer-web	S3 (bản web)	Client

Tên trong luận văn	Tên trong mã nguồn	Tài nguyên triển khai	Lớp trên Hình 4.1
Trang quản trị điều hành	admin-panel	S3	Client
Trang giám sát hệ thống	super-admin-panel	S3	Client
Nhà cung cấp dịch vụ thoại	Twilio	Dịch vụ bên ngoài	External Systems